

TRƯỜNG ĐẠI HỌC KHOA HỌC TỰ NHIÊN, ĐHQG-HCM
KHOA CÔNG NGHỆ THÔNG TIN



BÁO CÁO TIẾN ĐỘ GIỮA KÌ

Môn học: Nhận dạng

Lớp: 23KHMT

Giảng viên hướng dẫn: Thầy Võ Thanh Lâm
Thầy Lê Hoàng Thái
Thầy Nguyễn Thanh Tình

Sinh viên: Trương Quốc Cường – 23127333
Lê Anh Duy – 23127011
Trần Gia Huy – 23127199

TP. Hồ Chí Minh, ngày 1 tháng 3 năm 2026

Lời mở đầu

Phát hiện khuôn mặt là một trong những bài toán nền tảng và có ứng dụng rộng rãi nhất trong lĩnh vực thị giác máy tính và nhận dạng mẫu. Từ các hệ thống giám sát an ninh, xác thực sinh trắc học, phân tích mạng xã hội đến các ứng dụng thực tế tăng và giảm trên thiết bị di động, khả năng định vị chính xác vị trí khuôn mặt trong ảnh và video đóng vai trò then chốt trong toàn bộ chuỗi xử lý nhận dạng.

Trong khuôn khổ môn học Nhận dạng, nhóm chúng em được giao nhiệm vụ nghiên cứu và phân tích sâu bài toán phát hiện khuôn mặt qua hai góc nhìn bổ trợ: phương pháp cổ điển và phương pháp hiện đại dựa trên học sâu. Báo cáo tiến độ giữa kỳ này tập trung vào hai hướng nghiên cứu chính. Thứ nhất, chúng em phân tích chi tiết chương sách về phát hiện khuôn mặt cổ điển, đặc biệt là phương pháp Viola–Jones với cấu trúc cascade tăng cường, đặc trưng Haar-like và các kỹ thuật tối ưu tính toán. Thứ hai, chúng em nghiên cứu bài báo SCRFD được công bố tại hội nghị ICLR 2022, một trong những phương pháp tiên tiến nhất hiện nay trong việc tái phân bổ tài nguyên tính toán và phân bổ mẫu huấn luyện để cải thiện hiệu năng phát hiện khuôn mặt rất nhỏ.

Cấu trúc báo cáo được tổ chức thành hai chương chính. Chương I trình bày phân tích chương sách về phát hiện khuôn mặt cổ điển, bao gồm động lực nghiên cứu, kiến trúc nền, các kỹ thuật cốt lõi như thấp hình ảnh, quét cửa sổ trượt, cascade classifier, AdaBoost và các cải tiến kỹ thuật. Chương II tập trung vào phân tích bài báo SCRFD, làm rõ kiến trúc Backbone–Neck–Head, hai cơ chế tối ưu Computation Redistribution và Sample Redistribution, cùng với đánh giá so sánh với các phương pháp tiền nhiệm.

Qua quá trình nghiên cứu và thực hiện báo cáo này, nhóm chúng em đã có cơ hội tiếp cận sâu sắc với cả nền tảng lý thuyết cổ điển lẫn xu hướng nghiên cứu hiện đại trong lĩnh vực nhận dạng mẫu nói chung và phát hiện khuôn mặt nói riêng. Chúng em nhận thấy rằng mặc dù công nghệ học sâu đã đạt được những bước tiến vượt bậc, các nguyên lý thiết kế từ phương pháp cổ điển như loại sớm, phân bổ tính toán và xử lý mất cân bằng lớp vẫn giữ giá trị tham khảo quan trọng trong thiết kế hệ thống hiện đại.

Nhóm chúng em xin chân thành cảm ơn Thầy Võ Thanh Lâm, Thầy Lê Hoàng Thái và Thầy Nguyễn Thanh Tình đã tận tình hướng dẫn và tạo điều kiện để chúng em hoàn thành báo cáo này. Mặc dù đã cố gắng nghiên cứu và trình bày một cách có hệ thống, báo cáo không tránh khỏi những thiếu sót. Chúng em rất mong nhận được sự đóng góp ý kiến và chỉ bảo của các Thầy để báo cáo được hoàn thiện hơn trong giai đoạn tiếp theo.

Thành phố Hồ Chí Minh, ngày 1 tháng 3 năm 2026

Nhóm sinh viên thực hiện

Thông tin chung

Tên môn học:	Nhận dạng
Mã môn học:	CSC14006
Lớp:	23KHMT
Học kỳ:	2
Năm học:	2025–2026
Mã nguồn:	https://github.com/TQC0103/Nhan_dang
Giảng viên:	Thầy Võ Thanh Lâm Thầy Lê Hoàng Thái Thầy Nguyễn Thanh Tình
Sinh viên:	23127333 Trương Quốc Cường 23127011 Lê Anh Duy 23127199 Trần Gia Huy

Thông tin đề tài

- **Chủ đề:** Sự tiến hóa của kỹ thuật phát hiện khuôn mặt, từ phương pháp cổ điển đến hướng tối ưu kiến trúc và dữ liệu trong học sâu.
- **Chương sách được chọn:** *Handbook of Face Recognition*, ấn bản thứ hai, Chapter 11 *Face Detection*, trang 277–301, tác giả Stan Z. Li và Jianxin Wu.
- **Bài báo phân tích:** *Sample and Computation Redistribution for Efficient Face Detection*.
- **Tác giả:** Jia Guo, Jiankang Deng, Alexandros Lattas, Stefanos Zafeiriou.
- **Hội nghị:** ICLR 2022.
- **Xếp hạng hội nghị:** CORE A*.
- **Mục tiêu báo cáo giữa kỳ:** nắm khung phát hiện ba bước, tái lập detector Viola–Jones theo ví dụ trong chương sách và phân tích phương pháp SCRFD theo bài báo gốc.
- **Phạm vi:** không tái tạo pha tìm kiếm NAS do giới hạn tài nguyên tính toán; phần đối chiếu SCRFD dựa trên số liệu công bố trong bài báo; phần minh họa triển khai mở rộng sẽ thực hiện ở báo cáo cuối kỳ.

Bảng tự đánh giá theo tiêu chí chấm điểm

Tiêu chí	Điểm tối đa	Tự chấm	Minh chứng
1. Nhận dạng và mô tả kỹ thuật trong chương sách Xác định đúng kỹ thuật trung tâm của chương sách Trình bày rõ nguyên lý vận hành, các bước chính, mô hình toán hoặc kiến trúc	2.0	2.0	Chương I
2. Phân tích phương pháp trong bài báo khoa học Trình bày rõ phương pháp chính của bài báo Giải thích mục tiêu kỹ thuật, cách tiếp cận và lý do phương pháp hiệu quả	2.0	2.0	Chương II
3. Mối liên hệ giữa chương sách và bài báo Chỉ ra cách phương pháp trong bài báo được xây dựng dựa trên kỹ thuật trong chương sách Phân tích khác biệt về phương pháp giữa nội dung sách và tiếp cận nghiên cứu hiện đại	2.0	2.0	Chương II
4. Đánh giá kỹ thuật về điểm mạnh, hạn chế và phạm vi áp dụng Đánh giá điểm mạnh của phương pháp trình bày trong bài báo Nêu hạn chế, giả định và các vấn đề còn mở	2.0	2.0	Chương I và Chương II
5. Nhận định cá nhân và khả năng mở rộng Nhận định về hiệu quả hoặc ý nghĩa thực tiễn của phương pháp Đề xuất cải tiến hoặc hướng ứng dụng khác	1.0	1.0	Chương II
6. Trình bày học thuật và chất lượng báo cáo Chất lượng trình bày và diễn đạt trong báo cáo và thuyết trình Tuân thủ liêm chính học thuật, trích dẫn và ghi nguồn đầy đủ	1.0	1.0	Toàn báo cáo
Tổng	10.0	10.0	

Mục lục

Lời mở đầu	1
Thông tin chung	2
Thông tin đề tài	2
Bảng tự đánh giá theo tiêu chí chấm điểm	3
Danh mục hình	5
Danh mục bảng	6
Thuật ngữ và chữ viết tắt	7
I PHÂN TÍCH CHƯƠNG SÁCH: PHÁT HIỆN KHUÔN MẶT CỔ ĐIỂN	9
1 Giới thiệu và động lực	9
2 Các công trình liên quan và kiến thức nền	9
3 Phương pháp / Kỹ thuật cốt lõi	10
4 Phân tích kết quả trong chương sách	23
5 Minh họa cài đặt của nhóm	26
6 Thảo luận phản biện	31
7 Kết luận	34
II PHÂN TÍCH BÀI BÁO: SCRFD, ICLR 2022	35
1 Giới thiệu và động lực	35
2 Các công trình liên quan và kiến thức nền	35
3 Phương pháp bài báo đề xuất	37
4 Phân tích thực nghiệm	47
5 Minh họa cài đặt (để ở báo cáo cuối kỳ)	48
6 Thảo luận phản biện	48
7 Kết luận	50
III PHÂN TÍCH THỰC NGHIỆM BỔ SUNG CHO SCRFD	51
1 Mục tiêu và thiết lập thực nghiệm	51
2 Hai thành phần cải tiến	51
3 Kết quả định lượng	54
4 Vì sao mô hình cải tiến tốt hơn mô hình gốc	55
5 Vì sao bộ 12 mức theo bài báo cho hành vi khác	57
6 Kết luận	59
Tài liệu tham khảo	61

Danh mục hình

I.1	Luồng cài đặt detector cổ điển theo kiểu thác ảnh, quét cửa sổ trượt, cascade và gom cụm hộp bao.	11
I.2	Fig. 11.2 trong chương sách: minh họa haar filter. 1 đặc trưng là giá trị hiệu giữa phần màu trắng và màu đen.	17
I.3	Fig. 11.10 trong chương sách: minh họa của cấu trúc phát hiện khuôn mặt ở đa góc nhìn. Nguồn Huang et al. [7]	22
I.4	Fig. 11.14 trong chương sách: kết quả phát hiện khuôn mặt chính diện bằng hộp trắng.	24
I.5	Fig. 11.15 trong chương sách: kết quả phát hiện khuôn mặt đa góc nhìn trên bộ ảnh CMU.	25
I.6	So sánh ví dụ trong sách và kết quả tái lập của nhóm trên cùng ảnh Fig. 11.14. Màu khung trong hai hình tái lập chỉ dùng để phân biệt cấu hình, không biểu diễn TP, FP hay FN.	27
I.7	Đối chiếu kết quả đa góc nhìn: sách và tái lập trên cùng ảnh Fig. 11.15.	28
I.8	Kết quả tái lập theo định hướng đánh giá của mục 11.6 trong chương sách.	29
I.9	Phân tích hạn chế Viola–Jones trên một ảnh khó của WIDER FACE validation.	30
I.10	Minh họa cấu trúc phân nhánh hình cây từ thô đến tinh để xử lý khuôn mặt đa góc nhìn.	34
II.1	Quy trình phát hiện chuẩn dùng chung cho bộ phát hiện cổ điển và hiện đại.	36
II.2	Lộ trình tiến hóa từ phát hiện khuôn mặt thủ công đến SCRFD, nhánh một giai đoạn.	36
II.3	Minh họa kiến trúc nền SCRFD theo ba khối: Backbone, Neck và Head.	38
II.4	Quy trình tìm kiếm hai bước trong SCRFD để tái phân bố tính toán.	43
III.1	So sánh chỉ số Easy AP, Medium AP, Hard AP và mAP giữa mô hình gốc và mô hình cải tiến trên hai bộ tỉ lệ cắt.	54
III.2	Mức tăng hoặc giảm của mô hình cải tiến so với mô hình gốc trên từng chỉ số đánh giá.	55
III.3	Mật độ anchor dương trên mỗi khuôn mặt rất nhỏ trước và sau khi áp dụng cơ chế gán nhãn cải tiến.	56
III.4	Mức tăng khả năng thu hồi trên tập Hard theo từng khoảng kích thước khuôn mặt.	56
III.5	Mức tăng khả năng thu hồi trên tập Hard theo từng khoảng kích thước khuôn mặt.	57
III.6	So sánh hình học của hai tập tỉ lệ cắt và phân phối xác suất tương ứng.	58
III.7	So sánh phân phối kích thước khuôn mặt sau bước cắt và đổi cỡ ảnh giữa hai bộ tỉ lệ cắt.	59

Danh mục bảng

2	Chữ viết tắt dùng trong báo cáo	7
3	Đối chiếu thuật ngữ tiếng Việt - tiếng Anh	8
I.1	Kết quả tái lập cấu hình theo ba tài liệu [11], [12], [13] trên tập con 200 ảnh WIDER FACE validation.	29
II.1	So sánh phương pháp chương sách và SCRFD: cùng mục tiêu, khác cách hiện thực	50
III.1	Kết quả định lượng của mô hình gốc và mô hình cải tiến trên hai bộ tỉ lệ cắt	55

Thuật ngữ và chữ viết tắt

A. Chữ viết tắt

Bảng 2: Chữ viết tắt dùng trong báo cáo

Viết tắt	Nghĩa tiếng Việt	Mở rộng tiếng Anh
AP	Độ chính xác trung bình	Average Precision
CR	Tái phân bố tính toán	Computation Redistribution
SR	Tái phân bố mẫu	Sample Redistribution
NMS	Loại bỏ không cực đại	Non-Maximum Suppression
CNN	Mạng nơ-ron tích chập	Convolutional Neural Network
R-CNN	Mạng nơ-ron tích chập theo vùng	Region-based Convolutional Neural Network
FPS	Số khung hình mỗi giây	Frames Per Second
FLOPs	Số phép toán dấu chấm động	Floating-Point Operations
ICLR	Hội nghị Quốc tế về Biểu diễn Học máy	International Conference on Learning Representations
LBP	Mẫu nhị phân cục bộ	Local Binary Pattern
SCRFD	Tái phân bố mẫu và tính toán cho phát hiện khuôn mặt hiệu quả	Sample and Computation Redistribution for Efficient Face Detection

B. Bảng đối chiếu thuật ngữ dịch

Bảng 3: Đối chiếu thuật ngữ tiếng Việt - tiếng Anh

Thuật ngữ tiếng Việt (dùng trong báo cáo)	Thuật ngữ tiếng Anh tương ứng
Phát hiện khuôn mặt	Face detection
Khuôn mặt rất nhỏ	Tiny face
Điểm ảnh	Pixel
Mô hình cơ sở	Baseline
Quy trình phát hiện	Detection pipeline
Cửa sổ trượt	Sliding window
Mạng trục chính	Backbone
Cổ đặc trưng	Neck
Đầu dự đoán	Head
Phát hiện một giai đoạn	One-stage detection
Phát hiện hai giai đoạn	Two-stage detection
Dự đoán dày đặc	Dense prediction
Tăng cường dữ liệu theo tỉ lệ	Scale augmentation
Kiểm thử đa tỉ lệ	Multi-scale testing
Tập khó	Hard set
Dịch chuyển miền dữ liệu	Domain shift
Dương tính giả	False positive
Benchmark	Benchmark
Chưng cất tri thức	Distillation
Thích nghi miền dữ liệu	Domain adaptation

Chương I

PHÂN TÍCH CHƯƠNG SÁCH: PHÁT HIỆN KHUÔN MẶT CỔ ĐIỂN

1 Giới thiệu và động lực

Trong một hệ thống nhận dạng khuôn mặt hoàn chỉnh, phát hiện khuôn mặt là bước mở đầu của toàn bộ chuỗi xử lý. Trước khi chuẩn hóa hình học, trích xuất đặc trưng hay so khớp danh tính, hệ thống phải xác định đúng vị trí và phạm vi khuôn mặt trong ảnh hoặc trong khung hình video. Sai lệch ở bước này sẽ lan sang các bước sau và làm giảm hiệu năng toàn hệ thống.

Về bản chất, phát hiện khuôn mặt không chỉ là tìm một hình chữ nhật bao quanh khuôn mặt. Đây là bài toán phân loại mẫu trên không gian ảnh con, trong đó cần tách lớp có mặt và lớp không có mặt dưới biến thiên lớn về vị trí, tỉ lệ, góc nhìn, chiếu sáng, biểu cảm và che khuất. Không gian ảnh có số chiều cao, trong khi mẫu mặt chỉ chiếm tỉ lệ nhỏ và tạo thành một cấu trúc phi tuyến phức tạp. Do đó, bài toán khó đồng thời ở cả biểu diễn dữ liệu lẫn xây dựng ranh giới quyết định.

Các ứng dụng thực tế như giám sát, xác thực sinh trắc học và phân tích video còn đặt thêm ràng buộc thời gian thực. Vì vậy, bộ phát hiện phải cân bằng chặt giữa độ chính xác và hiệu quả tính toán.

Động lực của chương này là làm rõ vai trò nền tảng của phát hiện khuôn mặt trong hệ nhận dạng, xác định các thách thức cốt lõi theo góc nhìn hình học và thống kê, và hệ thống hóa các hướng giải bài toán từ mô hình dựa trên hình học đến mô hình dựa trên biểu diễn và học máy. Chương cũng đóng vai trò cầu nối giữa nền tảng học không gian con và phân loại mẫu ở các chương trước với hệ thống nhận dạng hoàn chỉnh ở các chương sau.

[1]

2 Các công trình liên quan và kiến thức nền

Trong cấu trúc chung của cuốn sách, phát hiện khuôn mặt thuộc giai đoạn định vị khuôn mặt, đứng trước chuẩn hóa và trích xuất đặc trưng. Nếu các chương trước tập trung vào học không gian con, mô hình hóa đa tạp và bài toán nhiều chiều ít mẫu, thì chương này đưa các ý tưởng đó vào một tác vụ cụ thể là phân biệt ảnh con có mặt và ảnh con không có mặt.

Vì vậy, phần kiến thức nền cần nhấn mạnh bốn điểm chính. Thứ nhất, không gian ảnh là không gian nhiều chiều nên chi phí tìm kiếm và chi phí học đều lớn. Thứ hai, đa tạp khuôn mặt có tính phi tuyến nên biên quyết định khó mô hình hóa bằng giả thiết đơn giản. Thứ ba, bài toán phát hiện là phân loại nhị phân nhưng có mất cân bằng mẫu mạnh do nền áp đảo số lượng. Thứ tư, biến thiên nội lớp của khuôn mặt thường rất lớn dưới điều kiện ngoài tự nhiên.

Các hướng tiếp cận kinh điển có thể nhóm thành ba tuyến.

- **Tuyến dựa trên hình học.** Khai thác quan hệ hình học giữa các thành phần khuôn mặt như mắt, mũi và

miệng. Tuyến này trực quan và gọn nhẹ nhưng phụ thuộc mạnh vào chất lượng định vị các điểm đặc trưng.

- **Tuyến dựa trên biểu diễn.** Quy bài toán về phân loại các cửa sổ ảnh bằng đặc trưng toàn cục và cục bộ. Tuyến này đánh dấu bước chuyển sang mô hình hóa thống kê.
- **Tuyến dựa trên học máy và phân tầng loại nhanh.** Học bộ phân loại từ dữ liệu và tổ chức theo nhiều tầng để loại sớm mẫu âm dễ, nhờ đó cải thiện đáng kể tốc độ suy luận.

Phát hiện khuôn mặt và nhận dạng khuôn mặt có quan hệ chặt nhưng mục tiêu khác nhau. Phát hiện khuôn mặt nhằm tách lớp có mặt và không có mặt trên không gian tìm kiếm rộng. Nhận dạng khuôn mặt nhằm phân biệt danh tính bên trong tập mẫu đã được định vị. Cả hai cùng chịu ảnh hưởng bởi tính phi tuyến của đa tập khuôn mặt, biến thiên nội lớp lớn và khó khăn do dữ liệu nhiều chiều ít mẫu. Tuy nhiên, phát hiện khuôn mặt thường chịu ràng buộc tính toán nghiêm ngặt hơn do phải xử lý đồng thời định vị và phân loại trên toàn ảnh. [1]

3 Phương pháp / Kỹ thuật cốt lõi

3.1 Nguyên lý vận hành theo quy trình 3 bước

Chương sách đặt nền trên hướng tiếp cận dựa trên biểu diễn kết hợp học máy thống kê. Thay vì mô hình hóa hình học 3D phức tạp của khuôn mặt, hệ thống xem phát hiện khuôn mặt là bài toán phân loại nhị phân trên từng ảnh con, gồm lớp có khuôn mặt và lớp không có khuôn mặt. Trong khung này, quy trình vận hành được tổ chức thành ba bước chuẩn:

- **Bước 1, sinh ứng viên.** Tạo tập cửa sổ ứng viên dày đặc trên nhiều mức tỉ lệ ảnh để bao phủ không gian vị trí và kích thước khuôn mặt.
- **Bước 2, chấm điểm và định vị.** Dùng bộ phân loại học được để đánh giá từng cửa sổ và giữ lại các cửa sổ có khả năng chứa khuôn mặt.
- **Bước 3, khử trùng lặp.** Gom các phát hiện chồng lấp cao thành kết quả cuối cùng.

Khung ba bước này là điểm nối trực tiếp giữa detector cổ điển và detector hiện đại: mục tiêu theo giai đoạn giữ nguyên, còn cách hiện thực từng giai đoạn thay đổi theo công nghệ.

3.2 Kỹ thuật cốt lõi rút ra từ chương sách

Kỹ thuật cốt lõi là một **bộ phát hiện cascade tăng cường dựa trên biểu diễn**, gồm các thành phần chính:

- Đặc trưng cục bộ kiểu Haar và biến thể MB-LBP.
- Ảnh tích phân để tính nhanh tổng đặc trưng hình chữ nhật.
- AdaBoost để kết hợp nhiều bộ phân loại yếu thành bộ phân loại mạnh.
- Cấu trúc cascade để loại sớm mẫu âm ngay từ các trạm đầu.
- Hậu xử lý gom cụm để hợp nhất các hộp chồng lấp.


Theo trình bày của chương sách, chuỗi kỹ thuật này liên tục được mở rộng bằng các biến thể đặc trưng và boosting như LBP, asymmetric boosting và vector boosting để tăng hiệu năng trong điều kiện thực tế khó hơn, gồm khuôn mặt nghiêng, nhiều mặt chồng lấp và khuôn mặt kích thước nhỏ. [1]

Ở mức luồng tổng thể, sơ đồ có thể đọc thành bốn khối xử lý liên tiếp:

- **Khối quét không gian.** Cửa sổ trượt đi qua toàn bộ ảnh và nhiều mức tỉ lệ trong tháp ảnh.

- **Khối trích xuất đặc trưng.** Đặc trưng Haar-like hoặc MB-LBP được tính nhanh bằng ảnh tích phân.
- **Khối học và ra quyết định.** AdaBoost học bộ phân loại mạnh từ các bộ phân loại yếu; biến thể bất đối xứng giúp ưu tiên giảm bỏ sót khuôn mặt.
- **Khối tăng tốc và hậu xử lý.** Cascade loại sớm vùng nền, sau đó gom cụm hộp bao để tạo đầu ra ổn định.

Sơ đồ trong Hình I.1 biểu diễn đầy đủ luồng xử lý theo đúng tinh thần chương sách. Các mục 3.3 đến 3.7 sẽ đi chi tiết theo đúng từng khối trong sơ đồ.



Hình I.1: Luồng cài đặt detector cổ điển theo kiểu tháp ảnh, quét cửa sổ trượt, cascade và gom cụm hộp bao.

3.3 Tạo tháp hình ảnh

3.3.1 Động cơ xử lý đa tỉ lệ trong phát hiện khuôn mặt

Trong bài toán phát hiện khuôn mặt, kích thước khuôn mặt thay đổi mạnh theo khoảng cách đến camera, tiêu cự và độ phân giải ảnh. Một bộ phân loại được huấn luyện trên cửa sổ cố định, ví dụ 24 nhân 24 điểm ảnh thường gặp trong họ phương pháp Viola–Jones, không thể áp trực tiếp cho mọi kích thước khuôn mặt trong ảnh. Trong chương sách, các ví dụ và so sánh cũng bàn đến nhiều kích thước cửa sổ con như 16 nhân 16 đến 32 nhân 32, cùng ví dụ 20 nhân 20 khi minh họa học ngưỡng. [1] Vấn đề kỹ thuật cốt lõi là giữ nguyên cấu trúc bộ phân loại nhưng vẫn bao phủ được nhiều tỉ lệ khuôn mặt trong cùng một lần suy luận. Giải pháp được dùng là tháp hình ảnh: thay đổi kích thước ảnh đầu vào theo nhiều mức, thay vì thay đổi kích thước bộ phân loại. [1], [2]

3.3.2 Nguyên lý xây dựng tháp hình ảnh

Gọi ảnh gốc là I_0 có kích thước $W_0 \times H_0$. Tạo chuỗi ảnh $\{I_k\}_{k=0}^K$ bằng phép co tỉ lệ với hệ số $s \in (0, 1)$:

$$I_k = \text{resize}(I_0, s^k)$$

trong đó k là chỉ số mức thấp và K là mức cuối sao cho kích thước ảnh vẫn đủ lớn để quét được cửa sổ chuẩn $w \times h$. Số mức thấp có thể ước lượng:

$$K \approx \left\lfloor \frac{\log(\min(W_0, H_0)/w)}{\log(1/s)} \right\rfloor$$

Mỗi mức thấp tương ứng một miền kích thước khuôn mặt khác nhau trong ảnh gốc. [1]

3.3.3 Vì sao resize ảnh thay vì resize cửa sổ

Có hai chiến lược xử lý đa tỉ lệ:

- Giữ ảnh cố định và thay đổi kích thước cửa sổ phân loại.
- Giữ cửa sổ phân loại cố định và thay đổi kích thước ảnh.

Viola-Jones chọn chiến lược thứ hai vì cửa sổ cố định cho phép dùng lại cùng bộ phân loại, giữ nguyên định nghĩa đặc trưng Haar trên lưới chuẩn và giữ pipeline thống nhất. Ảnh tích phân được tính riêng cho từng mức thấp với chi phí tuyến tính theo số điểm ảnh của mức đó, nên vẫn phù hợp cho xử lý thời gian thực ở thời điểm đề xuất. [2], [3]

3.3.4 Phân tích độ phức tạp tính toán

Ở mức k , ảnh có kích thước $W_k \times H_k$. Bỏ qua bước nhảy stride để xấp xỉ, số cửa sổ ứng viên:

$$N_k \approx (W_k - w)(H_k - h)$$

Tổng số cửa sổ trên toàn bộ tháp:

$$N_{\text{total}} = \sum_{k=0}^K (W_k - w)(H_k - h)$$

Với ảnh VGA 640 nhân 480 và cửa sổ 24 nhân 24, số ứng viên có thể tăng lên rất lớn. Điều này lý giải vì sao tháp ảnh phải đi cùng cơ chế loại nhanh để kiểm soát chi phí suy luận. [1]

3.3.5 Ảnh hưởng của hệ số tỉ lệ s

Hệ số s điều khiển trực tiếp đánh đổi giữa độ phủ tỉ lệ và tốc độ xử lý:

- s gần 1, ví dụ 0.95: nhiều mức thấp hơn, độ phủ tốt hơn, chi phí cao hơn.
- s nhỏ hơn, ví dụ 0.8: ít mức thấp hơn, suy luận nhanh hơn, nhưng có nguy cơ bỏ sót kích thước trung gian.

Vì vậy lựa chọn s là tham số nhạy với cả recall và độ trễ.

3.3.6 Quan hệ với mất cân bằng lớp

Phần lớn cửa sổ sinh ra từ tháp ảnh là nền không phải khuôn mặt. Khi số mức thấp tăng, số mẫu âm tăng rất nhanh, làm áp lực lọc mẫu dồn lên các trạm đầu của cascade. Do đó thiết kế tháp ảnh không tách rời khỏi thiết kế cascade nếu muốn giữ khả năng chạy gần thời gian thực.

3.3.7 Giới hạn của tháp hình ảnh cổ điển

Tháp hình ảnh đơn giản và hiệu quả, nhưng có ba giới hạn rõ:

- Chi phí tăng mạnh khi độ phân giải ảnh đầu vào tăng.
- Khó bao phủ tốt khuôn mặt cực nhỏ nếu nhỏ hơn ngưỡng cửa sổ tối thiểu.
- Không khai thác trực tiếp biểu diễn đa mức nội tại như feature pyramid trong kiến trúc học sâu hiện đại.

3.3.8 Kết luận

Tháp hình ảnh là cơ chế đa tỉ lệ cốt lõi trong pipeline Viola–Jones. Bằng cách co ảnh theo chuỗi tỉ lệ cố định và quét một cửa sổ chuẩn trên từng mức, hệ thống có thể phát hiện khuôn mặt ở nhiều kích thước mà không cần thay đổi bộ phân loại. Chi phí ứng viên tăng đáng kể, nhưng khi kết hợp với đặc trưng tính nhanh bằng ảnh tích phân và cơ chế cascade loại sớm, toàn hệ thống vẫn đạt hiệu năng thực dụng cho bối cảnh triển khai cổ điển. [1], [2], [3]

3.4 Quét cửa sổ trượt

3.4.1 Vai trò của bước quét cửa sổ trong pipeline

Sau khi xây dựng tháp hình ảnh để xử lý đa tỉ lệ, bước tiếp theo trong pipeline là quét cửa sổ trượt trên từng mức tháp. Mục tiêu của bước này là sinh ứng viên một cách có hệ thống, bao phủ toàn bộ không gian tìm kiếm và giảm nguy cơ bỏ sót vùng có khả năng chứa khuôn mặt ở giai đoạn đầu. Trong nhóm phương pháp cổ điển, đây là chiến lược vét cạn có kiểm soát. [1], [2]

3.4.2 Cơ chế hoạt động

Tại mỗi mức tháp I_k có kích thước $W_k \times H_k$, hệ thống dùng cửa sổ phân loại cố định $w \times h$, thường là 24 nhân 24 điểm ảnh. Cửa sổ được dịch chuyển tuần tự trên lưới tọa độ:

$$x = 0, 1, 2, \dots, W_k - w, \quad y = 0, 1, 2, \dots, H_k - h$$

Tại mỗi vị trí (x, y) , vùng ảnh con

$$R_{k,x,y} = I_k[x : x + w - 1, y : y + h - 1]$$

được đưa vào bộ phân loại để quyết định nhân khuôn mặt hoặc nền.

3.4.3 Bước nhảy stride và độ phủ không gian

Trong thực tế, cửa sổ không nhất thiết dịch chuyển từng điểm ảnh. Gọi Δ là bước nhảy:

$$x = 0, \Delta, 2\Delta, \dots, \quad y = 0, \Delta, 2\Delta, \dots$$

- Stride nhỏ: độ phủ mịn hơn, recall cao hơn, chi phí tính toán tăng.
- Stride lớn: nhanh hơn, nhưng dễ bỏ sót khuôn mặt nhỏ hoặc gần biên.

Trong triển khai thực tế của detector cổ điển, stride thường được đặt nhỏ để giữ độ phủ cao.

3.4.4 Phân tích số lượng cửa sổ ứng viên

Tại mức thấp k , số cửa sổ ứng viên xấp xỉ:

$$N_k \approx \left\lfloor \frac{W_k - w}{\Delta} \right\rfloor \cdot \left\lfloor \frac{H_k - h}{\Delta} \right\rfloor$$

Tổng số cửa sổ trên toàn tháp:

$$N_{\text{total}} = \sum_{k=0}^K \left(\left\lfloor \frac{W_k - w}{\Delta} \right\rfloor \cdot \left\lfloor \frac{H_k - h}{\Delta} \right\rfloor \right)$$

Với ảnh VGA 640 nhân 480, $w = h = 24$ và $\Delta = 1$, số cửa sổ có thể vượt 200 nghìn trên một ảnh. Điều này cho thấy bước quét cửa sổ là nguồn sinh ứng viên rất lớn và bắt buộc phải đi cùng cơ chế loại nhanh. [1]

3.4.5 Đặc điểm của chiến lược vét cạn

Sliding window có các đặc điểm:

- Không giả định trước vị trí khuôn mặt.
- Không phụ thuộc heuristic bối cảnh.
- Bao phủ toàn bộ không gian tìm kiếm.

Ưu điểm là đơn giản và khó bỏ sót nếu stride và scale đủ mịn. Nhược điểm là chi phí cao, số mẫu âm rất lớn và phụ thuộc mạnh vào năng lực bộ phân loại.

3.4.6 Tương quan với mất cân bằng lớp

Trong ảnh tự nhiên, phần lớn cửa sổ ứng viên là nền. Tỷ lệ âm trên dương có thể rất cao, nên:

- Trạng thái cần false positive rate thấp để chặn sớm cửa sổ âm.
- Cascade được dùng để giảm chi phí trung bình trên mỗi cửa sổ.
- Boosting được dùng để chọn đặc trưng có sức phân biệt cao.

Vì vậy sliding window trực tiếp tạo ra một bài toán phân loại nhị phân mất cân bằng mạnh, và kiến trúc Viola-Jones được tổ chức xoay quanh đúng đặc điểm này. [2], [3]

3.4.7 Giới hạn của phương pháp quét cửa sổ

Mặc dù đảm bảo độ phủ, quét cửa sổ có các giới hạn:

- Chi phí tăng theo độ phân giải ảnh.
- Không khai thác cấu trúc ngữ cảnh của cảnh.
- Không tận dụng tính liên tục thời gian nếu xử lý từng khung hình độc lập.
- Không tối ưu cho khuôn mặt rất nhỏ khi cửa sổ tối thiểu còn lớn.

Trong phạm vi chương sách, đây là một giới hạn được xử lý bằng thiết kế cascade và tối ưu đặc trưng tính nhanh, hơn là thay khung phát hiện bằng kiến trúc mới.

3.4.8 Kết luận

Quét cửa sổ trượt là cơ chế sinh ứng viên cốt lõi trong pipeline Viola-Jones. Khi kết hợp với tháp hình ảnh, hệ thống có thể bao phủ nhiều vị trí và tỷ lệ khuôn mặt. Chi phí tiềm ẩn rất lớn, nhưng cascade classifier ở bước sau sẽ loại nhanh phần lớn cửa sổ âm để giữ tốc độ suy luận ở mức thực dụng. [1], [2], [3]

3.5 Cascade classifier

3.5.1 Động cơ thiết kế: xử lý mất cân bằng lớp cực đoan

Sau bước tháp hình ảnh và quét cửa sổ trượt, hệ thống sinh ra số lượng rất lớn cửa sổ ứng viên. Trong thực tế, phần lớn cửa sổ là nền và chỉ một tỉ lệ rất nhỏ thực sự chứa khuôn mặt. Đây là bài toán phân loại nhị phân với mất cân bằng lớp rất mạnh:

$$P(\text{non-face}) \gg P(\text{face})$$

Nếu dùng một bộ phân loại phức tạp duy nhất cho mọi cửa sổ, chi phí trung bình sẽ rất cao vì đa số cửa sổ đều là âm. Cascade classifier được đề xuất để xử lý trực tiếp đặc điểm này. [2], [3]

3.5.2 Cấu trúc phân tầng

Cascade classifier là một chuỗi các bộ phân loại mạnh được sắp nối tiếp:

$$\text{Stage}_1 \rightarrow \text{Stage}_2 \rightarrow \dots \rightarrow \text{Stage}_N$$

Chương sách mô tả cơ chế này theo logic chuỗi dạng AND giữa các trạm mạnh, đồng thời thảo luận thêm biến thể soft-cascade theo hướng nhiều điểm thoát sớm để giảm thời gian kiểm tra. [1] Nguyên tắc vận hành:

- Nếu cửa sổ bị phân loại âm ở bất kỳ trạm nào thì dừng ngay.
- Chỉ cửa sổ vượt qua toàn bộ các trạm mới được xem là khuôn mặt.

Vì vậy cascade thực hiện dãy kiểm tra ngày càng khắt khe, với cơ chế loại sớm cho mẫu âm.

3.5.3 Phân tích hiệu năng theo từng stage

Gọi d_i là tỉ lệ phát hiện của stage i , và f_i là tỉ lệ báo động giả của stage i . Khi ghép nối tiếp N stage, hiệu năng tổng thể là:

$$D = \prod_{i=1}^N d_i, \quad F = \prod_{i=1}^N f_i$$

trong đó D là tỉ lệ phát hiện tổng thể và F là tỉ lệ báo động giả tổng thể.

Ví dụ, nếu mỗi stage có $d_i = 0.99$ và $f_i = 0.5$, với 20 stage:

$$D \approx 0.99^{20} \approx 0.82, \quad F \approx 0.5^{20} \approx 10^{-6}$$

Tỉ lệ báo động giả giảm theo cấp số nhân, trong khi tỉ lệ phát hiện giảm chậm hơn, tạo nên hiệu quả đặc trưng của cascade. [2]

3.5.4 Chi phí tính toán kỳ vọng

Gọi C_i là chi phí đánh giá stage i . Xác suất một cửa sổ đi tới stage i :

$$P(\text{survive to } i) = \prod_{j=1}^{i-1} f_j$$

Chi phí kỳ vọng trên một cửa sổ:

$$\mathbb{E}[C] = \sum_{i=1}^N \left(\prod_{j=1}^{i-1} f_j \right) C_i$$

Vì $f_j < 1$, số cửa sổ giảm nhanh theo từng stage. Do đó đa số cửa sổ bị loại ở trạm đầu và chi phí trung bình thấp hơn nhiều so với cách dùng một bộ phân loại đầy đủ cho mọi cửa sổ. Cascade vì vậy tối ưu chi phí kỳ vọng, không chỉ tối ưu độ chính xác. [1], [2]

3.5.5 Thiết kế từng stage

Mỗi stage thường tuân theo nguyên tắc:

- Stage đầu đơn giản, dùng ít đặc trưng, chi phí rất thấp.
- Stage sau phức tạp hơn, dùng nhiều đặc trưng để tăng độ phân biệt.

Trong thực hành, stage đầu có thể chỉ vài bộ phân loại yếu, còn stage sau có thể dùng nhiều hơn đáng kể. Cách phân bổ độ phức tạp theo tầng giúp tối ưu đánh đổi giữa tốc độ và độ chính xác.

3.5.6 Tối ưu từng stage trong huấn luyện

Huấn luyện cascade thường theo chuỗi:

- Huấn luyện stage i để đạt ngưỡng tỉ lệ phát hiện tối thiểu và tỉ lệ báo động giả mục tiêu.
- Dùng stage đã học để loại bỏ mẫu âm dễ.
- Huấn luyện stage $i + 1$ trên tập còn lại khó hơn.

Quá trình lặp lại đến khi tỉ lệ báo động giả toàn hệ thống đạt mục tiêu thiết kế. [2], [3]

3.5.7 Quan hệ giữa cascade và đặc trưng tính nhanh

Cascade chỉ thật sự hiệu quả khi chi phí đánh giá đặc trưng ở mỗi cửa sổ đủ thấp. Vì vậy ảnh tích phân và đặc trưng Haar là điều kiện thiết kế đi kèm: đặc trưng phải tính nhanh, bộ phân loại yếu phải đơn giản, rồi mới khai thác được lợi ích loại sớm của cascade. Nếu đặc trưng tính chậm, cascade sẽ mất lợi thế tốc độ.

3.5.8 Đánh giá tổng hợp: ưu điểm và hạn chế

Ưu điểm

- Tối ưu chi phí trung bình trên mỗi cửa sổ bằng cơ chế loại sớm.
- Phù hợp tự nhiên với mất cân bằng lớp rất lớn trong detection.
- Có thể đạt tốc độ gần thời gian thực trên phần cứng phổ thông.
- Dễ mở rộng theo mục tiêu giảm báo động giả bằng cách tăng số stage.

Hạn chế

- Phụ thuộc vào thứ tự và chất lượng stage đầu.
- Nếu stage đầu quá khắt khe, recall giảm đáng kể.
- Huấn luyện mang tính tuần tự nên khó tối ưu toàn cục.
- Khó khai thác ngữ cảnh không gian rộng như các mô hình CNN hiện đại.

3.5.9 Kết luận

Cascade classifier là lõi tối ưu tốc độ của phương pháp Viola–Jones. Bằng cách tổ chức nhiều bộ phân loại mạnh thành chuỗi và loại sớm các cửa sổ âm, cascade giảm mạnh chi phí tính toán trung bình trong khi vẫn duy trì tỉ lệ phát hiện cao. Thiết kế này giải quyết trực diện bài toán mất cân bằng lớp trong phát hiện khuôn mặt và là một đóng góp quan trọng bậc nhất của hướng cổ điển. [1], [2], [3]

3.6 Bộ phân loại mạnh trong từng trạm


Trong cấu trúc cascade, mỗi stage không phải là một phép kiểm tra đơn lẻ, mà là một bộ phân loại mạnh được xây dựng từ nhiều bộ phân loại yếu bằng AdaBoost. Mục này làm rõ ba thành phần nền tảng:

- Đặc trưng Haar-like.
- Integral image để tính đặc trưng nhanh.
- AdaBoost để chọn và kết hợp đặc trưng.

3.6.1 Không gian đặc trưng và cơ chế thể hiện đặc trưng Haar

Trong một cửa sổ có kích thước chuẩn 24×24 pixel, có tổng cộng 576 giá trị cường độ sáng. Nếu dùng trực tiếp vector điểm ảnh thô, biểu diễn này thường kém ổn định trước sự thay đổi của chiếu sáng, khó nhấn mạnh các cấu trúc đặc thù của khuôn mặt và tốn nhiều chi phí tính toán. Do đó, Viola-Jones đề xuất sử dụng đặc trưng Haar-like để thay thế.

Để hiểu rõ cơ chế này, cần phân biệt sự khác nhau căn bản giữa "cửa sổ" và "đặc trưng": cửa sổ 24×24 đóng vai trò là một khung không gian cố định, trong khi đặc trưng Haar là các filter bao gồm các vùng chữ nhật đen và trắng kề nhau. Các bộ lọc này có kích thước thay đổi (nhỏ hơn hoặc bằng 24×24) và được quét (trượt) qua các tọa độ khác nhau bên trong khung không gian đó.



Hình 11.2: Fig. 11.2 trong chương sách: minh họa haar filter. 1 đặc trưng là giá trị hiệu giữa phần màu trắng và màu đen.

Các mẫu điển hình thường gồm tổ hợp hai, ba hoặc bốn vùng chữ nhật. Chúng đóng vai trò như thước đo độ tương phản cục bộ. Các tương phản điển hình có thể kể đến như: vùng hốc mắt luôn tối hơn vùng má (phát hiện bằng mẫu hai vùng đặt nằm ngang), hay sống mũi sáng hơn vùng hai bên (phát hiện bằng mẫu ba vùng đặt thẳng đứng).

Sự đồ sộ của không gian đặc trưng bắt nguồn từ việc tổ hợp ba yếu tố của các bộ lọc:

1. **Loại mẫu hình (Type):** Cấu trúc hai, ba hoặc bốn vùng hình chữ nhật.
2. **Kích thước (Scale):** Bộ lọc có thể tự do co giãn kích thước từ mức rất nhỏ (như 2×2 pixel) cho đến khi lấp đầy toàn bộ cửa sổ 24×24 .
3. **Vị trí (Position):** Trượt bộ lọc qua mọi tọa độ khả dĩ bên trong giới hạn của cửa sổ.

Nhờ sự tổ hợp đa dạng này, chỉ trong một cửa sổ chuẩn 24×24 , hệ thống có thể sinh ra một không gian khổng lồ lên tới hơn 160.000 đặc trưng Haar khả dĩ. Số lượng biến thể này lớn hơn rất nhiều so với số lượng điểm ảnh thô ban đầu (576). Vì phần lớn trong số 160.000 đặc trưng này mang thông tin dư thừa hoặc vô dụng, việc áp dụng mô hình là bất khả thi nếu không có một cơ chế học máy (như AdaBoost) để tự động chọn lọc ra những đặc trưng mang lại độ chính xác cao nhất. [2], [3]

3.6.2 Integral Image: tính đặc trưng trong thời gian hằng

Cho ảnh $I(x, y)$, ảnh tích phân được định nghĩa:

$$II(x, y) = \sum_{x' \leq x, y' \leq y} I(x', y')$$

Về trực quan, ảnh tích phân giống một bảng cộng dồn diện tích: mỗi ô lưu tổng độ sáng của toàn bộ vùng phía trên-trái, nên tổng trên hình chữ nhật bất kỳ có thể lấy rất nhanh. Có thể tính theo một lượt quét bằng hai công thức đệ quy:

$$S(x, y) = S(x, y - 1) + I(x, y), \quad II(x, y) = II(x - 1, y) + S(x, y)$$

Tổng cường độ trên vùng chữ nhật có góc trên trái (x_1, y_1) và dưới phải (x_2, y_2) :

$$\text{Sum} = II(x_2, y_2) - II(x_1 - 1, y_2) - II(x_2, y_1 - 1) + II(x_1 - 1, y_1 - 1)$$

Nhờ đó, mỗi tổng vùng chỉ cần bốn phép truy xuất mảng, đạt độ phức tạp hằng số $O(1)$. [2]

3.6.3 Bộ phân loại yếu

Mỗi đặc trưng $z_k(x)$ tạo một bộ phân loại yếu dạng decision stump:

$$h(x; k, \tau, p) = \begin{cases} +1, & p z_k(x) < p \tau \\ -1, & \text{ngược lại} \end{cases}$$

trong đó k là chỉ số đặc trưng, τ là ngưỡng và $p \in \{+1, -1\}$ là cực tính. Mỗi bộ phân loại yếu chỉ dựa vào một đặc trưng nên năng lực phân biệt còn hạn chế.

3.6.4 AdaBoost: Xây dựng bộ phân loại mạnh

Với tập huấn luyện $\{(x_i, y_i)\}_{i=1}^N$, $y_i \in \{-1, +1\}$, mục tiêu là học:

$$H(x) = \text{sign} \left(\sum_{m=1}^M \alpha_m h_m(x) \right)$$

Có thể hình dung AdaBoost như cơ chế tập trung sửa sai: mẫu nào bị phân loại sai ở vòng trước sẽ được tăng trọng số để mô hình chú ý nhiều hơn ở vòng sau.

Quy trình AdaBoost chuẩn

- Khởi tạo trọng số mẫu $w_i^{(1)} = \frac{1}{N}$.
- Với mỗi vòng $m = 1, \dots, M$:
 - Huấn luyện bộ phân loại yếu h_m để tối thiểu hóa sai số có trọng số:

$$\epsilon_m = \sum_{i=1}^N w_i^{(m)} \mathbf{1}[h_m(x_i) \neq y_i]$$

- Tính hệ số tin cậy:

$$\alpha_m = \frac{1}{2} \ln \left(\frac{1 - \epsilon_m}{\epsilon_m} \right)$$

- Cập nhật trọng số:

$$w_i^{(m+1)} = w_i^{(m)} \exp(-\alpha_m y_i h_m(x_i))$$

- Chuẩn hóa lại tổng trọng số.

3.6.5 Diễn giải hình học của AdaBoost

AdaBoost có thể nhìn như tối ưu hóa hàm mất mát mũ, tăng biên phân loại và thực hiện chọn đặc trưng tự động. Mỗi vòng lặp chọn đặc trưng có sức phân biệt tốt nhất trong không gian đặc trưng lớn, tăng trọng số cho mẫu khó và giảm trọng số cho mẫu đã phân loại đúng. Vì vậy AdaBoost đồng thời giải quyết ba việc trong một khung chung: chọn đặc trưng, huấn luyện bộ phân loại và tối ưu trọng số kết hợp.

3.6.6 Quan hệ giữa AdaBoost và Cascade

Trong cascade, mỗi trạm là một bộ phân loại mạnh. Các trạm đầu thường dùng ít bộ phân loại yếu để xử lý nhanh, các trạm sau dùng nhiều hơn để tăng độ chính xác. Huấn luyện thường theo trình tự: huấn luyện trạm trước, loại bỏ mẫu âm dễ, rồi huấn luyện trạm sau trên tập còn lại. Thiết kế này tạo ra cơ chế tiết kiệm tính toán theo hướng loại sớm. [1], [2], [3]

3.6.7 Asymmetric Boosting (AsymBoost): Xử lý dữ liệu mất cân bằng

Trong phát hiện khuôn mặt, lượng cửa sổ nền (background) áp đảo hoàn toàn so với khuôn mặt, khiến mô hình dễ có xu hướng bỏ qua khuôn mặt. Để giải quyết, Viola & Jones phát triển **AsymBoost**. Bằng cách chấp nhận tăng tỷ lệ nhận diện nhầm nền thành mặt, AsymBoost giúp tỷ lệ bắt dính khuôn mặt đạt đến 99.9%, sự đánh đổi này sau đó sẽ được khắc phục triệt để nhờ kiến trúc Cascade nhiều tầng.

Quy trình AsymBoost chia sẻ hoàn toàn các bước tính sai số ϵ_m và hệ số α_m với AdaBoost chuẩn. Điểm khác biệt duy nhất nằm ở bước **cập nhật trọng số**, trong đó tích hợp thêm tham số phạt bất đối xứng $k > 1$:

$$w_i^{(m+1)} = w_i^{(m)} \exp(-\alpha_m y_i h_m(x_i)) \cdot \begin{cases} k & \text{nếu } y_i = +1 \text{ và } h_m(x_i) = -1 \\ 1 & \text{trong các trường hợp còn lại} \end{cases}$$

(Hệ số k khuếch đại trọng số của các mẫu khuôn mặt bị phân loại sai, buộc mô hình ưu tiên xử lý chúng ở vòng lặp tiếp theo). Sau đó, tiến hành chuẩn hóa lại tổng trọng số như bình thường.

3.6.8 Đánh giá ưu và nhược điểm

Ưu điểm

- Tự động chọn đặc trưng có ích từ không gian đặc trưng rất lớn.
- Tối ưu trực tiếp cho bài toán phân loại nhị phân.
- Phối hợp tốt với cascade trong bối cảnh mất cân bằng lớp mạnh.

Nhược điểm

- Có thể nhạy với nhiễu nếu khâu chuẩn hóa và lựa chọn dữ liệu huấn luyện chưa tốt.
- Các trạm sau phụ thuộc vào kết quả lọc của trạm trước.
- Khó biểu diễn quan hệ không gian phức tạp như các mô hình học sâu hiện đại.

3.6.9 Tổng kết

Trong pipeline Viola–Jones, AdaBoost giữ vai trò trung tâm: chọn đặc trưng Haar hữu ích nhất, kết hợp các bộ phân loại yếu thành bộ phân loại mạnh và tạo nên từng trạm của cascade. Khi kết hợp với integral image, hệ thống đạt tốc độ gần thời gian thực mà vẫn giữ độ chính xác tốt trong bối cảnh phát hiện khuôn mặt chính diện. [1], [2], [3]

3.7 Gom nhóm và hợp nhất các phát hiện

3.7.1 Hiện tượng nhiều phát hiện cho cùng một khuôn mặt

Do cơ chế thấp hình ảnh kết hợp quét cửa sổ trượt, một khuôn mặt thực thường được phát hiện ở nhiều vị trí gần nhau và ở nhiều mức tỉ lệ khác nhau. Stride nhỏ tạo ra nhiều vùng chồng lấp, còn các mức thấp lân cận tạo ra các hộp có kích thước hơi khác nhau quanh cùng đối tượng. Nếu giữ toàn bộ phát hiện dương tính sau cascade, một khuôn mặt có thể xuất hiện nhiều hộp bao, đầu ra thiếu ổn định và tăng nguy cơ báo động giả lẻ. Vì vậy bước hậu xử lý gom nhóm và hợp nhất là thành phần bắt buộc trong pipeline. [1], [4]

3.7.2 Nguyên lý gom nhóm dựa trên sự lân cận

Nguyên tắc trực quan của detector cổ điển là: nếu nhiều hộp dương tính gần nhau về vị trí và kích thước, chúng có khả năng cao cùng tương ứng một khuôn mặt. Ngược lại, phát hiện đơn lẻ không có lân cận xác nhận thường có xác suất là báo động giả cao hơn. Do đó, hậu xử lý được mô hình như một bài toán gom cụm hộp bao theo ba tiêu chí:

- Gần nhau về tọa độ tâm.
- Tương đương về kích thước.
- Có mức chồng lấp đáng kể.

3.7.3 Cơ chế xác nhận theo số lượng phát hiện

Chiến lược thường dùng trong triển khai cascade cổ điển:

- Gom các hộp lân cận thành cụm.
- Đếm số phát hiện trong từng cụm.
- Chỉ giữ cụm có số lượng đủ lớn.

Gọi n_j là số hộp thuộc cụm j . Một cụm được chấp nhận nếu:

$$n_j \geq T$$

trong đó T là ngưỡng xác nhận tối thiểu. Cơ chế này dựa trên quan sát rằng khuôn mặt thật thường sinh nhiều phát hiện chồng lấp, còn báo động giả ngẫu nhiên thường xuất hiện rời rạc.

3.7.4 Hợp nhất bounding box trong mỗi cụm

Sau khi cụm được chấp nhận, hệ thống tạo một hộp đại diện duy nhất. Hai cách phổ biến:

- Lấy trung bình tọa độ các hộp trong cụm.
- Chọn hộp có điểm tin cậy cao nhất.

Trong thực hành cascade cổ điển, cách lấy trung bình thường cho đầu ra ổn định hơn do làm mượt sai lệch nhỏ giữa các phát hiện lân cận.

3.7.5 Vai trò của hậu xử lý trong toàn hệ thống

Bước gom nhóm có ba vai trò trực tiếp:

- Giảm báo động giả bằng cách loại các phát hiện đơn lẻ.
- Ổn định đầu ra bằng cách hợp nhất nhiều hộp thành một hộp duy nhất cho mỗi khuôn mặt.
- Tăng độ tin cậy quyết định cuối theo cơ chế bỏ phiếu từ nhiều phát hiện lân cận.

3.7.6 Đánh giá tổng hợp: ưu điểm và hạn chế

Ưu điểm

- Đơn giản, dễ triển khai.
- Phù hợp đặc tính quét dày của sliding window.
- Cải thiện độ ổn định hiển thị trong ứng dụng thực tế.

Hạn chế

- Phụ thuộc vào ngưỡng xác nhận tối thiểu T .
- Có thể loại nhầm khuôn mặt nhỏ nếu số phát hiện sinh ra ít.
- Không trực tiếp tối ưu theo các tiêu chí đánh giá hiện đại.

3.7.7 Kết luận

Gom nhóm và hợp nhất phát hiện là bước hậu xử lý cuối trong pipeline detector cổ điển. Bằng cách khai thác hiện tượng một khuôn mặt sinh nhiều phát hiện lân cận, hệ thống loại bỏ phát hiện đơn lẻ và hợp nhất kết quả trùng lặp thành một hộp duy nhất. Bước này hoàn thiện chuỗi xử lý thấp hình ảnh, quét cửa sổ, cascade và học tăng cường, đồng thời bảo đảm đầu ra ổn định cho triển khai thực tế. [1], [4]

Cơ chế xác nhận dựa trên nhiều phát hiện lân cận phản ánh tư duy loại sớm và bỏ phiếu theo mật độ, trong đó các phát hiện đơn lẻ thường khó trở thành bằng chứng đủ mạnh cho quyết định cuối cùng. Những nguyên lý này tiếp tục được kế thừa dưới nhiều hình thức trong các hệ thống phát hiện đối tượng hiện đại, chẳng hạn ngưỡng hóa theo điểm tin cậy, khử trùng lặp bằng loại bỏ không cực đại và hợp nhất dự đoán ở giai đoạn hậu xử lý. [5], [6]


3.8 Áp dụng các cải tiến kỹ thuật vào bộ khung cơ sở

3.8.1 Định tuyến mô hình theo góc nhìn (Face-Pose Hierarchy)

Vấn đề thực tiễn

Bộ phân loại Cascade truyền thống thường chỉ được huấn luyện cho khuôn mặt nhìn thẳng (frontal face). Khi áp dụng vào môi trường thực tế với đa dạng góc xoay của đầu (in-plane và out-of-plane), hiệu năng của hệ thống suy giảm nghiêm trọng.

Cơ chế định tuyến (Routing)



Hình I.3: Fig. 11.10 trong chương sách: minh họa của cấu trúc phát hiện khuôn mặt ở đa góc nhìn. Nguồn Huang et al. [7]

Hệ thống sử dụng cấu trúc cây quyết định phân cấp thay vì một luồng tuyến tính I.3: các nút trên cây là một bộ phân loại mạnh, mỗi đường đi từ nút gốc đến nút lá là một luồng phân loại (cascade).

Đánh giá

- *Ưu điểm:* Mở rộng khả năng nhận diện đa góc độ (multiview) mà không làm giảm tốc độ rà quét (do chỉ chạy 1 luồng nhánh thay vì chạy song song mọi mô hình).
- *Hạn chế:* Tốn chi phí huấn luyện nhiều bộ Cascade; rủi ro sai số tích lũy (nếu trạm gốc phân loại sai góc, khuôn mặt sẽ bị đưa vào sai nhánh và bị loại bỏ vĩnh viễn).

3.8.2 Nâng cấp bộ trích xuất với đặc trưng MB-LBP

Vấn đề thực tiễn

Đặc trưng Haar-like cơ bản chỉ đo lường sự chênh lệch độ sáng đơn giản, dễ bị nhiễu loạn bởi điều kiện chiếu sáng và không phản ánh được kết cấu bề mặt của khuôn mặt.

Cơ chế trích xuất và Tham số hóa (Spatio-scale features)

- **Cấu trúc toán tử:** Thay vì so sánh pixel đơn lẻ, Multi-Block LBP (MB-LBP) so sánh tổng độ sáng của 1 khối trung tâm với 8 khối bao quanh nó. Kết quả trả về một mã nhị phân 8-bit, tương đương một số nguyên $c \in [0, 255]$.
- **Không gian đặc trưng:** Trong một cửa sổ nhận diện (ví dụ 24×24), một đặc trưng MB-LBP được định nghĩa bởi tọa độ (x, y) và tỷ lệ khối s (tạo ra toán tử kích thước $3s \times 3s$). Việc dịch chuyển và thay đổi s trong cửa sổ tạo ra hàng chục ngàn đặc trưng ứng viên. Thuật toán AdaBoost sẽ chọn ra các tọa độ và tỷ lệ có sự phân biệt tốt nhất.

Cơ chế phân loại: Look-up Table Classifier

Vì giá trị c là một biến phân loại chứ không phải giá trị liên tục, bộ phân loại yếu $h_m(x)$ không thể dùng ngưỡng cắt. Thay vào đó, nó học một **Bảng tra cứu (Look-up Table)**: Nhóm các mã MB-LBP thường xuyên xuất hiện ở ảnh khuôn mặt tại tọa độ đó thành một tập hợp S .

$$h_m(x) = \begin{cases} +1 & \text{nếu mã MB-LBP } c \in S \\ -1 & \text{nếu ngược lại} \end{cases}$$

Đánh giá

- *Ưu điểm:* Việc dùng tổng khối (block) giúp MB-LBP kháng nhiễu tốt hơn LBP gốc; đồng thời cấu trúc Look-up Table cho tốc độ thực thi tại runtime thậm chí còn nhanh hơn cả việc so sánh số thực của Haar-like.
- *Hạn chế:* Không gian 256 giá trị rời rạc có thể gây ra hiện tượng overfitting nếu tập dữ liệu huấn luyện không đủ lớn để phủ hết các phân bố mã.

3.8.3 Huấn luyện bất đối xứng với AsymBoost

Vấn đề thực tiễn

Bài toán trượt cửa sổ sinh ra sự mất cân bằng dữ liệu cực độ (1 khuôn mặt / hàng triệu ảnh nền). AdaBoost truyền thống dễ bị chệch, thiên vị lớp đa số để giảm sai số tổng, dẫn đến bỏ sót khuôn mặt.

Cơ chế huấn luyện

Sử dụng thuật toán Asymmetric Boosting (AsymBoost) để can thiệp vào quá trình cập nhật trọng số:


- Đưa vào hệ số phạt bất đối xứng $k > 1$.
- Nếu mô hình bỏ sót khuôn mặt, trọng số của mẫu đó bị khuếch đại lên k lần ở vòng lặp sau.
- Nếu mô hình nhận diện nhầm ảnh nền, trọng số chỉ được cập nhật bình thường.

Đánh giá

- *Ưu điểm:* Ép mô hình dịch chuyển ngưỡng quyết định, đảm bảo tỷ lệ phát hiện luôn tiệm cận 100%; phù hợp tuyệt đối với triết lý "thà bắt nhầm còn hơn bỏ sót" của các trạm Cascade đầu tiên.
- *Hạn chế:* Việc thiên vị lớp thiểu số làm tăng đáng kể tỷ lệ báo động giả, đẩy gánh nặng tính toán sang các trạm Cascade ở phía sau; đòi hỏi tinh chỉnh thủ công hệ số k .

4 Phân tích kết quả trong chương sách

Trong chương sách, ví dụ định tính quan trọng cho phát hiện khuôn mặt chính diện là Fig. 11.14, trong đó hệ thống phát hiện được minh họa trên 9 ảnh cảnh khác nhau với điều kiện nền và chiếu sáng thay đổi. [1]



Hình I.4: Fig. 11.14 trong chương sách: kết quả phát hiện khuôn mặt chính diện bằng hộp trắng.



Hình I.5: Fig. 11.15 trong chương sách: kết quả phát hiện khuôn mặt đa góc nhìn trên bộ ảnh CMU.

Phân tích từ ví dụ này cho thấy ba điểm kỹ thuật chính:

- Bộ phát hiện xử lý tốt các khuôn mặt chính diện có kích thước vừa đến lớn trong bối cảnh đời thường.
- Kết quả giữa các ảnh cho thấy hành vi tương đối ổn định khi nền thay đổi, phản ánh vai trò của cascade trong việc loại nhanh phần lớn cửa sổ âm.
- Chương sách nhấn mạnh đánh đổi giữa tỉ lệ phát hiện và số báo động giả, đồng thời dùng đường ROC để đánh giá ở cấp hệ thống. [1]

Với Fig. 11.15, chương sách chuyển sang bối cảnh đa góc nhìn, trong đó số lượng khuôn mặt lệch góc tăng rõ. Điểm này phù hợp với mô tả trong chương về các bộ phát hiện đa hướng dạng view-based và multiview cascade, thay vì chỉ dùng một bộ phân loại chính diện duy nhất. [1]

Đọc kỹ từ mục 11.6 cho thấy chương sách đặt ra một quy trình đánh giá có cấu trúc rõ:

- Tách riêng hai thành phần của hệ thống là bộ phân loại mặt và khâu hậu xử lý gom nhóm để đánh giá.

- Dùng hai kiểu dữ liệu kiểm tra gồm ảnh con kích thước cố định để đo bộ phân loại và ảnh tự nhiên để đo toàn hệ thống.
- Dùng cặp chỉ số tỉ lệ phát hiện và báo động giả, đồng thời nhấn mạnh số báo động giả sau hậu xử lý là chỉ số gần trực tiếp với đầu ra cuối.
- Dùng đường cong ROC với trục ngang là số báo động giả sau hậu xử lý trên bộ dữ liệu chuẩn MIT-CMU cho so sánh liên hệ thống.

Ở mục 11.6.2, sách còn tổng kết thêm các so sánh giữa các biến thể boosting, kiểu bộ học yếu và kích thước cửa sổ con, trong đó báo cáo rằng kích thước cửa sổ con 20 nhân 20 thường cho tỉ lệ phát hiện tốt ở miền báo động giả trung bình, còn 24 nhân 24 có thể phù hợp hơn ở miền báo động giả rất thấp. [1]

Giới hạn của ví dụ trong sách là tập trung chủ yếu vào nhóm ảnh khuôn mặt chính diện, chưa phản ánh đầy đủ tình huống khuôn mặt rất nhỏ, che khuất mạnh và thay đổi tư thế lớn như trong dữ liệu ngoài tự nhiên hiện đại. Vì vậy, ở mục sau nhóm thực hiện tái lập trực tiếp trên chính Fig. 11.14 rồi mở rộng sang ảnh khó để so sánh.

5 Minh họa cài đặt của nhóm

Phần này trình bày kết quả nhóm tự cài đặt để đối chiếu trực tiếp với ví dụ trong sách, sau đó mở rộng sang ảnh khó để phân tích hạn chế. Hệ thống dùng Viola–Jones qua OpenCV CascadeClassifier với bộ phân tầng Haar Cascade mặc định. [2], [3], [4], [8] Nhóm chạy một lượt đánh giá toàn tập trên 1687 ảnh lấy từ WIDER FACE validation, đây là số ảnh tải và đọc nhân thành công trong pipeline ở thời điểm thực nghiệm. [9], [10] Theo bộ chia công bố của WIDER FACE, tập validation có 3226 ảnh, vì vậy các sweep ở Hình 1.8 được chạy trên 3222 ảnh đọc nhân thành công để bám sát tập validation gần đầy đủ. [9], [10]

Giao thức đo cho lượt chạy toàn tập:

- Chạy detector trên 1687 ảnh đã chọn với một cấu hình cố định.
- Ghép dự đoán và nhãn thật bằng ngưỡng IoU bằng 0.3 để xác định TP, FP, FN.
- Tổng hợp Precision, Recall và F1 trên toàn tập.

Ngưỡng IoU bằng 0.3 được chọn để phù hợp bộ phát hiện cổ điển, vì hộp dự đoán của cascade thường lệch tâm và độ khít so với nhãn thật không cao như detector học sâu hiện đại. Ghép một-một theo chiến lược tham lam được dùng để giữ quy trình đánh giá đơn giản và dễ tái lập; tuy nhiên cách ghép này có thể phụ thuộc thứ tự hộp dự đoán. Nếu cần ổn định hơn ở bước đối sánh, có thể thay bằng ghép tối ưu toàn cục theo Hungarian.

Kết quả tổng hợp toàn tập:

- Tổng số nhãn thật: 37161 khuôn mặt.
- Tổng số dự đoán: 9211 hộp.
- TP bằng 6100, FP bằng 3111, FN bằng 31061.
- Precision bằng 66.23%, Recall bằng 16.42%, F1 bằng 26.31%.

Các chỉ số cho thấy detector vẫn hoạt động khá tốt trên một phần khuôn mặt chính diện rõ, nhưng độ phủ thấp ở bối cảnh không ràng buộc với khuôn mặt nhỏ, góc nghiêng và che khuất. Nguyên nhân quan trọng là Haar cascade trong OpenCV chủ yếu được huấn luyện cho khuôn mặt chính diện và dựa trên tương phản cục bộ, nên kém bền vững khi tư thế thay đổi, khi bị che khuất và khi độ phân giải thấp.

Tái lập trực tiếp trên ví dụ trong sách. Nhóm cắt đúng vùng Fig. 11.14 từ trang sách, tách thành 9 ảnh con theo đúng bố cục lưới của hình, chạy detector trên từng ảnh con rồi ghép kết quả lại để tránh nhiễu do quét xuyên biên giữa các ảnh:

- Nhóm quét lưới siêu tham số theo `scaleFactor`, `minNeighbors`, `minSize`, tổ hợp cascade và ngưỡng lọc kích thước hộp.
- Mỗi cấu hình được chấm theo ba tiêu chí hộp bao: tổng số phát hiện gần mật độ của hình sách, độ phủ đủ 9 ảnh con và không xuất hiện hộp bao quá lớn.
- Cấu hình A gần sách nhất dùng hai cascade `frontal_default` và `frontal_alt2`, chạy độc lập rồi hợp nhất các hộp trước khi gom nhóm, với `scaleFactor=1.05`, `minNeighbors=3`, `minSize=18`, lọc `maxAreaRatio=0.20`.
- Cấu hình B tăng nhẹ độ phủ dùng hai cascade `frontal_default` và `frontal_alt2`, chạy độc lập rồi hợp nhất các hộp trước khi gom nhóm, với `scaleFactor=1.07`, `minNeighbors=1`, `minSize=18`, lọc `maxAreaRatio=0.20`.



Hình I.6: So sánh ví dụ trong sách và kết quả tái lập của nhóm trên cùng ảnh Fig. 11.14. Màu khung trong hai hình tái lập chỉ dùng để phân biệt cấu hình, không biểu diễn TP, FP hay FN.

So sánh trực tiếp từ Hình I.6:

- Ảnh sách thể hiện nhiều khuôn mặt chính diện đã được bắt ổn định bằng hộp trắng.
- Cấu hình A cho 27 hộp, phủ đủ cả 9 ảnh con và có mật độ hộp bao gần nhất với hình sách.
- Cấu hình B cho 21 hộp, giảm bớt các hộp chồng lặp và giữ xu hướng ổn định hơn ở các ảnh nhiều nền.

Tái lập thêm cho Fig. 11.15 đa góc nhìn. Nhóm tiếp tục sweep siêu tham số trên chính Fig. 11.15 với nhiều tổ hợp cascade và chọn cấu hình có mật độ hộp bao gần sách nhất.



(a) Fig. 11.15 trong sách

(b) Tái lập gần đúng của nhóm

Hình I.7: Đối chiếu kết quả đa góc nhìn: sách và tái lập trên cùng ảnh Fig. 11.15.

Ở cấu hình được chọn, detector tạo 20 hộp phát hiện và bao phủ được phần lớn khuôn mặt chính. Tuy nhiên kích thước hộp và mức gom nhóm vẫn khác ảnh sách. Nguyên nhân chính là ảnh sách có thể dùng bộ phát hiện đa góc nhìn chuyên dụng được huấn luyện riêng theo các biến thể boosting và thiết kế cascade khác nhau, không trùng với các cascade dựng sẵn của OpenCV. [1]

Cấu hình siêu tham số dùng cho demo.

- Thư viện: OpenCV 4.13.0 với lớp CascadeClassifier, dùng mô hình Haar Cascade frontalface mặc định của OpenCV. [4], [8]
- Tiền xử lý: chuyển ảnh màu sang ảnh xám trước khi chạy detector.
- Bước 1 mô phỏng phát hiện thô trước gom nhóm: detectMultiScale với scaleFactor bằng 1.05, minNeighbors bằng 0, minSize bằng 20 nhân 20.
- Bước 2 cộng bước 3 cho đầu ra cuối: detectMultiScale với scaleFactor bằng 1.1, minNeighbors bằng 3, minSize bằng 20 nhân 20.
- Thiết lập khác giữ mặc định của OpenCV cho detectMultiScale.
- Đánh giá TP, FP, FN: ghép một-một theo chiến lược tham lam giữa hộp dự đoán và nhãn thật, với ngưỡng IoU bằng 0.3.

Thiết lập này ưu tiên bám sát hành vi detector cổ điển trong điều kiện ảnh thực tế. Ngưỡng IoU bằng 0.3 được giữ nhất quán để tránh phạt quá nặng các hộp dự đoán còn thô, và chiến lược ghép tham lam được chọn vì tính minh bạch khi tái lập. Trong OpenCV, detectMultiScale trả về các hình chữ nhật đã vượt qua cascade; khi minNeighbors bằng 0, đầu ra gần với tập phát hiện thô trước khi siết gom nhóm.

Tái lập mở rộng theo mục 11.6. Để bám sát tinh thần ROC và so sánh cấu hình trong chương sách, nhóm chạy thêm hai sweep trên 3 222 ảnh đọc nhãn thành công của WIDER FACE validation. Mục tiêu của phần này là **tái lập xu hướng** thay vì tái tạo đúng từng con số gốc trong sách. Do khác mô hình huấn luyện,

khác bộ dữ liệu và khác giao thức đánh giá, các so sánh định lượng trong mục này được dùng như minh họa có kiểm soát.


Ngoài sweep chuẩn, nhóm bổ sung một lượt tái lập có ràng buộc theo đúng ba nhánh thuật toán được chú thích trong Fig. 11.16 của sách, gồm nhánh từ [11], [12] và [13]. Do không có mô hình huấn luyện gốc trên MIT-CMU của từng bài, nhóm ánh xạ sang các siêu tham số suy luận tương đương trong OpenCV để giữ đúng tinh thần từng nhánh:

- Nhánh [11]: dùng cascade chính diện, giảm bước quét theo tỉ lệ xuống `scaleFactor=1.05`, `minNeighbors=2`, `minSize=20`.
- Nhánh [12]: dùng ba cascade `frontal_default`, `frontal_alt2` và `profile`, chạy độc lập rồi hợp nhất các hộp trước khi gom nhóm, bật quét ảnh lật ngang, `scaleFactor=1.08`, `minNeighbors=3`, `minSize=20`.
- Nhánh [13]: ưu tiên điểm làm việc thiên về độ phủ. Dùng hai cascade `frontal_default` và `frontal_alt2`, chạy độc lập rồi hợp nhất các hộp trước khi gom nhóm, với `scaleFactor=1.05`, `minNeighbors=1`, `minSize=20`.


Bảng I.1: Kết quả tái lập cấu hình theo ba tài liệu [11], [12], [13] trên tập con 200 ảnh WIDER FACE validation.

Cấu hình neo theo tài liệu	Precision	Recall	F1
[11]	36.38%	13.07%	19.23%
[12]	51.09%	18.38%	27.03%
[13]	26.13%	18.70%	21.80%

Kết quả cho thấy cấu hình neo theo [12] cho F1 cao nhất trong ba cấu hình ánh xạ, còn cấu hình neo theo [13] cho recall nhỉnh hơn nhưng kéo theo số báo động giả cao hơn.



(a) ROC-like theo số báo động giả sau hậu xử lý



(b) Ảnh hưởng kích thước cửa sổ con

Hình I.8: Kết quả tái lập theo định hướng đánh giá của mục 11.6 trong chương sách.

Thiết lập của Hình I.8 cố định `scaleFactor=1.1` và `minSize=20`. Số báo động giả được tính sau gom nhóm, và nhãn TP, FP, FN được xác định bằng ghép một-một theo chiến lược tham lam với ngưỡng IoU bằng 0.3.

Kết quả chính từ Hình I.8:

- Khi giảm `minNeighbors` từ 6 xuống 0, tỉ lệ phát hiện tăng từ 14.94% lên 26.60%, nhưng số báo động giả tăng mạnh từ 1 791 lên 320 969.
- Điểm cân bằng theo F1 trong sweep này nằm quanh `minNeighbors=2` đến `minNeighbors=3`, với F1 xấp xỉ 0.275 và độ phủ vào khoảng 18% đến 20%.

- Với $\text{minNeighbors}=3$, các mức minSize 16, 20, 24 cho kết quả tương đương; khi tăng lên 28 và 32 thì recall giảm từ 18.21% xuống 16.33% và 15.51%.

Những quan sát này nhất quán với kết luận của sách về đánh đổi giữa tỉ lệ phát hiện và báo động giả. Riêng phần so sánh sâu giữa DAB, RAB, GAB và kiểu cây yếu nhiều nút như trong 11.6.2 cần huấn luyện lại nhiều cascade trên bộ dữ liệu chuẩn cùng giao thức gốc và sẽ được nhóm triển khai ở báo cáo cuối kỳ.

Từ kết quả quét toàn tập, một ảnh đại diện thỏa đồng thời ba điều kiện đã được chọn để minh họa rõ hạn chế trong bối cảnh ngoài tự nhiên: có phát hiện đúng, có nhận nhầm và có bỏ sót. Ảnh thuộc WIDER FACE validation với định danh 2--Demonstration/2_Demonstration_Protesters_2_738.jpg. [9], [10]



Hình I.9: Phân tích hạn chế Viola-Jones trên một ảnh khó của WIDER FACE validation.

Quy ước ký hiệu trong Hình I.9:

- Ảnh trái: hộp màu xanh lam biểu diễn các phát hiện thô trước gom nhóm, đây là các hình chữ nhật vượt qua cascade khi $\text{minNeighbors}=0$.
- Ảnh giữa: hộp màu xanh lá biểu diễn các phát hiện còn lại sau cascade và gom nhóm.
- Ảnh phải: xanh lá là phát hiện đúng, đỏ là phát hiện sai, vàng là khuôn mặt thật bị bỏ sót.

Phân tích theo đúng luồng ba bước trên ảnh khó:

- Bước 1 tạo 425 phát hiện thô trước gom nhóm, phản ánh đặc tính bao phủ rộng nhưng chi phí lớn của cơ chế quét đa vị trí và đa tỉ lệ. Con số này là số hình chữ nhật vượt qua cascade, không phải số cửa sổ trượt theo nghĩa vết cạn của sliding window.
- Sau chấm điểm cascade và gom nhóm, đầu ra còn 11 hộp.
- Khi đối chiếu với nhân thật: $TP = 5$, $FP = 6$, $FN = 5$ trên tổng 10 khuôn mặt.

Với ví dụ này, điểm mạnh của phương pháp là phát hiện tốt một số khuôn mặt chính diện có kích thước vừa. Hạn chế thể hiện rõ ở các vùng nền giàu kết cấu gây nhận nhầm và ở các khuôn mặt nhỏ hoặc tư thế khó gây bỏ sót. Quan sát này nhất quán với kết quả tổng hợp toàn tập ở phần phân tích thực nghiệm.

6 Thảo luận phản biện

6.1 Đặc trưng Haar-like và Cấu trúc Cascade (Viola-Jones)

Điểm mạnh

- Tốc độ phát hiện cực nhanh nhờ kỹ thuật Hình ảnh tích phân giúp tính toán các đặc trưng chỉ bằng vài phép tính.
- Cấu trúc Cascade giúp loại bỏ phần lớn các vùng không phải khuôn mặt ngay ở những bước đầu, tiết kiệm đáng kể thời gian tính toán

Điểm yếu

- Độ chính xác không cao, đặc biệt với các khuôn mặt bị che khuất, nghiêng hoặc có kích thước nhỏ.
- Đặc trưng Haar-like chỉ có thể phát hiện các đặc điểm cơ bản của khuôn mặt, không thể phát hiện các chi tiết phức tạp.
- Số lượng đặc trưng quá lớn khiến việc huấn luyện ban đầu tốn rất nhiều thời gian.

Hướng cải thiện:

- Tích hợp đặc trưng HOG - Histogram of Oriented Gradients [14]: Để khắc phục giới hạn của Haar-like, hệ thống Cascade được cải tiến bằng cách kết hợp trực tiếp với đặc trưng HOG. Trong khi Haar-like chịu trách nhiệm bắt các khối sáng tối trên bề mặt, HOG có thể mạnh vượt trội trong việc trích xuất thông tin về hướng của cạnh và mô hình hóa chi tiết hình dáng, cấu trúc đường nét cục bộ của đối tượng. Việc tích hợp này giúp bộ phân loại được bổ trợ lẫn nhau: nó không chỉ nhận diện được mảng sáng tối mà còn nắm bắt được khung xương hình học của đối tượng. Nhờ vậy, mô hình giảm đáng kể tỷ lệ báo động giả trong môi trường nền nhiễu và hoạt động tốt hơn khi phát hiện đối tượng có cấu trúc biến đổi cao như người đi bộ hay khuôn mặt nhiều góc độ.

Khác với Haar-like tính tổng cường độ sáng, HOG tính toán độ lớn gradient G và hướng θ tại mỗi điểm ảnh (x, y) thông qua đạo hàm bậc 1 theo trục x và y :

$$G = \sqrt{G_x^2 + G_y^2}, \quad \theta = \arctan\left(\frac{G_y}{G_x}\right) \quad (\text{I.1})$$

Các giá trị này sau đó được gom nhóm vào các biểu đồ phân bố theo các vùng không gian, giúp mô hình hóa ranh giới đối tượng ổn định hơn trước sự thay đổi của ánh sáng.

6.2 Các đặc trưng cục bộ mở rộng (Extended Haar, MB-LBP, Granular)

Điểm mạnh

- Cung cấp độ chính xác phát hiện cao hơn, xử lý tốt hơn tình trạng khuôn mặt bị xoay ngang hoặc nghiêng.
- MB-LBP tính toán rất hiệu quả bằng ảnh tích phân.

Điểm yếu

- Làm tăng yêu cầu về không gian lưu trữ và bộ nhớ. Một số loại đặc trưng làm tăng thời gian ở giai đoạn Boosting.

Hướng cải thiện:

- Tích hợp Ảnh kênh tích phân [15]: Mở rộng tính toán trên đa kênh như màu LUV, gradient, ... thay vì chỉ cường độ sáng. Phương pháp này giúp tăng năng lực phân biệt đối tượng mà vẫn duy trì tốc độ tính toán hằng số nhờ ảnh tích phân.
- Cơ chế chọn lọc dựa trên tính thừa [16]: Sử dụng chuẩn L_1 trong quá trình huấn luyện để lọc ra các đặc trưng hạt tối ưu, giúp giảm dung lượng bộ nhớ mà không làm giảm độ chính xác.

Thay vì chỉ tối thiểu hóa lỗi phân loại thông thường, quá trình huấn luyện kết hợp thêm hàm phạt chuẩn L_1 đối với vector trọng số $\mathbf{w}$ của các đặc trưng:

$$\min_{\mathbf{w}} (\text{Loss}(\mathbf{w}) + \lambda \|\mathbf{w}\|_1) \quad (\text{I.2})$$

Thuộc tính toán học của chuẩn L_1 sẽ ép phần lớn các trọng số của các đặc trưng không quan trọng về đúng 0, từ đó tự động chọn lọc ra một tập đặc trưng gọn hơn mà vẫn giữ năng lực phân loại.

6.3 AdaBoost

Điểm mạnh

- Rất hiệu quả trong việc xây dựng ranh giới phân loại phi tuyến tính mạnh mẽ.
- Các biến thể ít cực đoan hơn (GentleBoost, LogitBoost) xử lý tốt các tập dữ liệu có chứa nhiễu

Điểm yếu

- Giả định tính đơn điệu có thể bị phá vỡ.
- Dễ bị quá khớp nếu số lượng bộ phân loại quá lớn.
- Thời gian huấn luyện lâu.

Hướng cải thiện:

- Real AdaBoost với bảng tra cứu [17]: Sử dụng giá trị thực và bảng ánh xạ để làm mượt ranh giới phân loại, giúp mô hình hội tụ nhanh hơn và đạt độ chính xác cao hơn AdaBoost nhị phân truyền thống.

Thay vì xuất ra nhãn rời rạc $\{-1, +1\}$, bộ phân loại yếu $h_m(x)$ trong Real AdaBoost dự đoán một nửa giá trị logarit của tỷ số khả năng:

$$h_m(x) = \frac{1}{2} \ln \frac{P(y = 1|x)}{P(y = -1|x)} \quad (\text{I.3})$$

- Cơ chế cắt tỉa trọng số [18]: Loại bỏ các mẫu có trọng số thấp trong quá trình huấn luyện để tập trung vào các mẫu khó, giúp rút ngắn đáng kể thời gian xây dựng bộ phân loại mạnh.

Tại mỗi vòng lặp, thuật toán sắp xếp các trọng số w_i giảm dần và chỉ giữ lại một phần trăm mẫu có tổng khối lượng trọng số lớn nhất: $\sum_{i \in \text{kept}} w_i > \theta$. Các mẫu bị phân loại đúng (trọng số cực nhỏ) sẽ bị loại bỏ khỏi tính toán ở vòng đó.

6.4 FloatBoost và Forward Feature Selection

Điểm mạnh

- FFS huấn luyện nhanh hơn AdaBoost
- FloatBoost khắc phục được nhược điểm tính phi đơn điệu của AdaBoost, giúp giảm tỷ lệ lỗi hoặc giảm thời gian phát hiện nhờ loại bỏ bớt các bộ phân loại dư thừa

Điểm yếu

- FFS có độ chính xác thấp hơn AdaBoost một chút.
- FloatBoost tốn kém chi phí tính toán hơn ở khâu huấn luyện vì phải liên tục kiểm tra và tính toán lại sau mỗi lần loại bỏ.

Hướng cải thiện:

- Tìm kiếm Heuristic trong FloatBoost [12]: Giới hạn độ sâu quay lui bằng các thuật toán heuristic để cân bằng giữa thời gian huấn luyện và chất lượng tập đặc trưng, tránh việc kiểm tra dư thừa quá mức.
- Theo thuật toán FloatBoost chuẩn, việc quay lui xảy ra nếu chi phí $J(H_M - h') < J_{M-1}^{\min}$ [12]. Khi thêm Heuristic, ta áp đặt thêm một điều kiện dừng:

$$\text{Quay lui nếu } J(H_M - h') < J_{M-1}^{\min} \quad \text{và} \quad \text{depth} \leq d_{\max} \quad (\text{I.4})$$

Việc giới hạn độ sâu $d_{\max}$ này chặn đứng các vòng lặp vô tận khi thuật toán cố gắng tối ưu những phần thập phân không đáng kể của hàm lỗi.

6.5 Các phương pháp học bất đối xứng (AsymBoost, LAC)

Điểm mạnh

- Cải thiện đáng kể độ chính xác của cấu trúc Cascade bằng cách thiết lập các mục tiêu học tập cụ thể
- MB-LBP tính toán rất hiệu quả bằng ảnh tích phân.

Điểm yếu

- Đòi hỏi phải tinh chỉnh thủ công hoặc dùng thuật toán phụ trợ để tìm ra các trọng số/tham số bất đối xứng phù hợp

Hướng cải thiện:

- Tự động hóa điều chỉnh chi phí [19]: Tích hợp hàm mục tiêu dựa trên đường cong ROC để thuật toán tự động tìm điểm cân bằng giữa tỷ lệ phát hiện và báo động giả mà không cần can thiệp thủ công.
- Quy tắc cập nhật trọng số bất đối xứng cơ bản có dạng $w_i^{(M)} = C \exp(-y_i H_M(x_i))$ [13]. Thay vì cố định hệ số C ngay từ đầu, phương pháp tự động [19] sẽ tính toán C_t tại mỗi bước t như một hàm phụ thuộc vào sự chênh lệch giữa tỷ lệ báo động giả hiện tại FPR_t và mục tiêu $\text{FPR}_{\text{target}}$ trên đường cong ROC, ép bộ phân loại từ từ hội tụ về đúng điểm hoạt động mong muốn.

6.6 Soft Cascade / Multi-exit Cascade

Điểm mạnh

- Giữ lại và sử dụng thông tin lịch sử của các bộ phân loại trước đó, giúp đạt hiệu suất phát hiện cao hơn và giảm đáng kể thời gian kiểm tra do các mẫu không phải khuôn mặt bị loại bỏ từ sớm.

Điểm yếu

- Đòi hỏi phải có thêm một tập dữ liệu xác thực riêng để sắp xếp tối ưu thứ tự các bộ phân loại yếu và tìm ra ngưỡng loại bỏ chuẩn xác.

Hướng cải thiện:

- Ứng dụng lý thuyết Wald [20]: Sử dụng Kiểm định tỷ số xác suất tuần tự để tối ưu hóa ngưỡng dừng tại mỗi bước, đảm bảo thời gian đưa ra quyết định là ngắn nhất về mặt toán học.
- Đối với một cửa sổ x , mô hình duy trì một tỷ số khả năng tích lũy $R_m(x)$:

$$R_m(x) = \frac{P(x|\text{khuôn mặt})}{P(x|\text{không phải mặt})} \quad (\text{I.5})$$

Ở mỗi bước m , nếu $R_m(x) \leq A$ (ngưỡng từ chối), loại bỏ mẫu; nếu $R_m(x) \geq B$ (ngưỡng chấp nhận), kết luận là khuôn mặt; nếu nằm giữa, tiếp tục đánh giá. Các ngưỡng A và B được tính toán tối ưu dựa trên xác suất sai lầm loại I và loại II cho phép.

6.7 Detector-Pyramid / View-based Framework

Điểm mạnh

- Cải thiện rõ rệt bài toán phát hiện khuôn mặt đa góc nhìn mà không cần mô hình hóa cấu trúc 3D phức tạp.

Điểm yếu

- Hệ thống phức tạp.
- Phải huấn luyện riêng biệt nhiều mô hình con và cần các cơ chế để phân xử/gộp kết quả khi có nhiều mô hình cùng báo phát hiện một khuôn mặt ở các góc độ khác nhau.


Hướng cải thiện:

- Cơ chế chia sẻ đặc trưng [21]: Sử dụng cấu trúc cây để dùng chung các đặc trưng ở những tầng đầu, chỉ phân tách ở những tầng sâu xử lý góc nhìn chuyên biệt. Điều này giúp giảm dung lượng mô hình và tăng tốc độ tổng thể.

Hệ thống được thiết kế dưới dạng cây phân nhánh từ thô đến tinh [21].

- **Nút gốc:** Đánh giá các đặc trưng Haar-like chung nhất có ở mọi góc độ khuôn mặt.
- **Các nhánh:** Càng xuống tầng sâu, cây càng rẽ nhánh thành các bộ phân loại chuyên biệt.

Cấu trúc này giúp giảm dung lượng mô hình và tăng tốc độ tổng thể so với việc chạy độc lập nhiều bộ dò tìm.



Hình I.10: Minh họa cấu trúc phân nhánh hình cây từ thô đến tinh để xử lý khuôn mặt đa góc nhìn.

7 Kết luận

Chương sách đóng góp nền tảng về logic phát hiện và tư duy tối ưu. Mô hình cơ sở này là then chốt để lý giải vì sao các phương pháp hiện đại như SCRFD là một bước tiến trong cách hiện thực, chứ không thay thế mục tiêu theo giai đoạn của bộ phát hiện.

Chương II

PHÂN TÍCH BÀI BÁO: SCRFD, ICLR 2022

1 Giới thiệu và động lực

Phát hiện khuôn mặt là một bài toán nền tảng trong thị giác máy tính, với nhiều ứng dụng quan trọng như căn chỉnh khuôn mặt, tái tạo khuôn mặt 3D, phân tích thuộc tính và nhận dạng khuôn mặt. Trong điều kiện tự nhiên, đây vẫn là bài toán khó, đặc biệt khi phần lớn khuôn mặt trong dữ liệu thực tế có kích thước rất nhỏ.

Thống kê phân bố kích thước trên WIDER FACE cho thấy phần lớn khuôn mặt trong tập khó nhỏ hơn 32×32 điểm ảnh; vì vậy, năng lực xử lý khuôn mặt rất nhỏ trở thành nhân tố quyết định hiệu năng tổng thể của bộ phát hiện. [9], [22]

Nhiều bộ phát hiện hiện đại kế thừa mạng trực chính từ bài toán phân loại ảnh, nơi tài nguyên tính toán thường tập trung vào các tầng sâu để học đặc trưng ngữ nghĩa mạnh. Tuy nhiên, với khuôn mặt nhỏ, thông tin quan trọng lại xuất hiện nhiều ở các tầng nông có độ phân giải cao hơn. Do đó, cách phân bố tính toán vốn hiệu quả cho phân loại ảnh chưa chắc tối ưu khi chuyển sang phát hiện khuôn mặt. [22]

Thay vì gia tăng độ phức tạp kiến trúc bằng nhiều nhánh bổ sung, bài báo xuất phát từ giả thuyết nghiên cứu sau: *Nếu tổng số phép tính được giữ cố định, liệu việc tái cấu trúc phân bố tính toán giữa các tầng có cải thiện đáng kể hiệu quả phát hiện hay không?*

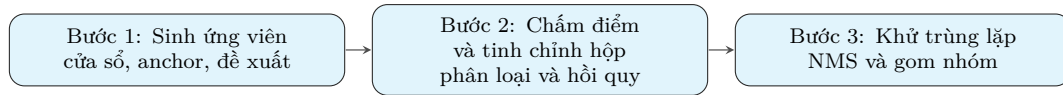
Từ động lực đó, SCRFD đề xuất hai hướng tối ưu. Thứ nhất, tái cân bằng tài nguyên tính toán trong bộ phát hiện để phù hợp hơn với phân bố kích thước khuôn mặt. Thứ hai, điều chỉnh phân bố mẫu huấn luyện theo thang đo để tăng mật độ mẫu tại các miền kích thước quan trọng. Kết quả cho thấy có thể cải thiện hiệu quả rõ rệt mà không cần tăng tổng ngân sách tính toán. [22]

2 Các công trình liên quan và kiến thức nền

Về kiến thức nền, SCRFD kế thừa khung phát hiện ba giai đoạn đã được hình thành từ các hệ cổ điển và được tinh chỉnh dần trong các kiến trúc học sâu một giai đoạn lẫn hai giai đoạn. Về công trình liên quan, chuỗi phát triển từ Viola–Jones đến RetinaNet và các mô hình chuyên biệt khuôn mặt cho thấy xu hướng chuyển dịch rõ ràng từ thiết kế thủ công sang tối ưu hóa phân bố tài nguyên tính toán và phân bố mẫu dữ liệu theo đặc thù bài toán.

2.1 Luồng bộ phát hiện 3 bước


Diễn giải theo luồng phát hiện cơ sở. Ở cách tiếp cận ngây thơ nhất, giai đoạn sinh ứng viên được thực hiện bằng cách duyệt toàn bộ cửa sổ trên ảnh ở mọi vị trí và mọi kích thước. Trong thực tế, thao tác này thường được cài đặt bằng quét cửa sổ trượt trên tháp tỉ lệ, nên số lượng ứng viên tăng rất nhanh theo độ phân giải ảnh



Hình II.1: Quy trình phát hiện chuẩn dùng chung cho bộ phát hiện cổ điển và hiện đại.

và số mức tỉ lệ. Ở giai đoạn chấm điểm, từng cửa sổ được đánh giá độc lập để quyết định có phải khuôn mặt hay không và có thể kèm hiệu chỉnh hộp bao. Ở giai đoạn hợp nhất, các dự đoán chồng lấp cao được gộp lại bằng cơ chế như NMS để tránh lặp phát hiện. Khung ngậy thơ này giúp nhìn rõ bản chất bài toán, đồng thời chỉ ra nút thắt tính toán khiến các phương pháp hiện đại phải tối ưu mạnh ở cả ba giai đoạn.

2.2 Sơ đồ tiến hóa đến SCRFD



Hình II.2: Lộ trình tiến hóa từ phát hiện khuôn mặt thủ công đến SCRFD, nhánh một giai đoạn.

2.3 Phân tích chi tiết các cột mốc trên đường tiến hóa đến SCRFD

Nguyên tắc đọc chung. Mỗi cột mốc kiến trúc trong Hình II.2 đều có thể quy chiếu về cùng một khung phát hiện ba giai đoạn: sinh ứng viên, chấm điểm kèm định vị lại hộp, và hợp nhất dự đoán. Sự khác biệt giữa các thể hệ chủ yếu nằm ở cách hiện thực và trọng tâm tối ưu hóa tại từng giai đoạn. Trong phần này, tuyến phân tích chính được giữ theo chuỗi *Viola-Jones* → *CNN detectors* → *RetinaNet* → *SCRFD*; các nhánh còn lại chỉ tóm tắt để định vị bối cảnh.

Viola-Jones. Ở giai đoạn sinh ứng viên, hệ thống quét cửa sổ trượt trên nhiều tỉ lệ ảnh để bao phủ không gian vị trí và kích thước khuôn mặt. Giai đoạn chấm điểm sử dụng đặc trưng Haar-like tính nhanh bằng ảnh tích phân, kết hợp AdaBoost để chọn đặc trưng phân biệt và tổ chức thành cascade nhiều tầng nhằm loại sớm mẫu âm. Giai đoạn cuối hợp nhất các cửa sổ chồng lấp thành phát hiện duy nhất. Đóng góp bản chất của cột mốc này là đặt nền cho một quy trình phát hiện có tính hệ thống, trong đó tốc độ được tối ưu ngay từ cơ chế ra quyết định. [1], [2], [3]

Kỹ nguyên học sâu. Trong giai đoạn chuyển tiếp sang học sâu, cơ chế sinh ứng viên dần rời khỏi các quy tắc thủ công và gắn với bản đồ đặc trưng học được. Khâu chấm điểm và hồi quy hộp hưởng lợi trực tiếp từ biểu diễn sâu, nhờ đó độ tách biệt giữa mặt và nền trong bối cảnh che khuất, thay đổi tư thế và điều kiện chiếu sáng phức tạp được cải thiện đáng kể. NMS tiếp tục đảm nhiệm khâu hợp nhất dự đoán, nhưng chất lượng đầu vào đã cao hơn rõ rệt. Điểm thay đổi cốt lõi của giai đoạn này là chuyển trọng tâm từ thiết kế đặc trưng bằng tay sang học biểu diễn từ dữ liệu.

Nhánh hai giai đoạn. Nhánh này gồm R-CNN, Fast R-CNN và Faster R-CNN. Trong R-CNN, sinh ứng viên dựa trên selective search với số lượng vùng đề xuất lớn; các vùng này được đưa qua CNN theo từng vùng, sau đó

phân loại bằng SVM và hồi quy hộp, trước khi hợp nhất bằng NMS. [23] Fast R-CNN giữ cơ chế đề xuất vùng bên ngoài nhưng tái cấu trúc khâu chấm điểm bằng cách chia sẻ đặc trưng tích chập toàn ảnh, chỉ trích xuất ROI tại bước sau, đồng thời học chung phân loại và hồi quy để giảm mạnh tính toán lặp. [24] Faster R-CNN tiếp tục hợp nhất quy trình bằng cách thay selective search bằng RPN dựa trên anchor và chia sẻ đặc trưng với nhánh nhận dạng; NMS vẫn giữ vai trò then chốt ở cả mức đề xuất và mức dự đoán cuối. [5] Nhìn tổng thể, nhánh hai giai đoạn ưu tiên chất lượng ứng viên và độ chính xác, đánh đổi bằng độ trễ suy luận cao hơn.

Nhánh một giai đoạn sớm. Nhánh này tiêu biểu bởi SSD và YOLO. SSD sinh ứng viên bằng default boxes đa tỉ lệ trên nhiều mức đặc trưng và dự đoán trực tiếp nhãn cùng sai lệch hộp cho từng default box trong một lượt suy luận, trước khi áp dụng NMS. [25] YOLO mô hình hóa không gian ảnh theo lưới đều, dự đoán đồng thời hộp giới hạn, điểm tin cậy và xác suất lớp tại từng ô, rồi khử trùng lặp bằng ngưỡng và NMS. [26] Đóng góp quan trọng của nhánh này là hợp nhất khâu sinh ứng viên và khâu chấm điểm vào một quy trình tích hợp theo hướng thời gian thực.

RetinaNet. RetinaNet duy trì cơ chế phát hiện dày đặc bằng anchor trên tháp đặc trưng đa mức. Khâu chấm điểm và hồi quy được tách thành hai nhánh song song; cải tiến quan trọng là focal loss nhằm giảm ảnh hưởng của mẫu âm dễ và dồn trọng số học vào mẫu khó. Khâu hậu xử lý vẫn sử dụng NMS để hợp nhất kết quả. So với SSD và YOLO, RetinaNet xử lý hiệu quả hơn bài toán mất cân bằng lớp trong phát hiện dày đặc, nhờ đó chất lượng phân loại được cải thiện rõ rệt. [6]

SCRFD. SCRFD kế thừa nền tảng phát hiện dày đặc một giai đoạn với anchor đa mức, nhưng không chấp nhận nguyên trạng tỉ lệ thiết kế của mô hình gốc. Ở tầng phương pháp, bài báo đồng thời tối ưu kiến trúc và dữ liệu huấn luyện qua hai cơ chế: Computation Redistribution tái cân bằng tài nguyên tính toán giữa mạng trực chính, cổ đặc trưng, đầu dự đoán và từng tầng trong mạng trực chính; Sample Redistribution điều chỉnh phân bố mẫu theo thang đo để tăng cường tín hiệu học tại các miền kích thước quan trọng của khuôn mặt nhỏ. NMS vẫn được giữ ở khâu hợp nhất dự đoán; tuy nhiên, chất lượng hộp và điểm tin cậy được nâng lên nhờ hai tối ưu nói trên. So với RetinaFace và nhiều mốc trước đó, SCRFD cải thiện rõ hiệu năng trên tập khó trong khi vẫn duy trì hiệu quả tính toán trong cùng ngân sách. [22], [27]


3 Phương pháp bài báo đề xuất

3.1 Tổng quan hệ thống SCRFD

SCRFD là viết tắt của Sample and Computation Redistribution for Efficient Face Detection. Đây là một bộ phát hiện khuôn mặt một giai đoạn theo kiểu dự đoán dày đặc, được xây dựng trên khung kiến trúc phổ biến gồm ba khối: *Backbone* – *Neck* – *Head*. Khác với các hướng tiếp cận bổ sung mô-đun phức tạp, SCRFD tập trung vào tái thiết kế ở mức hệ thống nhằm tối ưu đồng thời độ chính xác và chi phí tính toán. Kiến trúc nền của SCRFD chịu ảnh hưởng từ RetinaNet và sử dụng Focal Loss để xử lý mất cân bằng lớp trong phát hiện dày đặc. [6], [22]

A. Cấu trúc tổng thể Backbone – Neck – Head. SCRFD được tổ chức thành ba khối chức năng chính, minh họa ở Hình II.3:

- **Backbone:** trích xuất đặc trưng từ ảnh đầu vào và tạo ra các bản đồ đặc trưng nhiều mức $C_2 \rightarrow C_5$. Các tầng nông có độ phân giải cao giữ thông tin chi tiết quan trọng cho khuôn mặt nhỏ, trong khi các tầng sâu mang thông tin ngữ nghĩa mạnh hơn nhưng độ phân giải thấp hơn.
- **Neck dùng PAFPN:** hợp nhất đặc trưng đa mức theo cả hai hướng trên-xuống và dưới-lên nhằm tăng cường lan truyền thông tin không gian và ngữ nghĩa. Từ các mức đặc trưng của backbone, Neck tạo ra các mức đặc trưng đầu ra dùng cho dự đoán dày đặc.
- **Head:** thực hiện dự đoán phân loại khuôn mặt và nền, đồng thời hồi quy hộp bao trên từng mức đặc trưng. Các dự đoán từ nhiều mức được hợp nhất và đưa qua hậu xử lý để tạo đầu ra cuối cùng.



Hình II.3: Minh họa kiến trúc nền SCRFD theo ba khối: Backbone, Neck và Head.

B. Động cơ thiết kế trong bối cảnh phát hiện khuôn mặt nhỏ. Bài báo tập trung vào kịch bản phát hiện khuôn mặt trong thực tế, đặc biệt nhấn mạnh miền khuôn mặt rất nhỏ, thường dưới 32×32 điểm ảnh, và yêu cầu giữ hiệu năng cao dưới ngân sách suy luận chặt, chẳng hạn thiết lập VGA 640×480 . [22]

Khi áp dụng trực tiếp một detector tổng quát cho bài toán này, hai vấn đề kỹ thuật thường xuất hiện:

- *Phân bố tính toán chưa phù hợp:* các backbone xuất phát từ phân loại ảnh thường dồn nhiều tài nguyên ở tầng sâu, trong khi tín hiệu khuôn mặt nhỏ lại phụ thuộc mạnh vào các mức đặc trưng nông có độ phân giải cao.
- *Phân bố mẫu theo thang đo chưa tối ưu:* trong huấn luyện dày đặc, số mẫu dương hữu ích ở các mức đặc trưng phù hợp với khuôn mặt rất nhỏ có thể không đủ, làm giảm độ phủ trên tập khó.

C. Hai trụ cột tối ưu của SCRFD. Để giải quyết hai vấn đề trên, SCRFD đề xuất hai cơ chế phối hợp:

- **Computation Redistribution CR:** tái phân bổ năng lực tính toán giữa backbone, neck và head, cũng như giữa các tầng trong backbone, nhằm đưa nhiều tài nguyên hơn tới các mức đặc trưng có ích cho khuôn mặt nhỏ trong khi vẫn giữ tổng FLOPs trong ngân sách mục tiêu.
- **Sample Redistribution SR:** điều chỉnh phân bố mẫu huấn luyện theo thang đo thông qua chiến lược thu phóng có tìm kiếm, nhằm tăng mật độ mẫu dương tại các mức đặc trưng nhỏ và cải thiện độ phủ cho khuôn mặt rất nhỏ.

Hai cơ chế này phối hợp để tối ưu đánh đổi giữa độ chính xác và hiệu năng, tạo nên các biến thể SCRFD ở nhiều mức ngân sách tính toán khác nhau. Các mục tiếp theo sẽ trình bày chi tiết từng khối kiến trúc gồm Backbone, Neck, Head, trước khi phân tích sâu hai cơ chế CR và SR.

3.2 Backbone: Trích xuất đặc trưng đa mức

Backbone trong SCRFD đóng vai trò trích xuất đặc trưng nền từ ảnh đầu vào và tạo ra các bản đồ đặc trưng nhiều mức với độ phân giải và độ trù tượng khác nhau. Thiết kế backbone tuân theo cấu trúc CNN tiêu chuẩn, trong đó ảnh đầu vào được xử lý qua các khối tích chập tuần tự để tạo ra các mức đặc trưng $C_2 \rightarrow C_5$.

A. Cấu trúc phân tầng đặc trưng $C_2 \rightarrow C_5$.

Giả sử ảnh đầu vào có kích thước $H \times W$, backbone tạo ra các mức đặc trưng với stride so với ảnh gốc tăng dần theo chiều sâu mạng:

- C_2 : stride = 4, độ phân giải $\frac{H}{4} \times \frac{W}{4}$.
- C_3 : stride = 8, độ phân giải $\frac{H}{8} \times \frac{W}{8}$.

- C_4 : stride = 16, độ phân giải $\frac{H}{16} \times \frac{W}{16}$.
- C_5 : stride = 32, độ phân giải $\frac{H}{32} \times \frac{W}{32}$.

Khi stride tăng, receptive field của mỗi điểm trên bản đồ đặc trưng cũng tăng lên. Các mức sâu như C_4 và C_5 có ngữ nghĩa mạnh hơn do tích lũy thông tin qua nhiều lớp, nhưng đánh đổi bằng việc giảm mạnh độ phân giải không gian.

B. Ý nghĩa của độ phân giải đối với khuôn mặt nhỏ.

Trong bối cảnh phát hiện khuôn mặt rất nhỏ, chẳng hạn dưới 32×32 điểm ảnh, các mức đặc trưng nông như C_2 và C_3 trở nên đặc biệt quan trọng. Với thiết lập VGA 640×480 , một khuôn mặt 16×16 điểm ảnh khi chiếu lên:

- C_2 với stride 4 vẫn còn kích thước khoảng 4×4 ô lưới.
- C_3 với stride 8 còn khoảng 2×2 ô.
- C_4 với stride 16 chỉ còn 1×1 hoặc thậm chí mất hoàn toàn thông tin chi tiết.

Điều này cho thấy nếu phụ thuộc quá nhiều vào các mức sâu như C_4 hoặc C_5 , mô hình có nguy cơ đánh mất tín hiệu không gian quan trọng của khuôn mặt nhỏ. Do đó, backbone cần bảo toàn đủ năng lực biểu diễn ở các mức nông để duy trì độ nhạy với khuôn mặt siêu nhỏ.

C. Đặc điểm backbone trong SCRFD.

SCRFD kế thừa backbone từ các kiến trúc CNN hiện đại, chẳng hạn họ ResNet, nhưng được thiết kế để phù hợp với mục tiêu phát hiện hiệu quả. Khác với thiết kế phân loại ảnh thuần túy vốn ưu tiên tăng sâu để tăng khả năng phân biệt ngữ nghĩa, SCRFD sử dụng backbone như một nguồn đặc trưng đa mức cho bài toán định vị dày đặc.

Điểm quan trọng là backbone không hoạt động độc lập mà đóng vai trò cung cấp đặc trưng đầu vào cho Neck dùng PAFPN¹. Vì vậy, cách phân bổ độ sâu, độ rộng và số kênh ở từng mức đặc trưng sẽ ảnh hưởng trực tiếp đến chất lượng hợp nhất đa tỉ lệ ở giai đoạn sau.

Backbone trong SCRFD tạo ra hệ đặc trưng phân tầng từ C_2 đến C_5 , trong đó các mức nông giữ vai trò đặc biệt quan trọng đối với khuôn mặt nhỏ.

3.3 Neck: Hợp nhất đặc trưng đa tỉ lệ bằng PAFPN

Sau khi backbone tạo ra các mức đặc trưng phân tầng $C_2 \rightarrow C_5$, khối Neck có nhiệm vụ hợp nhất thông tin giữa các mức này để tạo ra các bản đồ đặc trưng đa tỉ lệ vừa giàu ngữ nghĩa vừa đủ chi tiết không gian, phục vụ trực tiếp cho dự đoán dày đặc ở Head. SCRFD sử dụng **PAFPN**, viết đầy đủ Path Aggregation Feature Pyramid Network, như một biến thể tăng cường của FPN truyền thống nhằm cải thiện truyền thông tin theo cả hai hướng trên-xuống và dưới-lên. [22]

A. Nhắc lại FPN: Top-down + Lateral connection. FPN, viết đầy đủ Feature Pyramid Network, xây dựng các mức đặc trưng đầu ra P_3, P_4, P_5 từ các mức đặc trưng từ backbone C_3, C_4, C_5 bằng hai cơ chế chính:

- **Lateral connection:** dùng phép chiếu 1×1 để đưa các đặc trưng từ backbone về cùng số kênh:

$$\tilde{C}_i = \phi_{1 \times 1}[C_i]$$

- **Top-down pathway:** truyền ngữ nghĩa từ tầng sâu lên tầng nông bằng upsample và cộng phần tử:

$$P_i = \tilde{C}_i + \text{Up}[P_{i+1}]$$

¹scrfd_2.5g.py

Trong đó $\text{Up}[\cdot]$ thường là phép tăng kích thước theo tỉ lệ 2, có thể dùng nearest hoặc bilinear, để khớp kích thước không gian. Phép **cộng theo từng phần tử** thay vì nối kênh giúp giữ số kênh ổn định, tránh tăng FLOPs và đồng thời ép mô hình học cách kết hợp ngữ nghĩa và chi tiết trong cùng không gian đặc trưng.

B. Hạn chế của FPN thuần trong thiết lập phát hiện dày đặc. FPN giúp tăng ngữ nghĩa cho các mức nông, chẳng hạn mức P_3 , bằng cách truyền thông tin từ mức sâu. Tuy nhiên, khi chỉ có đường truyền trên-xuống, thông tin chi tiết từ mức nông và trung gian có thể không được quay trở lại để tăng cường cho các mức sâu hơn theo hướng dưới lên. Trong các bài toán định vị dày đặc, đặc biệt với đối tượng nhỏ, việc lan truyền thông tin theo cả hai hướng thường giúp:

- tăng chất lượng định vị ở các mức có độ phân giải khác nhau,
- giảm chênh lệch biểu diễn giữa các mức đặc trưng,
- cải thiện độ ổn định của head khi dự đoán trên toàn tháp đặc trưng.

C. PAFPN: Bổ sung đường truyền dưới lên theo Path Aggregation. PAFPN mở rộng FPN bằng cách thêm một đường truyền **dưới-lên** để tăng cường khả năng tổng hợp đặc trưng. Về trực giác:

- FPN nhấn mạnh luồng ngữ nghĩa từ sâu sang nông, giúp P_3 giàu ngữ nghĩa hơn.
- PAFPN bổ sung luồng chi tiết từ nông sang sâu, giúp các mức cao hơn nhận lại tín hiệu định vị tốt hơn.

Một cách mô tả phổ biến của PAFPN trong các detector hiện đại là:

1. Tạo tháp top-down P_3, P_4, P_5 như FPN.
2. Tạo tháp bottom-up N_3, N_4, N_5 bằng cách downsample và hợp nhất dần:

$$N_3 = P_3, \quad N_{i+1} = \psi[\text{Down}[N_i], P_{i+1}]$$

Trong đó:

- $\text{Down}[\cdot]$ là phép giảm kích thước, thường dùng tích chập stride 2 để tăng receptive field,
- $\psi[\cdot]$ là phép hợp nhất, thường dùng phép cộng hoặc phép cộng sau khi qua tích chập để trộn thông tin.

Nhờ nhánh dưới-lên, PAFPN tạo ra các mức đặc trưng cuối cùng có chất lượng hợp nhất tốt hơn so với FPN thuần, đặc biệt trong bối cảnh dự đoán dày đặc trên nhiều mức.

D. Liên hệ trực tiếp với bài toán phát hiện khuôn mặt nhỏ. Trong face detection, đặc biệt trên WIDER FACE hard, khó khăn đến từ việc khuôn mặt có thể:

- rất nhỏ, thường được gọi là tiny faces,
- bị che khuất,
- lệch góc,
- nền phức tạp gây nhiễu.

Các trường hợp này đòi hỏi đặc trưng sử dụng cho head phải đồng thời:

- giữ chi tiết không gian để định vị chính xác đối tượng nhỏ,
- đủ ngữ nghĩa để phân biệt khuôn mặt với nền.

PAFPN hỗ trợ mục tiêu này bằng cách tăng cường lan truyền thông tin hai chiều:

- đường top-down giúp các mức nông, chẳng hạn P_3 và N_3 , nhận thêm ngữ nghĩa cho phân loại,
- đường bottom-up giúp các mức sâu hơn nhận lại tín hiệu định vị và chi tiết tổng hợp, hạn chế gián đoạn thông tin giữa các mức.

E. Tóm tắt vai trò của Neck trong SCRFD. Neck của SCRFD sử dụng PAFPN để tạo ra các mức đặc trưng hợp nhất đa tỉ lệ từ $C_2 \rightarrow C_5$. Các mức đầu ra, thường ở stride 8, 16, 32 tương ứng với các mức dự đoán, được thiết kế để cung cấp đầu vào ổn định cho head phân loại và hồi quy. Nhờ cơ chế hợp nhất hai chiều, PAFPN giúp mô hình khai thác tốt hơn tín hiệu khuôn mặt nhỏ mà không cần tăng đáng kể độ phức tạp kiến trúc.

Trên nền đặc trưng này, khối Head thực hiện dự đoán phân loại và hồi quy hộp bao trên từng mức đặc trưng của tháp PAFPN.

3.4 Head: Dự đoán dày đặc phân loại và hồi quy

Sau khi Backbone và Neck dùng PAFPN tạo ra các mức đặc trưng đa tỉ lệ, khối Head chịu trách nhiệm thực hiện dự đoán dày đặc trên từng mức đặc trưng, thường gọi là dense prediction. SCRFD theo thiết kế one-stage anchor-based detector: tại mỗi vị trí trên bản đồ đặc trưng, mô hình dự đoán trực tiếp xác suất khuôn mặt và tham số hộp bao tương ứng.

A. Dự đoán theo từng mức đặc trưng.

Giả sử sau PAFPN ta thu được các mức đặc trưng đầu ra, chẳng hạn stride 8, 16, 32. Với mỗi mức F_i có kích thước $\frac{H}{s_i} \times \frac{W}{s_i} \times C$, Head áp dụng cùng một cấu trúc tích chập để sinh dự đoán tại mọi vị trí lưới.

Tại mỗi vị trí không gian $\mathbf{p} = [x, y]$ và mỗi anchor được gán cho mức đó, Head xuất ra:

- **Điểm phân loại p :** xác suất thuộc lớp *face*.
- **Tham số hồi quy $t = [t_x, t_y, t_w, t_h]$:** độ lệch so với anchor chuẩn.

Thiết kế này cho phép dự đoán song song hàng nghìn ứng viên trong một lần forward pass, thay vì sinh proposal riêng biệt như các detector hai giai đoạn.

B. Kiến trúc con của Head.

Head trong SCRFD gồm hai nhánh song song:

- **Classification branch:** một chuỗi lớp tích chập 3×3 dùng để trích xuất đặc trưng phân biệt face/background, sau đó qua lớp tích chập cuối để xuất xác suất.
- **Regression branch:** chuỗi lớp tích chập tương tự, nhưng đầu ra là bốn tham số hồi quy hộp bao.

Các nhánh này có thể chia sẻ cấu trúc tương tự nhau nhưng không chia sẻ trọng số, nhằm tránh xung đột giữa mục tiêu phân loại và định vị. Thiết kế head dạng nhiều lớp tích chập nhỏ thay vì một lớp tuyến tính duy nhất giúp tăng năng lực biểu diễn mà vẫn giữ tính cục bộ và chi phí tính toán thấp.

C. Cơ chế anchor-based.

SCRFD sử dụng cơ chế anchor theo từng mức đặc trưng. Tại mỗi vị trí trên mức stride s , một tập anchor với kích thước được định nghĩa trước sẽ được gán. Ví dụ trong cấu hình tiêu biểu:

$$\{16, 32\} \text{ trên stride } 8, \quad \{64, 128\} \text{ trên stride } 16, \quad \{256, 512\} \text{ trên stride } 32.$$

Mỗi anchor đại diện cho một giả thuyết hộp bao ban đầu. Có thể xem anchor như các khung tham chiếu đặt sẵn trên ảnh để mô hình học cách dịch chuyển và co giãn thành hộp bao bám sát khuôn mặt thật. Head học cách hiệu chỉnh anchor này thông qua tham số hồi quy:

$$t_x = \frac{x - x_a}{w_a}, \quad t_y = \frac{y - y_a}{h_a}, \quad t_w = \log \frac{w}{w_a}, \quad t_h = \log \frac{h}{h_a},$$

trong đó $a = [x_a, y_a, w_a, h_a]$ là anchor và $b = [x, y, w, h]$ là hộp thật.

Cách mã hóa này giúp việc học ổn định hơn do chuẩn hóa theo kích thước anchor.

D. Hàm mất mát trong Head.

Huấn luyện head bao gồm hai thành phần mất mát chính:

- **Classification loss:** thường sử dụng Focal Loss nhằm xử lý mất cân bằng mạnh giữa số anchor âm và dương trong phát hiện dày đặc. Focal Loss giảm trọng số của các mẫu âm dễ, giúp mô hình tập trung vào các mẫu khó hơn. [6]
- **Regression loss:** thường dùng Smooth L1 hoặc biến thể tương đương để tối ưu sai lệch vị trí hộp bao.

Tổng loss có dạng:

$$\mathcal{L} = \mathcal{L}_{cls} + \lambda \mathcal{L}_{reg},$$

trong đó λ điều chỉnh tầm quan trọng tương đối giữa phân loại và hồi quy.

E. Hậu xử lý.

Trong giai đoạn suy luận, các dự đoán có điểm phân loại thấp sẽ bị loại bỏ trước. Các hộp còn lại được đưa qua loại bỏ không cực đại NMS để loại các hộp chồng lấp mạnh, giữ lại hộp có độ tin cậy cao nhất cho mỗi đối tượng.

F. Vai trò của Head trong toàn hệ thống.

Head là khối chuyển đổi đặc trưng đa mức thành quyết định phát hiện cuối cùng. Chất lượng đặc trưng từ Backbone và Neck ảnh hưởng trực tiếp đến khả năng phân biệt và định vị của Head. Do đó, mọi thay đổi trong phân bố tính toán CR hoặc phân bố mẫu SR sẽ gián tiếp tác động đến hiệu quả của khối này.

3.5 Computation Redistribution CR

Sau khi đã mô tả kiến trúc nền Backbone–Neck–Head, phần này trình bày cơ chế *Computation Redistribution CR*, đóng góp cốt lõi của SCRFD nhằm tối ưu phân bố tài nguyên tính toán dưới ràng buộc FLOPs cố định. [22]

A. Động cơ: Phân bố FLOPs mặc định chưa phù hợp cho khuôn mặt nhỏ.

Các backbone phổ biến, chẳng hạn họ ResNet, được thiết kế cho phân loại ảnh, nơi tầng sâu đóng vai trò quyết định khả năng phân biệt ngữ nghĩa. Do đó, phần lớn phép tính thường tập trung ở các tầng sâu C_4 và C_5 , trong khi các tầng nông C_2 và C_3 có độ phân giải cao lại nhẹ hơn.

Tuy nhiên, trong phát hiện khuôn mặt rất nhỏ:

- Tín hiệu định vị phụ thuộc mạnh vào các mức có stride nhỏ như 8 hoặc 16.
- Việc giảm độ phân giải sớm có thể làm mất thông tin không gian quan trọng.

Vì vậy, phân bố tính toán mặc định từ mạng phân loại ảnh có thể không tối ưu cho bài toán face detection, đặc biệt ở miền tiny faces.

B. Không gian tìm kiếm rút gọn.

Thay vì thiết kế thủ công lại toàn bộ kiến trúc, SCRFD xây dựng một *search space rút gọn* cho phép điều chỉnh:

- **Depth:** số block tại mỗi tầng backbone từ C_2 đến C_5 .
- **Width:** số kênh đặc trưng tại từng mức.
- **Channel của Neck và Head:** nhằm cân bằng tổng FLOPs.

Không gian này được giới hạn bởi ràng buộc FLOPs mục tiêu, đảm bảo mọi cấu hình sinh ra đều khả thi cho triển khai thực tế.

Lấy cảm hứng từ phương pháp RegNet [22], nhóm tác giả SCRFD tiến hành xây dựng và khám phá cấu trúc của các bộ phát hiện khuôn mặt dựa trên giả định sử dụng các khối mạng tiêu chuẩn cố định [22].

Mặc dù cấu trúc tổng thể của một mạng phát hiện khá đơn giản, nhưng nếu để hệ thống tự do kết hợp, số lượng cấu hình mạng có thể tạo ra sẽ rất lớn [22]. Do đó, mục tiêu cốt lõi của phần này là tinh giản không gian tìm kiếm đó xuống thành một không gian thiết kế ít chiều thông qua việc kiểm soát chặt chẽ các bậc tự do.


Tinh giản không gian xương sống

- *Cấu trúc cơ sở*: Backbone bao gồm phần Stem và phần Body gồm 4 giai đoạn C_2, C_3, C_4, C_5 hoạt động ở các độ phân giải giảm dần [22]. Tại mỗi giai đoạn i , cấu trúc có 2 bậc tự do chính là số lượng khối d_i và độ rộng khối w_i [22].
- *Gộp bậc tự do*: Vì số lượng kênh của phần Stem luôn bằng với độ rộng của khối Residual đầu tiên trong giai đoạn C_2 , nên bậc tự do của Stem (w_1) được gộp thẳng vào tham số w_2 [22]. Do đó, toàn bộ phần Backbone chỉ còn lại đúng 8 bậc tự do (4 giai đoạn $\times$ 2 tham số d_i, w_i).
- *Ràng buộc lấy mẫu*: Hệ thống tiến hành lấy mẫu ngẫu nhiên phân bố đều với các ngưỡng chặn: $d_i \leq 24$ và $w_i \leq 512$ [22]. Đồng thời, dựa trên nguyên tắc thiết kế các mạng hiện đại, không gian tìm kiếm bị ép tuân thủ quy luật mở rộng dần chiều rộng: $w_{i+1} \geq w_i$ [22].

Tinh giản không gian Neck và Head

- *Cấu trúc cơ sở*: Phần Neck sử dụng mô-đun tổng hợp đặc trưng đa tỷ lệ PAFPN với n kênh [22]. Phần Head bao gồm m lớp tích chập 3×3 với h kênh để dự đoán điểm số và hồi quy hộp giới hạn khuôn mặt [22].
- *Gộp bậc tự do*: Nhóm tác giả sử dụng thiết kế chia sẻ phần Head cho cả 3 tỷ lệ bản đồ đặc trưng, đồng thời cố định số lượng kênh cho tất cả các lớp tích chập bên trong Head [22]. Nhờ vậy, thiết kế Neck và Head được rút gọn xuống chỉ còn 3 bậc tự do:
 1. Số kênh đầu ra của nhánh Neck: n .
 2. Số kênh đầu ra của nhánh Head: h .
 3. Số lượng lớp tích chập 3×3 bên trong Head: m .
- *Ràng buộc lấy mẫu*: Tương tự như Backbone, các tham số này được lấy mẫu đều với các điều kiện: $n \leq 256$, $h \leq 256$, và $m \leq 6$ [22].

C. Chiến lược tìm kiếm hai bước.



Hình II.4: Quy trình tìm kiếm hai bước trong SCRFD để tái phân bổ tính toán.

Để tránh bùng nổ tổ hợp khi tìm kiếm, SCRFD áp dụng chiến lược hai bước, minh họa ở Hình II.4:

- **Bước 1**: tìm depth và width cho backbone dưới giới hạn FLOPs. Trong bước này, tìm kiếm ưu tiên tăng năng lực tại các tầng nông như C_2 và C_3 , nơi có độ phân giải cao và đóng vai trò quan trọng cho khuôn mặt nhỏ.
- **Bước 2**: sau khi backbone được cố định, tiếp tục điều chỉnh số kênh của Neck và Head để cân bằng tổng chi phí tính toán và giữ hiệu năng tối ưu.

Chiến lược hai bước giúp giảm đáng kể không gian tìm kiếm và làm cho random search trở nên hiệu quả trong thực tế.

D. Tái phân bổ tài nguyên giữa các tầng.

Kết quả của CR cho thấy một xu hướng rõ ràng:

- Tăng độ sâu hoặc số kênh tại C_2, C_3 .
- Giảm tương đối tài nguyên tại C_4, C_5 .
- Giữ Neck và Head ở mức vừa đủ để không làm FLOPs vượt ngưỡng.

Thiết kế này tạo nên một kiến trúc tập trung vào tầng nông và gọn ở tầng sâu, phù hợp hơn với bài toán phát hiện khuôn mặt nhỏ.

E. Tác động đến hiệu quả tính toán.

Điểm quan trọng của CR là không tăng tổng ngân sách FLOPs mà chỉ tái phân bổ lại phép tính. Nhờ đó, mô hình đạt được cải thiện đáng kể về độ chính xác trên tập khó trong khi vẫn giữ chi phí suy luận trong giới hạn mục tiêu.

Computation Redistribution không bổ sung mô-đun mới mà tái cấu trúc phân bổ tài nguyên trong toàn mạng. Cơ chế này đặt nền tảng cho kiến trúc SCRFD tối ưu dưới nhiều mức ngân sách tính toán khác nhau.

3.6 Sample Redistribution SR

Bên cạnh việc tái phân bổ tài nguyên tính toán, SCRFD còn giải quyết một vấn đề quan trọng khác trong phát hiện dày đặc: sự mất cân bằng phân bố mẫu theo thang đo, còn gọi là scale imbalance. Cơ chế *Sample Redistribution SR* được đề xuất nhằm tăng mật độ mẫu dương hữu ích ở các mức đặc trưng phù hợp với khuôn mặt rất nhỏ, mà không làm tăng chi phí suy luận. [22]

A. Vấn đề: Thiếu mẫu dương ở mức tiny faces.

Trong detector anchor-based, mỗi anchor tại từng mức đặc trưng được gán nhãn dương hoặc âm dựa trên mức độ chồng lấp IoU với hộp thật. Với khuôn mặt rất nhỏ:

- Số lượng anchor phù hợp có thể hạn chế.
- Việc thu nhỏ độ phân giải qua backbone làm giảm số vị trí lưới có thể khớp tốt.
- Phân bố kích thước khuôn mặt trong dữ liệu thực tế thường lệch mạnh về phía đối tượng nhỏ.

Hệ quả là ở các mức đặc trưng nông với stride nhỏ, số mẫu dương hữu ích có thể chưa đủ để huấn luyện head đạt độ nhạy cao với tiny faces.

B. Ý tưởng cốt lõi của SR.

Thay vì thay đổi kiến trúc hoặc thêm anchor phức tạp, SR điều chỉnh *chiến lược thu phóng dữ liệu trong huấn luyện*. Cụ thể, SCRFD tìm một phân bố scale augmentation tối ưu sao cho:

- Các khuôn mặt nhỏ xuất hiện nhiều hơn ở các mức đặc trưng phù hợp.
- Tăng số anchor được gán nhãn dương ở các stride nhỏ.

Điểm quan trọng là SR chỉ tác động trong giai đoạn huấn luyện; kiến trúc và quy trình suy luận không thay đổi.

C. Thiết kế anchor theo mức đặc trưng.

SCRFD sử dụng thiết kế anchor đơn giản và chuyên biệt cho face detection:

$$\{16, 32\} \text{ trên stride } 8, \quad \{64, 128\} \text{ trên stride } 16, \quad \{256, 512\} \text{ trên stride } 32.$$

So với detector tổng quát, SCRFD:

- Giảm đa dạng tỉ lệ hình học và ưu tiên gần vuông cho khuôn mặt.
- Phân công rõ ràng kích thước theo từng mức đặc trưng.

Thiết kế này tạo điều kiện để SR điều chỉnh phân bố scale huấn luyện một cách hiệu quả.

D. Không gian tìm kiếm cho chiến lược thu phóng.

SR xây dựng một không gian tìm kiếm cho các hệ số thu phóng, còn gọi là resize scale, áp dụng trong data augmentation. Thông qua tìm kiếm thực nghiệm, mô hình chọn được phân bố scale giúp:

- Tăng xác suất khuôn mặt rất nhỏ được ánh xạ lên kích thước phù hợp với anchor stride 8.
- Giảm tình trạng thiếu mẫu dương ở các mức nông.

Chiến lược này có thể được xem như một hình thức cân bằng lại phân bố mẫu theo thang đo, nhưng được thực hiện ở mức dữ liệu thay vì thay đổi kiến trúc.

E. Phân biệt SR với CR.

Hai cơ chế CR và SR có vai trò bổ sung nhưng khác bản chất:

- CR tái phân bố *tài nguyên tính toán* trong kiến trúc.
- SR tái phân bố *mẫu huấn luyện* theo thang đo.

CR thay đổi cấu trúc mạng, còn SR giữ nguyên cấu trúc nhưng thay đổi cách dữ liệu được trình bày cho mạng trong huấn luyện.

F. Tác động đến độ phủ tiny faces.

Nhờ tăng số mẫu dương ở các mức đặc trưng nông, SR cải thiện đáng kể recall trên miền khó của WIDER FACE mà không làm tăng FLOPs. Hiệu quả này đặc biệt rõ khi kết hợp với CR, do tài nguyên tính toán đã được dồn nhiều hơn về các tầng có độ phân giải cao.

Sample Redistribution là cơ chế cân bằng lại phân bố scale của dữ liệu huấn luyện nhằm tối đa hóa hiệu quả của kiến trúc đã được tái phân bố bởi CR.

3.7 Kết quả kiến trúc tối ưu sau CR và SR

Sau khi áp dụng Computation Redistribution CR và Sample Redistribution SR, SCRFD thu được các cấu hình kiến trúc tối ưu tương ứng với nhiều mức ngân sách FLOPs khác nhau. Phần này mô tả đặc điểm chung của các kiến trúc tối ưu thu được từ quá trình tìm kiếm.

A. Xu hướng tái phân bố tài nguyên hướng tới tầng nông.

So với backbone phân loại ảnh truyền thống, chẳng hạn ResNet chuẩn, kiến trúc tối ưu của SCRFD thể hiện một dịch chuyển rõ rệt:

- Tăng độ sâu, tức số block, và hoặc số kênh tại các tầng nông C_2, C_3 .
- Giảm tương đối độ sâu hoặc số kênh tại các tầng sâu C_4, C_5 .

Thiết kế này phản ánh trực tiếp mục tiêu của CR: dồn nhiều tài nguyên tính toán hơn về các mức đặc trưng có độ phân giải cao, nơi chứa thông tin quan trọng cho phát hiện khuôn mặt nhỏ.

Trong khi đó, việc giảm tài nguyên ở tầng sâu không làm suy giảm đáng kể hiệu năng, do bài toán face detection, đặc biệt với khuôn mặt rất nhỏ, phụ thuộc nhiều hơn vào độ chính xác định vị không gian hơn là ngữ nghĩa trừu tượng ở mức cao.

B. Cân bằng lại Neck và Head dưới ràng buộc FLOPs.

Sau khi backbone được tái cấu trúc, số kênh tại Neck dùng PAFPN và Head cũng được điều chỉnh để giữ tổng FLOPs trong ngân sách mục tiêu. Các cấu hình tối ưu thường:

- Giữ số kênh Neck ở mức vừa đủ để hợp nhất đặc trưng hiệu quả.
- Duy trì Head gọn nhẹ nhằm tránh chi phí dày đặc tăng theo kích thước đặc trưng.

Điều này đảm bảo rằng việc tăng năng lực tại tầng nông không làm bùng nổ chi phí ở các phần còn lại của mạng.

C. Tinh chỉnh thiết kế anchor theo cấu trúc tối ưu.

Song song với tái phân bố tính toán, thiết kế anchor được đơn giản hóa và chuyên biệt cho khuôn mặt:

- Giảm đa dạng tỉ lệ hình học, ưu tiên tỉ lệ gần vuông phù hợp với cấu trúc khuôn mặt.
- Quy hoạch kích thước theo từng mức stride:

$\{16, 32\}$ trên stride 8, $\{64, 128\}$ trên stride 16, $\{256, 512\}$ trên stride 32.

Việc gán kích thước rõ ràng theo từng mức đặc trưng giúp tối đa hóa hiệu quả của SR, vì dữ liệu được thu phóng trong huấn luyện sẽ đẩy thêm mẫu dương về đúng mức cần tăng độ nhảy.

D. Đặc trưng chung của họ mô hình SCRFD.

Từ quá trình tìm kiếm, SCRFD hình thành một họ mô hình tương ứng với nhiều mức ngân sách tính toán, chẳng hạn dưới 1 GFLOPs hoặc vài chục GFLOPs. Mặc dù khác nhau về quy mô, các cấu hình này đều chia sẻ những đặc điểm chung:

- Tập trung tài nguyên vào các tầng có độ phân giải cao.
- Giữ cấu trúc Neck–Head gọn nhẹ.
- Thiết kế anchor đơn giản, phù hợp với face detection.

Những đặc điểm này cho thấy hiệu năng cải thiện của SCRFD không đến từ việc tăng thuần kích thước mô hình, mà từ việc tái cấu trúc hợp lý phân bố tính toán và phân bố mẫu.

Vậy, kiến trúc tối ưu của SCRFD là kết quả trực tiếp của hai cơ chế CR và SR, thể hiện một sự điều chỉnh có hệ thống so với thiết kế detector tổng quát ban đầu.

3.8 Liên hệ tư duy thiết kế với phát hiện khuôn mặt cổ điển

Mặc dù SCRFD được xây dựng trên nền tảng học sâu hiện đại, nhiều nguyên lý thiết kế cốt lõi của nó có thể được đặt trong mạch phát triển lịch sử của bài toán phát hiện khuôn mặt. Đặc biệt, khi so sánh ở mức tư duy hệ thống, SCRFD cho thấy sự kế thừa có chọn lọc từ các phương pháp cổ điển như Viola–Jones.

A. Nguyên lý tối ưu chi phí tính toán.

Viola–Jones đạt được tốc độ gần thời gian thực thông qua cơ chế cascade: loại sớm phần lớn cửa sổ âm bằng các bộ phân loại đơn giản, chỉ dành tài nguyên cho những ứng viên có tiềm năng cao. Nguyên lý cốt lõi ở đây là *phân bổ tài nguyên theo xác suất hữu ích của tín hiệu*.

SCRFD hiện thực hóa nguyên lý này ở mức kiến trúc học sâu: thay vì loại sớm từng cửa sổ, mô hình tái phân bổ FLOPs về các tầng đặc trưng có độ phân giải cao, nơi tín hiệu khuôn mặt nhỏ xuất hiện nhiều hơn. Computation Redistribution vì vậy có thể xem như một hình thức tối ưu chi phí ở cấp độ mạng nơ-ron, thay vì ở cấp độ cửa sổ quét.

B. Tư duy đa tỉ lệ.

Trong Viola–Jones, tháp ảnh, còn gọi là image pyramid, được sử dụng để quét cửa sổ ở nhiều kích thước khác nhau. Ý tưởng này phản ánh nhận thức rằng đối tượng xuất hiện ở nhiều thang đo cần được xử lý tương ứng.

SCRFD kế thừa nguyên lý đa tỉ lệ nhưng hiện đại hóa thông qua đặc trưng phân tầng $C_2 \rightarrow C_5$ và PAFPN. Thay vì thu nhỏ ảnh nhiều lần, mô hình học trực tiếp một tháp đặc trưng nội tại. Sample Redistribution tiếp

tục mở rộng tư duy này bằng cách điều chỉnh phân bố scale trong huấn luyện, nhằm đảm bảo các mức đặc trưng quan trọng nhận đủ mẫu dương.

C. Cơ chế hợp nhất dự đoán cuối.

Trong detector cổ điển, nhiều cửa sổ chồng lấp quanh cùng một khuôn mặt được gom nhóm và hợp nhất để tạo ra một hộp duy nhất. SCRFD duy trì vai trò này thông qua loại bỏ không cực đại NMS, cho thấy cấu trúc ba bước của bài toán phát hiện vẫn giữ nguyên: sinh giả thuyết, chấm điểm, hợp nhất kết quả.

D. Từ tối ưu thủ công sang tối ưu theo dữ liệu.

Khác biệt căn bản giữa hai thể hệ phương pháp nằm ở cách tối ưu:

- Viola-Jones dựa vào thiết kế đặc trưng thủ công và cascade cố định.
- SCRFD sử dụng tìm kiếm kiến trúc và điều chỉnh phân bố dữ liệu dựa trên thực nghiệm.

Tuy nhiên, cả hai đều chia sẻ cùng một mục tiêu: đạt hiệu năng cao nhất dưới ràng buộc tài nguyên tính toán.

SCRFD có thể được xem như một bước tiến hóa tự nhiên của tư duy phát hiện khuôn mặt: giữ nguyên cấu trúc logic của bài toán gồm đa tỉ lệ, dự đoán dày đặc, hợp nhất kết quả, nhưng thay thế cơ chế thủ công bằng mô hình học sâu và tối ưu dựa trên dữ liệu. Sự kế thừa này cho thấy các nguyên lý nền tảng của bài toán vẫn còn giá trị, ngay cả khi công nghệ hiện thực đã thay đổi đáng kể.

4 Phân tích thực nghiệm

SCRFD được đánh giá trên WIDER FACE, nơi khuôn mặt nhỏ chiếm ưu thế và bộc lộ rõ điểm yếu xử lý tỉ lệ. Bài báo báo cáo AP trên các tập Easy/Medium/Hard và so sánh đồng thời độ chính xác lẫn hiệu năng trong điều kiện suy luận được kiểm soát. [9], [22]

Một số kết quả định lượng tiêu biểu trong bài báo cho thấy mức cải thiện rõ rệt về đánh đổi độ chính xác - chi phí tính toán:

- Ở chế độ VGA, **SCRFD-34GF** đạt AP tập khó 86.21, cao hơn TinaFace ở mức 81.43 trong khi chi phí thấp hơn mạnh.
- Cùng mốc này, SCRFD-34GF dùng khoảng 34.13 GFLOPs so với 172.95 GFLOPs của TinaFace, tức chỉ khoảng một phần năm chi phí tính toán.
- So với BFBox trong cùng bối cảnh đánh giá, bài báo báo cáo mức vượt đáng kể ở AP tập khó nhờ tối ưu đồng thời backbone, neck và head.
- Ở miền chi phí thấp, SCRFD-0.5GF vượt rõ các cấu hình nhẹ kiểu MobileNet baseline trên tập khó, cho thấy lợi ích của CR và SR vẫn giữ được khi ngân sách tính toán rất hạn chế.

Các số liệu trên được trích trực tiếp từ các bảng định lượng trong bài báo SCRFD, chủ yếu ở Table 2 và phần đối chiếu chi phí TinaFace tại Table 4. [22]

Trọng tâm phân tích của báo cáo gồm:

- Vì sao CR giúp chuyển tài nguyên tính toán sang các thành phần có đóng góp hiệu quả hơn cho phát hiện khuôn mặt nhỏ.
- Vì sao SR cải thiện hành vi của mô hình trên tập khó thông qua tái phân bố mẫu theo thang tỉ lệ.
- SCRFD định vị như thế nào so với các mô hình nền tiêu biểu ở cả nhánh một giai đoạn và hai giai đoạn.

5 Minh họa cài đặt (để ở báo cáo cuối kỳ)

Phần cài đặt và benchmark đầy đủ được dời lại. Báo cáo giữa kỳ này chốt trước kế hoạch minh họa:

- Chạy ít nhất hai mức kích thước mô hình SCRFD trên cùng một tập kiểm định.
- Báo cáo AP (hoặc chỉ báo thay thế theo tập), độ trễ, FPS, và độ phức tạp mô hình.
- Trình bày ví dụ định tính cả thành công/lỗi trên khuôn mặt nhỏ, đông đúc, và che khuất.
- Giữ cố định môi trường và tiền xử lý để đảm bảo so sánh công bằng.

6 Thảo luận phản biện

6.1 Điểm mạnh

Bài báo trình bày một quy trình tối ưu có hệ thống cho bài toán phát hiện khuôn mặt dưới ràng buộc tài nguyên tính toán.

- **Tối ưu hóa toàn diện:** SCRFD tái phân bổ tính toán trên cả backbone, neck và head thay vì chỉ tối ưu một thành phần riêng lẻ.
- **Không gian tìm kiếm được không chế:** Tác giả giảm bậc tự do để giới hạn tổ hợp cần khảo sát trong NAS:
 - **Giảm bậc tự do:** gộp tham số stem vào C_2 , dùng head chia sẻ giữa các mức và áp ngưỡng chặn cho tham số kiến trúc.
 - **Tìm kiếm hai bước:** tách tìm kiếm backbone và tìm kiếm toàn mạng để giảm chi phí khảo sát.
 - **Bootstrap thống kê:** dùng bootstrap để ước lượng phân bố tính toán ổn định hơn từ tập mô hình ngẫu nhiên.
- **Tự động hóa tăng cường theo thang đo:** cơ chế SR tăng mật độ mẫu dương ở miền khuôn mặt nhỏ, cải thiện tín hiệu huấn luyện cho tập khó.
- **Đánh đổi độ chính xác – chi phí hợp lý:** kết quả thực nghiệm cho thấy mô hình giữ hiệu năng tốt trên WIDER FACE trong nhiều mức ngân sách FLOPs.
- **Khả năng mở rộng theo tài nguyên:** cùng một triết lý thiết kế có thể áp dụng từ cấu hình rất nhẹ đến cấu hình hiệu năng cao.

6.2 Hạn chế

Phương pháp của SCRFD vẫn dựa trên một số giả định và còn các giới hạn kỹ thuật sau:

- **Chi phí NAS cao nhưng phát sinh một lần:** Việc huấn luyện hàng trăm mô hình trên cụm GPU là chi phí tìm kiếm kiến trúc ở giai đoạn nghiên cứu. Đây không phải chi phí bắt buộc khi triển khai. Ở lớp ứng dụng, người dùng dùng trực tiếp kiến trúc và trọng số đã công bố nên chi phí suy luận vẫn thấp.
- **Giả định khối cơ bản cố định:** Không gian tìm kiếm chủ yếu tối ưu ở mức vĩ mô (độ sâu, độ rộng, kênh neck/head), chưa mở rộng tới tìm kiếm toán tử vi mô trong từng khối.
- **Phụ thuộc miền dữ liệu và độ phân giải mục tiêu:** Cấu hình tối ưu chịu ảnh hưởng bởi phân bố dữ liệu WIDER FACE và thiết lập VGA, nên khi chuyển miền có thể cần tinh chỉnh lại.

- **Giới hạn ở miền khuôn mặt cực nhỏ:** Với khuôn mặt dưới ngưỡng khớp anchor, hiệu quả vẫn giảm do tín hiệu đặc trưng quá ít.
- **Ràng buộc thủ công trong không gian tìm kiếm:** Các ngưỡng chặn giúp giảm chi phí NAS nhưng có thể bỏ qua một số cấu hình tiềm năng.
- **Khả năng chuyển giao có điều kiện:** Khi đổi tác vụ hoặc đổi kiến trúc nền, cần thiết kế lại không gian tìm kiếm thay vì tái sử dụng nguyên quy trình.

6.3 Giá trị ứng dụng công nghiệp

SCRFD đưa ra một thông điệp thực dụng cho triển khai công nghiệp: không thể lấy nguyên cấu hình mạng phân loại tổng quát rồi áp thẳng vào bài toán phát hiện khuôn mặt nhỏ mà không tái thiết kế theo đặc thù dữ liệu. Họ mô hình từ 0.5GF đến 34GF tạo ra một dải cấu hình phù hợp nhiều mức tài nguyên, từ thiết bị biên công suất thấp đến hệ thống máy chủ giám sát.

- Ở lớp thiết bị biên, các cấu hình nhẹ ưu tiên độ trễ thấp và chi phí tính toán nhỏ.
- Ở lớp máy chủ, các cấu hình cao hơn giữ độ chính xác mạnh trên cảnh đông và khuôn mặt nhỏ.
- Cùng một triết lý CR và SR giúp duy trì tính nhất quán khi mở rộng từ kịch bản camera đơn lẻ sang hệ thống phân tích đám đông.

6.4 Rào cản kỹ thuật và khả năng tái lập

Điểm khó lớn nhất của phương pháp nằm ở pha tìm kiếm kiến trúc. Theo mô tả trong bài báo, để thực hiện empirical bootstrap cho từng mức ngân sách FLOPs, nhóm tác giả sinh và huấn luyện từ đầu 320 mô hình trên cụm 8 GPU Tesla V100. [22]

- Với phòng thí nghiệm nhỏ hoặc dữ liệu tùy chỉnh, chi phí tái lập đầy đủ pha NAS là thách thức đáng kể.
- Trong triển khai thực tế, cách làm phổ biến là dùng cấu hình và trọng số đã công bố, sau đó tinh chỉnh nhẹ theo miền dữ liệu nếu cần.
- Vì vậy, rào cản chính nằm ở tái lập quy trình tìm kiếm kiến trúc, không nằm ở chi phí suy luận của mô hình đã chốt.

6.5 Hướng cải tiến tiềm năng

- **Tinh chỉnh hàm mất mát cho miền khuôn mặt nhỏ:** Có thể thử các biến thể focal loss theo mức đặc trưng hoặc cân bằng động giữa nhánh phân loại và hồi quy để giảm bỏ sót trên tập Hard mà không làm tăng đáng kể FLOPs.
- **Knowledge distillation từ mô hình lớn sang mô hình nhẹ:** Dùng mô hình giáo viên có độ chính xác cao để hướng dẫn các bản SCRFD nhẹ học tốt hơn phân bố điểm số và hộp bao, giúp cải thiện chất lượng trong giới hạn tính toán thấp.
- **Tăng cường dữ liệu theo hướng thực dụng:** Ưu tiên các phép tăng cường phản ánh điều kiện triển khai như mờ chuyển động, nén ảnh, thiếu sáng, che khuất cục bộ và thay đổi tỉ lệ khuôn mặt để tăng độ bền mô hình.
- **Giảm chi phí tìm kiếm kiến trúc:** Có thể dùng chiến lược NAS chi phí thấp như weight sharing hoặc chỉ báo đánh giá nhanh để rút ngắn thời gian khảo sát không gian kiến trúc, nhưng vẫn giữ triết lý phân bổ tính toán của SCRFD. [28]

- **Tinh chỉnh theo miền dữ liệu khi triển khai:** Thay vì chạy lại toàn bộ NAS, có thể giữ kiến trúc đã công bố và điều chỉnh tham số huấn luyện, ngưỡng hậu xử lý cùng lịch tăng cường dữ liệu theo miền ứng dụng.

6.6 Tóm tắt so sánh chương sách và SCRFD

Bảng II.1: So sánh phương pháp chương sách và SCRFD: cùng mục tiêu, khác cách hiện thực

Khía cạnh	Chương sách (cổ điển)	Bài báo SCRFD (hiện đại)
Thiết kế đặc trưng	Họ đặc trưng thủ công Haar/LBP	Hệ đặc trưng CNN học sâu đa tầng
Lỗi học máy	Xây dựng bộ phân loại dựa trên boosting	Tìm kiếm CR + SR dưới ràng buộc ngân sách tính toán
Chiến lược tốc độ	Loại sớm bằng cascade	Tái cấu trúc phân bổ tính toán + họ mô hình gọn
Xử lý tỉ lệ	Quét theo tháp/quy tắc kinh nghiệm đa góc nhìn	Tái phân bổ tăng cường theo thang tỉ lệ được tìm kiếm
Hợp nhất kết quả cuối	Gom các cửa sổ chồng lấp	NMS chuẩn trên dự đoán dày đặc

7 Kết luận

SCRFD giữ nguyên mục tiêu theo giai đoạn của bộ phát hiện đã hình thành từ phát hiện cổ điển, nhưng thay thế từng giai đoạn bằng cơ chế học được, có nhận thức ngân sách tính toán và nhảy theo thang tỉ lệ. Cấu trúc hai chương này làm rõ cả nền tảng lịch sử (chương sách) lẫn hiện thực tiên tiến hiện đại (bài báo) trong một mạch báo cáo nghiên cứu thống nhất.

Chương III

PHÂN TÍCH THỰC NGHIỆM BỔ SUNG CHO SCRFD

1 Mục tiêu và thiết lập thực nghiệm

Phần này tổng hợp và diễn giải lại kết quả thực nghiệm của mô hình SCRFD 2.5G dưới dạng một chương độc lập trong báo cáo. Mục tiêu chính là trả lời hai câu hỏi:

- vì sao mô hình có hai cải tiến đề xuất lại tốt hơn mô hình gốc;
- vì sao khi thay bộ tỉ lệ cắt mặc định bằng bộ 12 mức được chọn từ quá trình tìm kiếm trong bài báo SCRFD, hành vi của mô hình lại thay đổi.

Trong toàn bộ thí nghiệm, kiến trúc Backbone–Neck–Head của SCRFD 2.5G được giữ nguyên. Các mô hình đều được huấn luyện trong 80 epoch với lịch học cosine. Hai nhóm thí nghiệm được so sánh là:

- **Bộ tỉ lệ mặc định trong mã nguồn:** dùng đúng tập tỉ lệ cắt xuất hiện trong mã nguồn công khai của SCRFD.
- **Bộ 12 mức theo kết quả tìm kiếm của bài báo:** thay tập tỉ lệ cắt tĩnh bằng bộ 12 mức được mô tả ở phần phân phối lại mẫu của bài báo SCRFD [22].

Trong mỗi nhóm, so sánh được thực hiện giữa:

- **mô hình gốc:** dùng cơ chế huấn luyện ban đầu của SCRFD;
- **mô hình cải tiến:** bổ sung hai thành phần là *phân phối lại mẫu thích nghi* và *phân phối lại phép gán mẫu*.

2 Hai thành phần cải tiến

2.1 Phân phối lại mẫu thích nghi

Thành phần thứ nhất thay thế cách chọn tỉ lệ cắt ảnh theo xác suất cố định bằng một phân phối xác suất được cập nhật liên tục theo phản hồi của quá trình huấn luyện. Có thể hiểu cơ chế này theo ba ý chính:

- từ kết quả huấn luyện của epoch hiện tại, mô hình thống kê xem nhóm khuôn mặt nào đang học kém;
- các nhóm đang khó hơn sẽ làm tăng xác suất của những tỉ lệ cắt có xu hướng sinh ra đúng loại mẫu đó trong epoch kế tiếp;

- sau nhiều lần cập nhật, phân phối dữ liệu huấn luyện sẽ dịch dần về phía những trường hợp mà mô hình còn xử lý chưa tốt, đặc biệt là khuôn mặt rất nhỏ.

Như vậy, thay vì giữ nguyên một lịch lấy mẫu tĩnh từ đầu đến cuối, mô hình tự điều chỉnh cách lấy mẫu theo tình trạng học thực tế của chính nó.

Trong cài đặt hiện tại, khuôn mặt trong mỗi ảnh sau tăng cường dữ liệu được chia vào bốn nhóm kích thước: rất nhỏ, nhỏ, vừa và lớn. Sau mỗi epoch, hệ thống thu thập các thống kê sau cho từng nhóm b :

- G_b : số khuôn mặt thật thuộc nhóm b ;
- P_b : số anchor dương khớp với nhóm b ;
- L_b^{cls} : tổng lỗi phân loại trên nhóm b ;
- L_b^{box} : tổng lỗi hồi quy hộp bao trên nhóm b .

Từ các thống kê này, trước hết ta đo mức thiếu giám sát của từng nhóm thông qua

$$r_b = \max\left(0, 1 - \min\left(\frac{P_b}{\max(G_b, 1)}, 1\right)\right), \quad (\text{III.1})$$

trong đó r_b càng lớn thì nhóm b càng có xu hướng thiếu mẫu dương.

Tiếp theo, ta tính lỗi trung bình trên mỗi mẫu dương:

$$\bar{L}_b^{cls} = \frac{L_b^{cls}}{\max(P_b, 1)}, \quad \bar{L}_b^{box} = \frac{L_b^{box}}{\max(P_b, 1)}. \quad (\text{III.2})$$

Để các đại lượng này có cùng thang đo, mỗi đại lượng được chuẩn hóa theo trung bình của các giá trị dương:

$$\text{Norm}(x_b) = \frac{x_b}{\text{mean}(\{x_j \mid x_j > 0\}) + \varepsilon}. \quad (\text{III.3})$$

Độ khó của nhóm b được xác định bằng tổng ba thành phần:

$$d_b = \text{Norm}(r_b) + \text{Norm}(\bar{L}_b^{cls}) + \text{Norm}(\bar{L}_b^{box}). \quad (\text{III.4})$$

Nói cách khác, một nhóm được xem là “khó” khi vừa thiếu anchor dương, vừa có lỗi phân loại cao, vừa có lỗi hồi quy cao.

Sau khi có độ khó d_b , hệ thống chiếu thông tin này sang từng tỉ lệ cắt s bằng một hàm tương hợp:

$$S(s, b) = \exp\left(-\frac{|\log s - \log \mu_b|}{0.45}\right), \quad (\text{III.5})$$

trong đó μ_b là tỉ lệ cắt được xem là phù hợp nhất với nhóm kích thước b . Xác suất thô cho từng tỉ lệ cắt được viết dưới dạng

$$q(s) \propto \sum_b S(s, b) d_b. \quad (\text{III.6})$$

Để tránh việc một số tỉ lệ bị triệt tiêu hoàn toàn, phân phối mới được làm trơn bằng hai bước. Trước hết, áp đặt một mức xác suất sàn:

$$\tilde{q}(s) = q(s)(1 - Km) + m, \quad (\text{III.7})$$

trong đó K là số tỉ lệ cắt và m là mức sàn tối thiểu. Sau đó, cập nhật bằng trung bình trượt lũy thừa:

$$p_{t+1}(s) = \alpha p_t(s) + (1 - \alpha) \tilde{q}(s), \quad (\text{III.8})$$

với α là hệ số làm trơn theo thời gian.

Điểm cần nhấn mạnh là trong pipeline của SCRFD, tỉ lệ cắt s không biểu diễn trực tiếp “khuôn mặt lớn” hay “khuôn mặt nhỏ”. Thay vào đó:

- s nhỏ tương ứng với vùng cắt nhỏ hơn, tức là phóng to khuôn mặt sau khi đổi cỡ ảnh;
- s lớn tương ứng với vùng cắt rộng hơn, tức là làm khuôn mặt nhỏ lại sau khi đổi cỡ ảnh.

Vì vậy, thành phần này thực chất điều khiển phân phối kích thước khuôn mặt mà mô hình nhìn thấy trong quá trình huấn luyện. Nó không thay đổi kiến trúc mạng, mà thay đổi “bài toán huấn luyện” theo hướng ưu tiên nhiều hơn cho những trường hợp khuôn mặt rất nhỏ.

2.2 Phân phối lại phép gán mẫu

Thành phần thứ hai tác động vào bước gán nhãn giữa anchor và khuôn mặt thật trong giai đoạn huấn luyện. Mục tiêu là tăng mật độ giám sát cho các khuôn mặt rất nhỏ, vốn thường nhận quá ít anchor dương nếu giữ nguyên quy tắc gán nhãn ban đầu. Về bản chất, cơ chế này làm ba việc:

- nới ngưỡng chấp nhận cho các khuôn mặt rất nhỏ hoặc nhỏ;
- nới điều kiện ràng buộc theo vùng gần tâm để bớt loại bỏ quá sớm các anchor lân cận;
- nếu sau hai bước trên mà số anchor dương vẫn chưa đủ, hệ thống sẽ chọn thêm một số anchor gần nhất theo điểm số ghép cặp.

Vì vậy, cơ chế này không làm thay đổi mạng ở giai đoạn suy luận, mà chỉ làm cho khuôn mặt rất nhỏ nhận được nhiều tín hiệu giám sát hơn trong lúc huấn luyện.

Cơ chế gán nhãn gốc của SCRFD dựa trên ATSS. Với mỗi khuôn mặt thật g , ATSS xây dựng một ngưỡng chấp nhận

$$\tau_g = \mu_g + \sigma_g, \quad (\text{III.9})$$

trong đó μ_g và σ_g lần lượt là trung bình và độ lệch chuẩn của IoU trên tập anchor ứng viên quanh g . Một anchor chỉ được xem là dương nếu vừa đủ gần tâm, vừa có IoU lớn hơn ngưỡng này.

Phần cải tiến can thiệp theo ba bước.

2.2.0.1 Nới ngưỡng chấp nhận cho đối tượng nhỏ

Với các khuôn mặt có kích thước dưới ngưỡng quy định, ngưỡng chấp nhận được hạ xuống:

$$\tau'_g = \tau_g - \Delta_g, \quad (\text{III.10})$$

trong đó

$$\Delta_g = \begin{cases} \delta_{\text{rất nhỏ}}, & \text{nếu } \text{size}_g < T_{\text{rất nhỏ}}, \\ \delta_{\text{nhỏ}}, & \text{nếu } T_{\text{rất nhỏ}} \leq \text{size}_g < T_{\text{nhỏ}}, \\ 0, & \text{nếu } \text{size}_g \geq T_{\text{nhỏ}}. \end{cases} \quad (\text{III.11})$$

Như vậy, với khuôn mặt rất nhỏ, anchor không cần đạt IoU quá cao mới được xem là mẫu dương.

2.2.0.2 Nới điều kiện ràng buộc theo tâm

Không chỉ ngưỡng IoU, điều kiện “anchor phải đủ gần tâm” cũng được điều chỉnh theo kích thước. Hệ số điều chỉnh được viết là

$$c_g = \text{clip}\left(\frac{\text{size}_g}{T_{\text{rất nhỏ}}}, 1, \rho\right). \quad (\text{III.12})$$

Anchor a được giữ lại nếu thỏa điều kiện

$$d_{\min}(a, g) c_g > t_{\text{tâm}}, \quad (\text{III.13})$$

trong đó $d_{\min}(a, g)$ là khoảng cách tối thiểu từ anchor đến vùng trung tâm của khuôn mặt g . Khi g rất nhỏ, hệ số c_g làm điều kiện này bớt khắt khe hơn, nhờ đó một số anchor lân cận vẫn còn được giữ lại.

2.2.0.3 Bổ sung anchor nếu vẫn thiếu mẫu dương

Ngay cả sau hai bước trên, một khuôn mặt rất nhỏ vẫn có thể nhận quá ít mẫu dương. Khi đó, nếu

$$N_{\text{dương}}(g) < N_{\min}, \quad (\text{III.14})$$

hệ thống sẽ chọn thêm một số anchor gần nhất theo điểm số

$$\text{score}(a, g) = \text{IoU}(a, g) - 0.05 \cdot \frac{\text{dist}(a, g)}{\max(\text{size}_g, 1)}. \quad (\text{III.15})$$

Điểm số này ưu tiên những anchor vừa có IoU khá tốt, vừa nằm gần khuôn mặt thật. Trong một số biến thể, trọng số mềm còn được mô tả bởi

$$w(a, g) = \exp\left(-\frac{\text{dist}_{\text{chuẩn hóa}}}{T}\right) \cdot \text{clamp}(\text{IoU}(a, g) + 0.1, 0.05, 1.0), \quad (\text{III.16})$$


nhưng trong các thực nghiệm báo cáo ở đây, cơ chế chính vẫn là nối ngưỡng và bổ sung một số anchor gần nhất khi cần.

Tóm lại, nếu thành phần thứ nhất làm thay đổi loại dữ liệu mà mô hình thường xuyên nhìn thấy, thì thành phần thứ hai làm tăng trực tiếp lượng tín hiệu giám sát mà đối tượng rất nhỏ nhận được trong quá trình gán nhãn.

3 Kết quả định lượng

3.1 So sánh tổng quát

Hình III.1 và Bảng III.1 tóm tắt kết quả trên bộ dữ liệu WIDERFace.




Hình III.1: So sánh chỉ số Easy AP, Medium AP, Hard AP và mAP giữa mô hình gốc và mô hình cải tiến trên hai bộ tỉ lệ cắt.

Bảng III.1: Kết quả định lượng của mô hình gốc và mô hình cải tiến trên hai bộ tỉ lệ cắt

Bộ tỉ lệ cắt	Mô hình	Easy AP	Medium AP	Hard AP / mAP
Bộ mặc định trong mã nguồn	Gốc	0.9140	0.8969	0.7249 / 0.8453
Bộ mặc định trong mã nguồn	Cải tiến	0.9039	0.8925	0.7690 / 0.8551
Bộ 12 mức theo bài báo	Gốc	0.9161	0.8999	0.7371 / 0.8510
Bộ 12 mức theo bài báo	Cải tiến	0.9028	0.8901	0.7738 / 0.8556

Độ chênh giữa mô hình cải tiến và mô hình gốc được thể hiện ở Hình III.2.




Hình III.2: Mức tăng hoặc giảm của mô hình cải tiến so với mô hình gốc trên từng chỉ số đánh giá.

Quan sát chung cho thấy trong cả hai bộ tỉ lệ cắt, phần cải thiện lớn nhất luôn nằm ở chỉ số Hard AP. Đây là dấu hiệu đầu tiên cho thấy hai thành phần cải tiến đang tác động đúng vào nhóm trường hợp khó, thay vì chỉ làm tăng điểm trung bình một cách dàn trải.

4 Vì sao mô hình cải tiến tốt hơn mô hình gốc

4.1 Mật độ giám sát cho khuôn mặt rất nhỏ tăng lên rõ rệt

Hình III.3 cho thấy sau bước gán nhãn cải tiến, số anchor dương trên mỗi khuôn mặt rất nhỏ tăng lên đáng kể và ổn định ở cả hai bộ tỉ lệ cắt.



Hình III.3: Mật độ anchor dương trên mỗi khuôn mặt rất nhỏ trước và sau khi áp dụng cơ chế gán nhãn cải tiến.


Các giá trị chính là:

- với bộ mặc định trong mã nguồn: số anchor dương trên mỗi khuôn mặt rất nhỏ tăng từ 1.73 lên 2.67, tức tăng khoảng 1.542 lần;
- với bộ 12 mức theo bài báo: số anchor dương trên mỗi khuôn mặt rất nhỏ tăng từ 1.76 lên 2.67, tức tăng khoảng 1.520 lần.

Kết quả này cho thấy phần cải thiện không đến từ may mắn của quá trình huấn luyện, mà đến từ một thay đổi có chủ đích ở đúng nơi trước đây mô hình bị thiếu giám sát nhất.


4.2 Phần tăng điểm tập trung vào đúng nhóm khuôn mặt khó

Hình III.4 cho thấy mức tăng về khả năng thu hồi trên tập Hard tập trung gần như hoàn toàn vào hai khoảng kích thước nhỏ nhất, tức là những khuôn mặt từ 0 đến 16 pixel sau khi quy về kích thước đánh giá.




Hình III.4: Mức tăng khả năng thu hồi trên tập Hard theo từng khoảng kích thước khuôn mặt.

Hình III.5 cho thấy chi tiết theo từng bộ tỉ lệ cắt.



(a) Bộ mặc định trong mã nguồn



(b) Bộ 12 mức theo bài báo

Hình III.5: Mức tăng khả năng thu hồi trên tập Hard theo từng khoảng kích thước khuôn mặt.

Với bộ mặc định trong mã nguồn, phần tăng lớn nhất nằm ở:

- khoảng $[0, 8)$: tăng 0.138;
- khoảng $[8, 16)$: tăng 0.119.

Với bộ 12 mức theo bài báo, phần tăng lớn nhất cũng nằm ở hai khoảng tương tự:

- khoảng $[0, 8)$: tăng 0.108;
- khoảng $[8, 16)$: tăng 0.104.

Từ 16 pixel trở lên, phần chênh lệch gần như bằng 0 hoặc giảm nhẹ. Điều này cho thấy cơ chế cải tiến không làm tăng đồng đều cho mọi loại mẫu, mà tập trung rất đúng vào nhóm khuôn mặt rất nhỏ trên tập Hard, tức là nhóm trường hợp khó nhất của bài toán.

4.3 Hai thành phần cải tiến bổ sung cho nhau

Từ cơ chế hoạt động và kết quả định lượng, có thể tóm lược vai trò của hai thành phần như sau:


- **Phân phối lại mẫu thích nghi** làm thay đổi phân phối dữ liệu mà mô hình nhìn thấy trong quá trình huấn luyện, theo hướng đưa nhiều trường hợp khuôn mặt rất nhỏ vào học hơn.
- **Phân phối lại phép gán mẫu** làm tăng trực tiếp số lượng anchor dương gắn với khuôn mặt rất nhỏ, nghĩa là tăng mật độ giám sát đúng tại bước gán nhãn.

Nếu chỉ có thành phần thứ nhất, mô hình có thể nhìn thấy nhiều khuôn mặt rất nhỏ hơn nhưng vẫn chưa học được hiệu quả vì số anchor dương còn quá ít. Ngược lại, nếu chỉ có thành phần thứ hai, tín hiệu gán nhãn có thể dày hơn nhưng chưa chắc đã được khai thác hết, vì mô hình chưa được buộc nhìn đủ nhiều tình huống khó. Khi kết hợp cả hai, một thành phần làm tăng “độ hiện diện” của mẫu khó trong dữ liệu, còn thành phần kia làm tăng “mật độ giám sát” của chính nhóm mẫu đó. Đó là lý do vì sao mô hình cải tiến tốt hơn mô hình gốc ở cả hai bộ tỉ lệ cắt.

5 Vì sao bộ 12 mức theo bài báo cho hành vi khác

5.1 Bộ 12 mức theo bài báo vốn đã thiên về khuôn mặt rất nhỏ

Hình III.6 so sánh hình học của hai tập tỉ lệ cắt.



Hình III.6: So sánh hình học của hai tập tỉ lệ cắt và phân phối xác suất tương ứng.


Các số liệu tổng hợp cho thấy:

- với bộ mặc định trong mã nguồn, khối lượng xác suất đặt ở vùng phóng to mạnh ($s \leq 0.6$) lớn hơn, còn khối lượng ở vùng thu nhỏ mạnh ($s \geq 2.0$) nhỏ hơn;
- với bộ 12 mức theo bài báo, khối lượng ở vùng thu nhỏ mạnh lớn hơn đáng kể.

Điều đó có nghĩa là ngay từ khi chưa dùng cơ chế thích nghi, bộ 12 mức theo bài báo đã có xu hướng làm xuất hiện nhiều khuôn mặt nhỏ hơn sau bước cắt và đổi cỡ ảnh.

5.2 Phân phối khuôn mặt sau tăng cường dữ liệu đã dịch mạnh về phía mẫu khó

Hình III.7 minh họa rõ hơn tác động này.



Hình III.7: So sánh phân phối kích thước khuôn mặt sau bước cắt và đổi cỡ ảnh giữa hai bộ tỉ lệ cắt.

So sánh hai mô hình gốc cho thấy:

- với bộ mặc định trong mã nguồn, tỉ lệ khuôn mặt rất nhỏ là 0.475, trung vị kích thước khuôn mặt là 17.12;
- với bộ 12 mức theo bài báo, tỉ lệ khuôn mặt rất nhỏ tăng lên 0.582, còn trung vị kích thước giảm xuống 12.97.

Nói cách khác, chỉ riêng việc thay bộ tỉ lệ cắt đã làm bài toán huấn luyện nghiêng mạnh hơn về nhóm khuôn mặt rất nhỏ. Đó là lý do mô hình gốc với bộ 12 mức theo bài báo đã mạnh hơn mô hình gốc với bộ mặc định trong mã nguồn, đặc biệt ở chỉ số Hard AP.

5.3 Vì sao phần tăng thêm của mô hình cải tiến không còn lớn như trước

Khi bộ tỉ lệ cắt ban đầu đã đẩy nhiều mẫu về vùng khuôn mặt rất nhỏ, mô hình gốc đã nhận sẵn một phần lợi ích mà trước đây cơ chế cải tiến phải tự tạo ra. Nói cách khác, khoảng trống để cải thiện thêm trở nên nhỏ hơn.

Điều này giải thích đồng thời hai hiện tượng:

- mô hình gốc với bộ 12 mức theo bài báo mạnh hơn mô hình gốc với bộ mặc định trong mã nguồn;
- mô hình cải tiến vẫn tiếp tục tốt hơn mô hình gốc, nhưng phần chênh lệch tăng thêm không còn cách biệt quá lớn như khi bắt đầu từ bộ mặc định trong mã nguồn.

Vì vậy, kết quả thực nghiệm không cho thấy bộ 12 mức theo bài báo làm mô hình kém đi. Ngược lại, nó tạo ra một điểm xuất phát mạnh hơn cho mô hình gốc. Phần cải thiện còn lại của mô hình đề xuất chủ yếu đến từ việc tăng giám sát cho đúng nhóm khuôn mặt rất nhỏ mà bộ tỉ lệ cắt này vẫn còn khó xử lý tốt.

6 Kết luận

Từ các kết quả trên có thể rút ra ba nhận xét chính.

Thứ nhất, mô hình cải tiến tốt hơn mô hình gốc trong cả hai bộ tỉ lệ cắt vì nó đồng thời làm được hai việc: tăng tần suất xuất hiện của các trường hợp khó trong quá trình huấn luyện, và tăng mật độ anchor dương cho chính các trường hợp đó.

Thứ hai, phần tăng điểm không phân bố đều trên mọi loại mẫu mà tập trung rất rõ vào các khuôn mặt rất nhỏ trên tập Hard. Đây là bằng chứng cho thấy cải tiến đi đúng vào nút thắt của bài toán phát hiện khuôn mặt nhỏ.

Thứ ba, bộ 12 mức theo bài báo không làm mô hình yếu đi. Ngược lại, nó đã thiên sẵn về nhóm khuôn mặt rất nhỏ nên mô hình gốc cũng được hưởng lợi. Do đó, khi áp dụng thêm cơ chế cải tiến, mô hình vẫn tốt hơn mô hình gốc, nhưng biên độ tăng thêm sẽ bị thu hẹp hơn so với trường hợp khởi đầu từ bộ tỉ lệ cắt mặc định trong mã nguồn.

Tài liệu tham khảo

- [1] S. Z. Li and J. Wu, “Face detection,” in *Handbook of Face Recognition*, S. Z. Li and A. K. Jain, Eds., 2nd ed., Springer, 2011, pp. 277–301. DOI: 10.1007/978-0-85729-932-1_11
- [2] P. Viola and M. Jones, “Rapid object detection using a boosted cascade of simple features,” in *2001 IEEE Computer Society Conference on Computer Vision and Pattern Recognition*, 2001, pp. I-511–I-518. DOI: 10.1109/CVPR.2001.990517
- [3] P. Viola and M. Jones, “Robust real-time face detection,” *International Journal of Computer Vision*, vol. 57, no. 2, pp. 137–154, 2004. DOI: 10.1023/B:VISI.0000013087.49260.fb
- [4] OpenCV Team. “Opencv cascade classifier documentation,” Accessed: Feb. 27, 2026. [Online]. Available: https://docs.opencv.org/4.x/db/d28/tutorial_cascade_classifier.html
- [5] S. Ren, K. He, R. Girshick, and J. Sun, “Faster r-cnn: Towards real-time object detection with region proposal networks,” in *Advances in Neural Information Processing Systems*, vol. 28, 2015. Accessed: Feb. 26, 2026. [Online]. Available: <https://arxiv.org/abs/1506.01497>
- [6] T.-Y. Lin, P. Goyal, R. Girshick, K. He, and P. Dollar, “Focal loss for dense object detection,” in *2017 IEEE International Conference on Computer Vision*, 2017, pp. 2999–3007. DOI: 10.1109/ICCV.2017.324
- [7] C. Huang, H. Ai, Y. Li, and S. Lao, “High-performance rotation invariant multiview face detection,” *IEEE Transactions on Pattern Analysis and Machine Intelligence*, vol. 29, no. 4, pp. 671–686, 2007. DOI: 10.1109/TPAMI.2007.1011
- [8] G. Bradski, “The opencv library,” *Dr. Dobb’s Journal of Software Tools*, 2000.
- [9] S. Yang, P. Luo, C. C. Loy, and X. Tang, “Wider face: A face detection benchmark,” in *2016 IEEE Conference on Computer Vision and Pattern Recognition (CVPR)*, 2016, pp. 5525–5533. DOI: 10.1109/CVPR.2016.596
- [10] Hugging Face Datasets. “Cuhk-cse/wider_face dataset mirror,” Accessed: Feb. 27, 2026. [Online]. Available: https://huggingface.co/datasets/CUHK-CSE/wider_face
- [11] S. C. Brubaker, J. Wu, J. Sun, M. D. Mullin, and J. M. Rehg, “On the design of cascades of boosted ensembles for face detection,” *International Journal of Computer Vision*, vol. 77, no. 1-3, pp. 65–86, 2008. DOI: 10.1007/s11263-007-0084-7
- [12] S. Z. Li and Z.-Q. Zhang, “Floatboost learning and statistical face detection,” *IEEE Transactions on Pattern Analysis and Machine Intelligence*, vol. 26, no. 9, pp. 1112–1123, 2004. DOI: 10.1109/TPAMI.2004.64
- [13] J. Wu, S. C. Brubaker, M. D. Mullin, and J. M. Rehg, “Fast asymmetric learning for cascade face detection,” *IEEE Transactions on Pattern Analysis and Machine Intelligence*, vol. 30, no. 3, pp. 369–382, 2008. DOI: 10.1109/TPAMI.2007.70766
- [14] N. Dalal and B. Triggs, “Histograms of oriented gradients for human detection,” in *CVPR*, 2005.
- [15] P. Dollár, Z. Tu, P. Perona, and S. Belongie, “Integral channel features,” *BMVC*, 2009.
- [16] B. Zhang and et al., “Local derivative pattern device for face recognition,” *IEEE Transactions on Image Processing*, 2010.
- [17] J. Wu, M. Brubaker, M. Mullin, and J. Rehg, “Fast asymmetric learning for cascade face detection,” in *IEEE Transactions on Pattern Analysis and Machine Intelligence*, 2004.

- [18] J. Friedman, T. Hastie, and R. Tibshirani, “Additive logistic regression: A statistical view of boosting,” *The Annals of Statistics*, vol. 28, no. 2, pp. 337–407, 2000.
- [19] H. Masnadi-Shirazi and N. Vasconcelos, “On the design of loss functions for classification: Theory, algorithms and applications,” *IEEE Transactions on Pattern Analysis and Machine Intelligence*, 2010.
- [20] J. Sochman and J. Matas, “Waldboost-learning for time constrained sequential detection,” in *CVPR*, 2005.
- [21] A. Torralba, K. P. Murphy, and W. T. Freeman, “Sharing visual features for multiclass object detection,” *IEEE Transactions on Pattern Analysis and Machine Intelligence*, 2007.
- [22] J. Guo, J. Deng, A. Lattas, and S. Zafeiriou, “Sample and computation redistribution for efficient face detection,” in *International Conference on Learning Representations (ICLR)*, 2022. Accessed: Feb. 25, 2026. [Online]. Available: <https://openreview.net/forum?id=RhB1AdoFfGE>
- [23] R. Girshick, J. Donahue, T. Darrell, and J. Malik, “Rich feature hierarchies for accurate object detection and semantic segmentation,” *arXiv preprint arXiv:1311.2524*, 2014. Accessed: Feb. 26, 2026. [Online]. Available: <https://arxiv.org/abs/1311.2524>
- [24] R. Girshick, “Fast r-cnn,” in *2015 IEEE International Conference on Computer Vision*, 2015, pp. 1440–1448. DOI: 10.1109/ICCV.2015.169
- [25] W. Liu et al., “Ssd: Single shot multibox detector,” *arXiv preprint arXiv:1512.02325*, 2016. Accessed: Feb. 26, 2026. [Online]. Available: <https://arxiv.org/abs/1512.02325>
- [26] J. Redmon, S. Divvala, R. Girshick, and A. Farhadi, “You only look once: Unified, real-time object detection,” in *2016 IEEE Conference on Computer Vision and Pattern Recognition (CVPR)*, 2016, pp. 779–788. DOI: 10.1109/CVPR.2016.91
- [27] J. Deng, J. Guo, Y. Zhou, J. Yu, I. Kotsia, and S. Zafeiriou, “Retinaface: Single-shot multi-level face localisation in the wild,” *arXiv preprint arXiv:1905.00641*, 2020. Accessed: Feb. 26, 2026. [Online]. Available: <https://arxiv.org/abs/1905.00641>
- [28] J. Mellor, J. Turner, A. Storkey, and E. J. Crowder, “Neural architecture search without training,” in *International Conference on Machine Learning (ICML)*, PMLR, 2021, pp. 7588–7598.