TRƯỜNG ĐẠI HỌC KHOA HỌC TỰ NHIÊN, ĐHQG-HCM
KHOA CÔNG NGHỆ THÔNG TIN

BÁO CÁO MÔN HỌC

Môn học: Nhận dạng mẫu
Lớp: 23TGMT

Giảng viên hướng dẫn: Võ Thanh Lâm
Lê Hoàng Thái
Nguyễn Thanh Tình

Sinh viên: Trương Quốc Cường – 23127333
Lê Anh Duy – 23127011
Trần Gia Huy – 23127199

TP. Hồ Chí Minh, 2026

Lời mở đầu

Mẫu báo cáo này được chuẩn bị cho viết học thuật bằng LaTeX. Tài liệu bao gồm trang bìa, mục lục, danh mục hình và bảng, danh mục thuật ngữ/chữ viết tắt, cùng quy trình tài liệu tham khảo với XeLaTeX và Biber.

Thông tin chung

- **Tên báo cáo:** (điền tên báo cáo)
- **Học phần / Đơn vị:** (điền tên học phần hoặc đơn vị)
- **Nhóm trưởng:** Trương Quốc Cường (23127333)
- **Thành viên nhóm:** Lê Anh Duy (23127011), Trần Gia Huy (23127199)
- **Chương sách được chọn:** *Handbook of Face Recognition* (2nd Edition), chương *Face Detection*, trang 277–301, tác giả chương Stan Z. Li và Jianxin Wu.
- **Thông tin bài báo phân tích:** *Sample and Computation Redistribution for Efficient Face Detection*, hội nghị ICLR 2022, tác giả Jia Guo, Jiankang Deng, Alexandros Lattas, Stefanos Zafeiriou.
- **Mục tiêu:** Báo cáo giữa kỳ tập trung vào hiểu khung phát hiện ba bước, tái lập detector Viola–Jones theo ví dụ chương sách, và phân tích phương pháp SCRFD theo bài báo gốc.
- **Phạm vi:** Không tái tạo toàn bộ pha tìm kiếm NAS do giới hạn tài nguyên tính toán; phần đối chiếu SCRFD dựa trên số liệu công bố trong bài báo; phần minh họa triển khai mở rộng sẽ dùng mô hình có sẵn ở giai đoạn báo cáo cuối kỳ.
- **Công cụ / Môi trường:** XeLaTeX + Biber cho báo cáo; Python và OpenCV cho tái lập detector cổ điển; nguồn dữ liệu gồm hình ví dụ trong chương sách và WIDER FACE validation.

Sau khi hoàn tất thông tin trên, tiếp tục triển khai nội dung chính theo cấu trúc chương/mục của báo cáo.

Mục lục

Lời mở đầu **1**

Thông tin chung **2**

Danh mục hình **4**

Danh sách hình ảnh đã sử dụng **5**

Danh mục bảng **6**

Thuật ngữ và chữ viết tắt **7**

I PHÂN TÍCH CHƯƠNG SÁCH: PHÁT HIỆN KHUÔN MẶT CỔ ĐIỂN **9**

1 Giới thiệu và động lực 9
2 Các công trình liên quan và kiến thức nền 9
3 Phương pháp / Kỹ thuật cốt lõi 10
4 Phân tích kết quả trong chương sách 24
5 Minh họa cài đặt của nhóm 26
6 Thảo luận phản biện 30
7 Kết luận 31

II PHÂN TÍCH BÀI BÁO: SCRFD (ICLR 2022) **32**

1 Giới thiệu và động lực 32
2 Các công trình liên quan và kiến thức nền 32
3 Phương pháp bài báo đề xuất 34
4 Phân tích thực nghiệm 37
5 Minh họa cài đặt (để ở báo cáo cuối kỳ) 37
6 Thảo luận phản biện 38
7 Kết luận 39

Tài liệu tham khảo **40**

Danh mục hình

I.1 Luồng cài đặt detector cổ điển theo kiểu tháp ảnh, quét cửa sổ trượt, cascade và gom cụm hộp bao. 12
I.2 Fig. 11.10 trong chương sách: minh họa của cấu trúc phát hiện khuôn mặt ở đa góc nhìn. Nguồn Huang et al. [7] 23
I.3 Fig. 11.14 trong chương sách: kết quả phát hiện khuôn mặt chính diện bằng hộp trắng. 24
I.4 Fig. 11.15 trong chương sách: kết quả phát hiện khuôn mặt đa góc nhìn trên bộ ảnh CMU. . . . 25
I.5 So sánh ví dụ trong sách và kết quả tái lập của nhóm trên cùng ảnh Fig. 11.14. 27
I.6 Đối chiếu kết quả đa góc nhìn: sách và tái lập trên cùng ảnh Fig. 11.15. 28
I.7 Kết quả tái lập theo định hướng đánh giá của mục 11.6 trong chương sách. 29
I.8 Phân tích hạn chế Viola–Jones trên một ảnh khó của WIDER FACE validation. 30

II.1 Quy trình phát hiện chuẩn dùng chung cho bộ phát hiện cổ điển và hiện đại. 33
II.2 Lộ trình tiến hóa từ phát hiện khuôn mặt thủ công đến SCRFD (nhánh một giai đoạn). 33
II.3 Minh họa kiến trúc nền SCRFD theo ba khối: Backbone, Neck và Head. 35
II.4 Quy trình tìm kiếm hai bước trong SCRFD để tái phân bổ tính toán. 35

Danh sách hình ảnh đã sử dụng

Mục này liệt kê các hình được chèn trực tiếp bằng `\includegraphics` và vị trí sử dụng trong tài liệu.

- `assets/HCMUS.png`: logo trường ở trang bìa (trong `cover.tex`).
- `figures/ch1_classical/book_fig1114_from_book.jpg`: ảnh Fig. 11.14 trích từ trang sách để phân tích kết quả trong Chương I.
- `figures/ch1_classical/book_fig1114_reproduce_cfgA.jpg`: kết quả tái lập Viola–Jones trên Fig. 11.14 với cấu hình A trong Chương I.
- `figures/ch1_classical/book_fig1114_reproduce_cfgB.jpg`: kết quả tái lập Viola–Jones trên Fig. 11.14 với cấu hình B trong Chương I.
- `figures/ch1_classical/book_fig1115_from_book.jpg`: ảnh Fig. 11.15 trích từ trang sách để phân tích đa góc nhìn trong Chương I.
- `figures/ch1_classical/book_fig1115_reproduce_best.jpg`: kết quả tái lập gần đúng Fig. 11.15 bằng cấu hình đa cascade trong Chương I.
- `figures/ch1_classical/sec116_roc_like_curve.png`: đồ thị ROC-like tái lập theo mục 11.6 trong Chương I.
- `figures/ch1_classical/sec116_subwindow_compare_curve.png`: đồ thị so sánh kích thước cửa sổ con theo mục 11.6 trong Chương I.
- `figures/ch1_classical/demo_step1_dense_candidates.jpg`: minh họa bước sinh ứng viên dày đặc trong Chương I.
- `figures/ch1_classical/demo_step2_step3_final.jpg`: minh họa đầu ra sau chấm điểm cascade và gom nhóm trong Chương I.
- `figures/ch1_classical/demo_tp_fp_fn_overlay.jpg`: minh họa đối chiếu TP, FP, FN trong Chương I.

Danh mục bảng

1 Chữ viết tắt dùng trong báo cáo 7
2 Đối chiếu thuật ngữ tiếng Việt - tiếng Anh 8

I.1 Kết quả tái lập cấu hình theo ba tài liệu [11], [12], [13] trên tập con 200 ảnh WIDER FACE validation. 29

II.1 So sánh phương pháp chương sách và SCRFD: cùng mục tiêu, khác cách hiện thực 39

Thuật ngữ và chữ viết tắt

A. Chữ viết tắt

Bảng 1: Chữ viết tắt dùng trong báo cáo

Viết tắt	**Nghĩa tiếng Việt**	**Mở rộng tiếng Anh**
AP	Độ chính xác trung bình	Average Precision
CR	Tái phân bổ tính toán	Computation Redistribution
SR	Tái phân bổ mẫu	Sample Redistribution
NMS	Loại bỏ không cực đại	Non-Maximum Suppression
CNN	Mạng nơ-ron tích chập	Convolutional Neural Network
R-CNN	Mạng nơ-ron tích chập theo vùng	Region-based Convolutional Neural Network
FPS	Số khung hình mỗi giây	Frames Per Second
FLOPs	Số phép toán dấu chấm động	Floating-Point Operations
ICLR	Hội nghị Quốc tế về Biểu diễn Học máy	International Conference on Learning Representations
LBP	Mẫu nhị phân cục bộ	Local Binary Pattern
SCRFD	Tái phân bổ mẫu và tính toán cho phát hiện khuôn mặt hiệu quả	Sample and Computation Redistribution for Efficient Face Detection

B. Bảng đối chiếu thuật ngữ dịch

Bảng 2: Đối chiếu thuật ngữ tiếng Việt - tiếng Anh

Thuật ngữ tiếng Việt (dùng trong báo cáo)	**Thuật ngữ tiếng Anh tương ứng**
Phát hiện khuôn mặt	Face detection
Khuôn mặt rất nhỏ	Tiny face
Điểm ảnh	Pixel
Mô hình cơ sở	Baseline
Quy trình phát hiện	Detection pipeline
Cửa sổ trượt	Sliding window
Mạng trục chính	Backbone
Cổ đặc trưng	Neck
Đầu dự đoán	Head
Phát hiện một giai đoạn	One-stage detection
Phát hiện hai giai đoạn	Two-stage detection
Dự đoán dày đặc	Dense prediction
Tăng cường dữ liệu theo tỉ lệ	Scale augmentation
Kiểm thử đa tỉ lệ	Multi-scale testing
Tập khó	Hard set
Dịch chuyển miền dữ liệu	Domain shift
Dương tính giả	False positive
Benchmark	Benchmark
Chưng cất tri thức	Distillation
Thích nghi miền dữ liệu	Domain adaptation

Chương I

PHÂN TÍCH CHƯƠNG SÁCH: PHÁT HIỆN KHUÔN MẶT CỔ ĐIỂN

1 Giới thiệu và động lực

Trong một hệ thống nhận dạng khuôn mặt hoàn chỉnh, phát hiện khuôn mặt là bước mở đầu của toàn bộ chuỗi xử lý. Trước khi chuẩn hóa hình học, trích xuất đặc trưng hay so khớp danh tính, hệ thống phải xác định đúng vị trí và phạm vi khuôn mặt trong ảnh hoặc trong khung hình video. Sai lệch ở bước này sẽ lan sang các bước sau và làm giảm hiệu năng toàn hệ thống.

Về bản chất, phát hiện khuôn mặt không chỉ là tìm một hình chữ nhật bao quanh khuôn mặt. Đây là bài toán phân loại mẫu trên không gian ảnh con, trong đó cần tách lớp có mặt và lớp không có mặt dưới biến thiên lớn về vị trí, tỉ lệ, góc nhìn, chiếu sáng, biểu cảm và che khuất. Không gian ảnh có số chiều cao, trong khi mẫu mặt chỉ chiếm tỉ lệ nhỏ và tạo thành một cấu trúc phi tuyến phức tạp. Do đó, bài toán khó đồng thời ở cả biểu diễn dữ liệu lẫn xây dựng ranh giới quyết định.

Các ứng dụng thực tế như giám sát, xác thực sinh trắc học và phân tích video còn đặt thêm ràng buộc thời gian thực. Vì vậy, bộ phát hiện phải cân bằng chặt giữa độ chính xác và hiệu quả tính toán.

Động lực của chương này là làm rõ vai trò nền tảng của phát hiện khuôn mặt trong hệ nhận dạng, xác định các thách thức cốt lõi theo góc nhìn hình học và thống kê, và hệ thống hóa các hướng giải bài toán từ mô hình dựa trên hình học đến mô hình dựa trên biểu diễn và học máy. Chương cũng đóng vai trò cầu nối giữa nền tảng học không gian con và phân loại mẫu ở các chương trước với hệ thống nhận dạng hoàn chỉnh ở các chương sau. [1]

2 Các công trình liên quan và kiến thức nền

Trong cấu trúc chung của cuốn sách, phát hiện khuôn mặt thuộc giai đoạn định vị khuôn mặt, đứng trước chuẩn hóa và trích xuất đặc trưng. Nếu các chương trước tập trung vào học không gian con, mô hình hóa đa tạp và bài toán nhiều chiều ít mẫu, thì chương này đưa các ý tưởng đó vào một tác vụ cụ thể là phân biệt ảnh con có mặt và ảnh con không có mặt.

Vì vậy, phần kiến thức nền cần nhấn mạnh bốn điểm chính. Thứ nhất, không gian ảnh là không gian nhiều chiều nên chi phí tìm kiếm và chi phí học đều lớn. Thứ hai, đa tạp khuôn mặt có tính phi tuyến nên biên quyết định khó mô hình hóa bằng giả thiết đơn giản. Thứ ba, bài toán phát hiện là phân loại nhị phân nhưng có mất cân bằng mẫu mạnh do nền áp đảo số lượng. Thứ tư, biến thiên nội lớp của khuôn mặt thường rất lớn dưới điều kiện ngoài tự nhiên.

Các hướng tiếp cận kinh điển có thể nhóm thành ba tuyến.

- **Tuyến dựa trên hình học.** Khai thác quan hệ hình học giữa các thành phần khuôn mặt như mắt, mũi và

miệng. Tuyến này trực quan và gọn nhẹ nhưng phụ thuộc mạnh vào chất lượng định vị các điểm đặc trưng.

- **Tuyến dựa trên biểu diễn.** Quy bài toán về phân loại các cửa sổ ảnh bằng đặc trưng toàn cục và cục bộ. Tuyến này đánh dấu bước chuyển sang mô hình hóa thống kê.
- **Tuyến dựa trên học máy và phân tầng loại nhanh.** Học bộ phân loại từ dữ liệu và tổ chức theo nhiều tầng để loại sớm mẫu âm dễ, nhờ đó cải thiện đáng kể tốc độ suy luận.

Phát hiện khuôn mặt và nhận dạng khuôn mặt có quan hệ chặt nhưng mục tiêu khác nhau. Phát hiện khuôn mặt nhằm tách lớp có mặt và không có mặt trên không gian tìm kiếm rộng. Nhận dạng khuôn mặt nhằm phân biệt danh tính bên trong tập mẫu đã được định vị. Cả hai cùng chịu ảnh hưởng bởi tính phi tuyến của đa tạp khuôn mặt, biến thiên nội lớp lớn và khó khăn do dữ liệu nhiều chiều ít mẫu. Tuy nhiên, phát hiện khuôn mặt thường chịu ràng buộc tính toán nghiêm ngặt hơn do phải xử lý đồng thời định vị và phân loại trên toàn ảnh. [1]

3 Phương pháp / Kỹ thuật cốt lõi

3.1 Nguyên lý vận hành theo quy trình 3 bước

Chương sách đặt nền trên hướng tiếp cận dựa trên biểu diễn kết hợp học máy thống kê. Thay vì mô hình hóa hình học 3D phức tạp của khuôn mặt, hệ thống xem phát hiện khuôn mặt là bài toán phân loại nhị phân trên từng ảnh con, gồm lớp có khuôn mặt và lớp không có khuôn mặt. Trong khung này, quy trình vận hành được tổ chức thành ba bước chuẩn:

- **Bước 1, sinh ứng viên.** Tạo tập cửa sổ ứng viên dày đặc trên nhiều mức tỉ lệ ảnh để bao phủ không gian vị trí và kích thước khuôn mặt.
- **Bước 2, chấm điểm và định vị.** Dùng bộ phân loại học được để đánh giá từng cửa sổ và giữ lại các cửa sổ có khả năng chứa khuôn mặt.
- **Bước 3, khử trùng lặp.** Gom các phát hiện chồng lấp cao thành kết quả cuối cùng.

Khung ba bước này là điểm nối trực tiếp giữa detector cổ điển và detector hiện đại: mục tiêu theo giai đoạn giữ nguyên, còn cách hiện thực từng giai đoạn thay đổi theo công nghệ.

3.2 Kỹ thuật cốt lõi rút ra từ chương sách

Kỹ thuật cốt lõi là một **bộ phát hiện cascade tăng cường dựa trên biểu diễn**, gồm các thành phần chính:

- Đặc trưng cục bộ kiểu Haar và biến thể MB-LBP.
- Ảnh tích phân để tính nhanh tổng đặc trưng hình chữ nhật.
- AdaBoost để kết hợp nhiều bộ phân loại yếu thành bộ phân loại mạnh.
- Cấu trúc cascade để loại sớm mẫu âm ngay từ các trạm đầu.
- Hậu xử lý gom cụm để hợp nhất các hộp chồng lấp.

Theo trình bày của chương sách, chuỗi kỹ thuật này liên tục được mở rộng bằng các biến thể đặc trưng và boosting như LBP, asymmetric boosting và vector boosting để tăng hiệu năng trong điều kiện thực tế khó hơn, gồm khuôn mặt nghiêng, nhiều mặt chồng lấp và khuôn mặt kích thước nhỏ. [1]

Ở mức luồng tổng thể, sơ đồ có thể đọc thành bốn khối xử lý liên tiếp:

- **Khối quét không gian.** Cửa sổ trượt đi qua toàn bộ ảnh và nhiều mức tỉ lệ trong tháp ảnh.

- **Khối trích xuất đặc trưng.** Đặc trưng Haar-like hoặc MB-LBP được tính nhanh bằng ảnh tích phân.
- **Khối học và ra quyết định.** AdaBoost học bộ phân loại mạnh từ các bộ phân loại yếu; biến thể bất đối xứng giúp ưu tiên giảm bỏ sót khuôn mặt.
- **Khối tăng tốc và hậu xử lý.** Cascade loại sớm vùng nền, sau đó gom cụm hộp bao để tạo đầu ra ổn định.

Sơ đồ trong Hình I.1 biểu diễn đầy đủ luồng xử lý theo đúng tinh thần chương sách. Các mục 3.3 đến 3.7 sẽ đi chi tiết theo đúng từng khối trong sơ đồ.

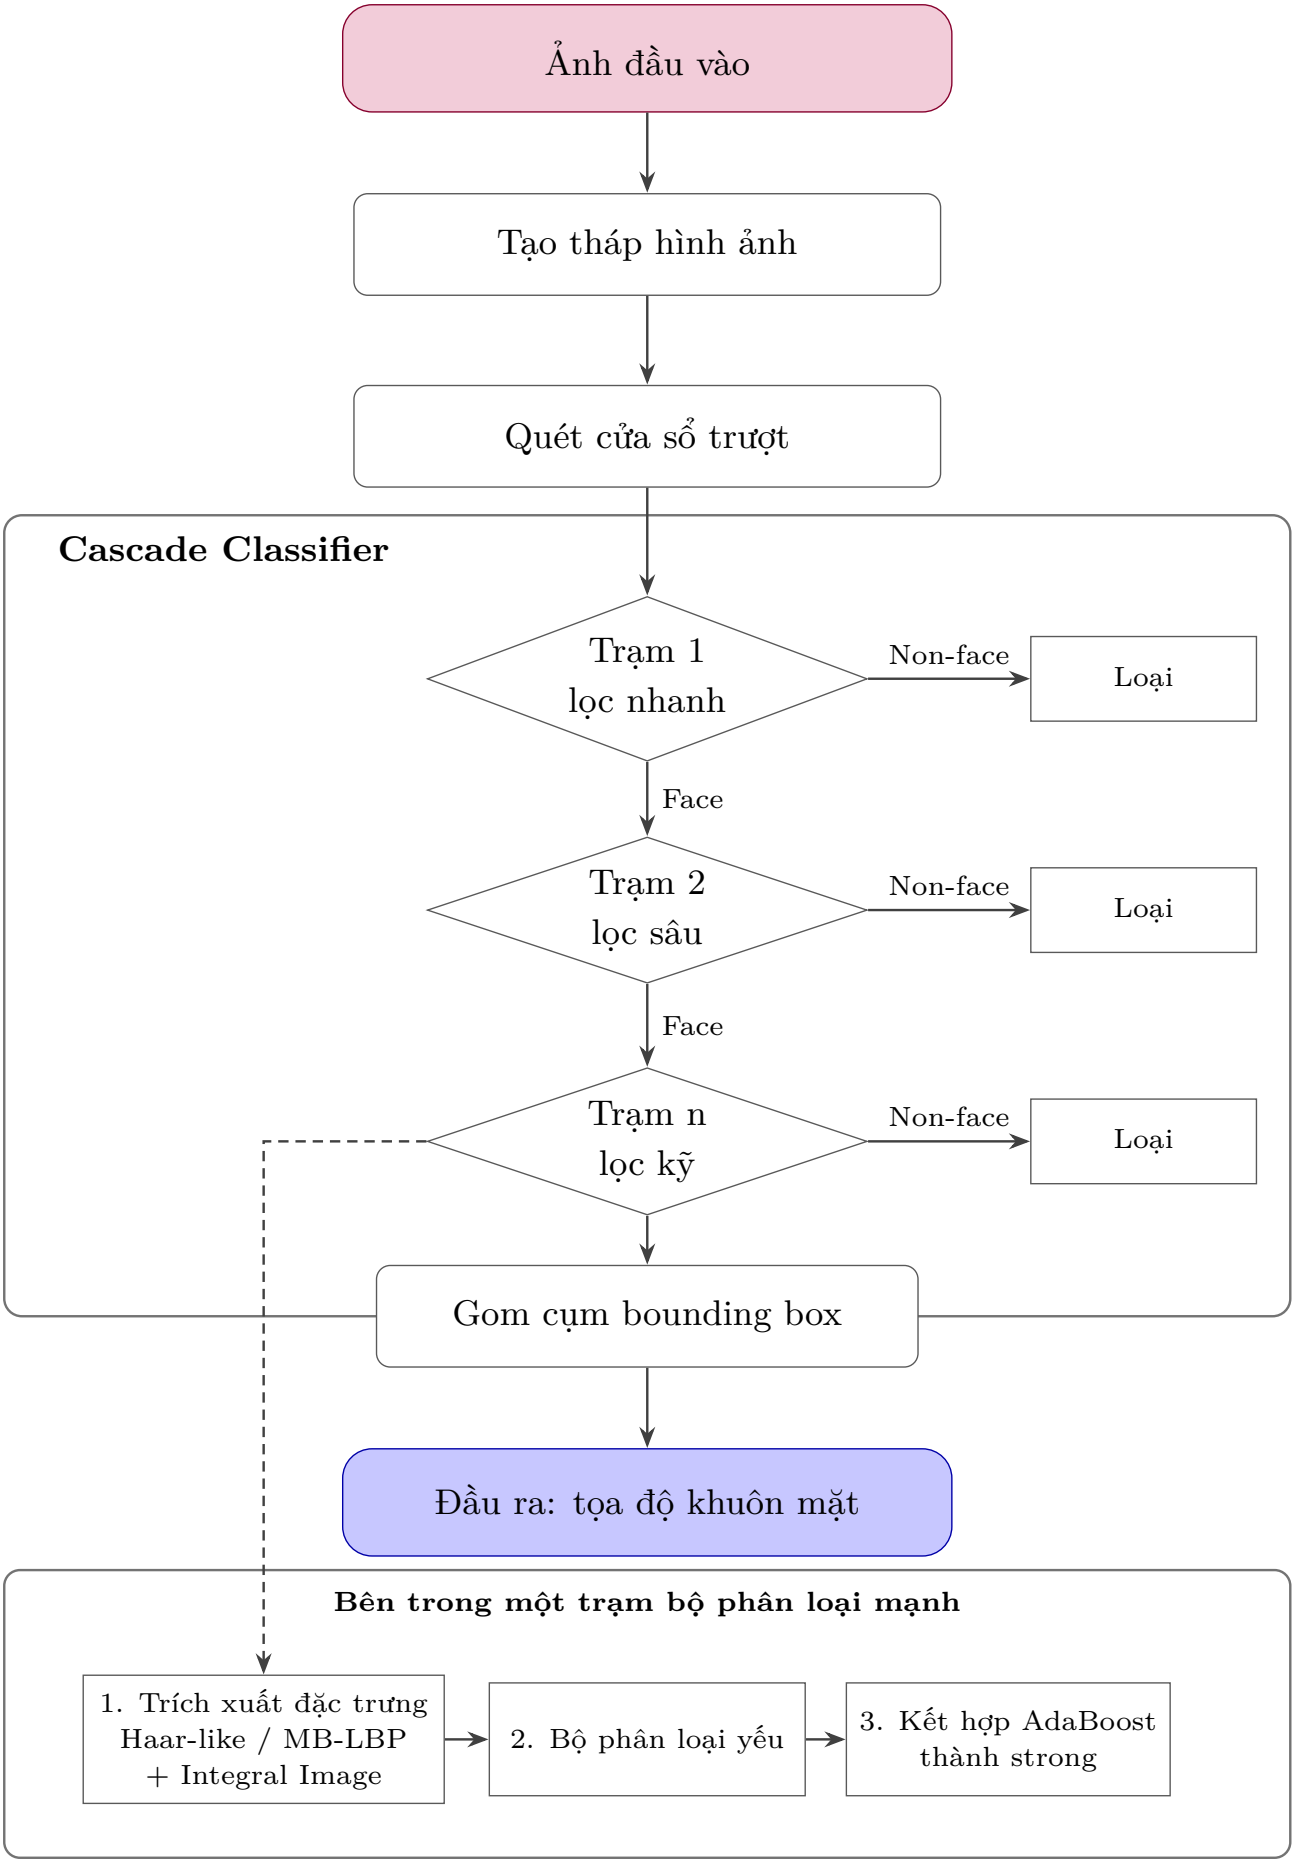

Hình I.1: Luồng cài đặt detector cổ điển theo kiểu tháp ảnh, quét cửa sổ trượt, cascade và gom cụm hộp bao.

3.3 Tạo tháp hình ảnh

3.3.1 Động cơ xử lý đa tỉ lệ trong phát hiện khuôn mặt

Trong bài toán phát hiện khuôn mặt, kích thước khuôn mặt thay đổi mạnh theo khoảng cách đến camera, tiêu cự và độ phân giải ảnh. Một bộ phân loại được huấn luyện trên cửa sổ cố định, ví dụ 24 nhân 24 điểm ảnh thường gặp trong họ phương pháp Viola–Jones, không thể áp trực tiếp cho mọi kích thước khuôn mặt trong ảnh. Trong chương sách, các ví dụ và so sánh cũng bàn đến nhiều kích thước cửa sổ con như 16 nhân 16 đến 32 nhân 32, cùng ví dụ 20 nhân 20 khi minh họa học ngưỡng. [1] Vấn đề kỹ thuật cốt lõi là giữ nguyên cấu trúc bộ phân loại nhưng vẫn bao phủ được nhiều tỉ lệ khuôn mặt trong cùng một lần suy luận. Giải pháp được dùng là tháp hình ảnh: thay đổi kích thước ảnh đầu vào theo nhiều mức, thay vì thay đổi kích thước bộ phân loại. [1], [2]

3.3.2 Nguyên lý xây dựng tháp hình ảnh

Gọi ảnh gốc là I_0 có kích thước $W_0 \times H_0$. Tạo chuỗi ảnh $\{I_k\}_{k=0}^{K}$ bằng phép co tỉ lệ với hệ số $s \in (0, 1)$:

$$I_k = \text{resize}(I_0, s^k)$$

trong đó k là chỉ số mức tháp và K là mức cuối sao cho kích thước ảnh vẫn đủ lớn để quét được cửa sổ chuẩn $w \times h$. Số mức tháp có thể ước lượng:

$$K \approx \left\lfloor \frac{\log\left(\min(W_0, H_0)/w\right)}{\log(1/s)} \right\rfloor$$

Mỗi mức tháp tương ứng một miền kích thước khuôn mặt khác nhau trong ảnh gốc. [1]

3.3.3 Vì sao resize ảnh thay vì resize cửa sổ

Có hai chiến lược xử lý đa tỉ lệ:

- Giữ ảnh cố định và thay đổi kích thước cửa sổ phân loại.
- Giữ cửa sổ phân loại cố định và thay đổi kích thước ảnh.

Viola–Jones chọn chiến lược thứ hai vì cửa sổ cố định cho phép dùng lại cùng bộ phân loại, giữ nguyên định nghĩa đặc trưng Haar trên lưới chuẩn và giữ pipeline thống nhất. Ảnh tích phân được tính riêng cho từng mức tháp với chi phí tuyến tính theo số điểm ảnh của mức đó, nên vẫn phù hợp cho xử lý thời gian thực ở thời điểm đề xuất. [2], [3]

3.3.4 Phân tích độ phức tạp tính toán

Ở mức k, ảnh có kích thước $W_k \times H_k$. Bỏ qua bước nhảy stride để xấp xỉ, số cửa sổ ứng viên:

$$N_k \approx (W_k - w)(H_k - h)$$

Tổng số cửa sổ trên toàn bộ tháp:

$$N_{\text{total}} = \sum_{k=0}^{K} (W_k - w)(H_k - h)$$

Với ảnh VGA 640 nhân 480 và cửa sổ 24 nhân 24, số ứng viên có thể tăng lên rất lớn. Điều này lý giải vì sao tháp ảnh phải đi cùng cơ chế loại nhanh để kiểm soát chi phí suy luận. [1]

3.3.5 Ảnh hưởng của hệ số tỉ lệ s

Hệ số s điều khiển trực tiếp đánh đổi giữa độ phủ tỉ lệ và tốc độ xử lý:

- s gần 1, ví dụ 0.95: nhiều mức tháp hơn, độ phủ tốt hơn, chi phí cao hơn.
- s nhỏ hơn, ví dụ 0.8: ít mức tháp hơn, suy luận nhanh hơn, nhưng có nguy cơ bỏ sót kích thước trung gian.

Vì vậy lựa chọn s là tham số nhạy với cả recall và độ trễ.

3.3.6 Quan hệ với mất cân bằng lớp

Phần lớn cửa sổ sinh ra từ tháp ảnh là nền không phải khuôn mặt. Khi số mức tháp tăng, số mẫu âm tăng rất nhanh, làm áp lực lọc mẫu dồn lên các trạm đầu của cascade. Do đó thiết kế tháp ảnh không tách rời khỏi thiết kế cascade nếu muốn giữ khả năng chạy gần thời gian thực.

3.3.7 Giới hạn của tháp hình ảnh cổ điển

Tháp hình ảnh đơn giản và hiệu quả, nhưng có ba giới hạn rõ:

- Chi phí tăng mạnh khi độ phân giải ảnh đầu vào tăng.
- Khó bao phủ tốt khuôn mặt cực nhỏ nếu nhỏ hơn ngưỡng cửa sổ tối thiểu.
- Không khai thác trực tiếp biểu diễn đa mức nội tại như feature pyramid trong kiến trúc học sâu hiện đại.

3.3.8 Kết luận

Tháp hình ảnh là cơ chế đa tỉ lệ cốt lõi trong pipeline Viola–Jones. Bằng cách co ảnh theo chuỗi tỉ lệ cố định và quét một cửa sổ chuẩn trên từng mức, hệ thống có thể phát hiện khuôn mặt ở nhiều kích thước mà không cần thay đổi bộ phân loại. Chi phí ứng viên tăng đáng kể, nhưng khi kết hợp với đặc trưng tính nhanh bằng ảnh tích phân và cơ chế cascade loại sớm, toàn hệ thống vẫn đạt hiệu năng thực dụng cho bối cảnh triển khai cổ điển. [1], [2], [3]

3.4 Quét cửa sổ trượt

3.4.1 Vai trò của bước quét cửa sổ trong pipeline

Sau khi xây dựng tháp hình ảnh để xử lý đa tỉ lệ, bước tiếp theo trong pipeline là quét cửa sổ trượt trên từng mức tháp. Mục tiêu của bước này là sinh ứng viên một cách có hệ thống, bao phủ toàn bộ không gian tìm kiếm và giảm nguy cơ bỏ sót vùng có khả năng chứa khuôn mặt ở giai đoạn đầu. Trong nhóm phương pháp cổ điển, đây là chiến lược vét cạn có kiểm soát. [1], [2]

3.4.2 Cơ chế hoạt động

Tại mỗi mức tháp I_k có kích thước $W_k \times H_k$, hệ thống dùng cửa sổ phân loại cố định $w \times h$, thường là 24 nhân 24 điểm ảnh. Cửa sổ được dịch chuyển tuần tự trên lưới tọa độ:

$$x = 0, 1, 2, \ldots, W_k - w, \qquad y = 0, 1, 2, \ldots, H_k - h$$

Tại mỗi vị trí (x, y), vùng ảnh con

$$R_{k,x,y} = I_k[x : x + w - 1,\ y : y + h - 1]$$

được đưa vào bộ phân loại để quyết định nhãn khuôn mặt hoặc nền.

3.4.3 Bước nhảy stride và độ phủ không gian

Trong thực tế, cửa sổ không nhất thiết dịch chuyển từng điểm ảnh. Gọi Δ là bước nhảy:

$$x = 0, \Delta, 2\Delta, \ldots, \qquad y = 0, \Delta, 2\Delta, \ldots$$

- Stride nhỏ: độ phủ mịn hơn, recall cao hơn, chi phí tính toán tăng.
- Stride lớn: nhanh hơn, nhưng dễ bỏ sót khuôn mặt nhỏ hoặc gần biên.

Trong triển khai thực tế của detector cổ điển, stride thường được đặt nhỏ để giữ độ phủ cao.

3.4.4 Phân tích số lượng cửa sổ ứng viên

Tại mức tháp k, số cửa sổ ứng viên xấp xỉ:

$$N_k \approx \left\lfloor \frac{W_k - w}{\Delta} \right\rfloor \cdot \left\lfloor \frac{H_k - h}{\Delta} \right\rfloor$$

Tổng số cửa sổ trên toàn tháp:

$$N_{\text{total}} = \sum_{k=0}^{K} \left(\left\lfloor \frac{W_k - w}{\Delta} \right\rfloor \cdot \left\lfloor \frac{H_k - h}{\Delta} \right\rfloor \right)$$

Với ảnh VGA 640 nhân 480, $w = h = 24$ và $\Delta = 1$, số cửa sổ có thể vượt 200 nghìn trên một ảnh. Điều này cho thấy bước quét cửa sổ là nguồn sinh ứng viên rất lớn và bắt buộc phải đi cùng cơ chế loại nhanh. [1]

3.4.5 Đặc điểm của chiến lược vét cạn

Sliding window có các đặc điểm:

- Không giả định trước vị trí khuôn mặt.
- Không phụ thuộc heuristic bối cảnh.
- Bao phủ toàn bộ không gian tìm kiếm.

Ưu điểm là đơn giản và khó bỏ sót nếu stride và scale đủ mịn. Nhược điểm là chi phí cao, số mẫu âm rất lớn và phụ thuộc mạnh vào năng lực bộ phân loại.

3.4.6 Tương quan với mất cân bằng lớp

Trong ảnh tự nhiên, phần lớn cửa sổ ứng viên là nền. Tỉ lệ âm trên dương có thể rất cao, nên:

- Trạm đầu cần false positive rate thấp để chặn sớm cửa sổ âm.
- Cascade được dùng để giảm chi phí trung bình trên mỗi cửa sổ.
- Boosting được dùng để chọn đặc trưng có sức phân biệt cao.

Vì vậy sliding window trực tiếp tạo ra một bài toán phân loại nhị phân mất cân bằng mạnh, và kiến trúc Viola–Jones được tổ chức xoay quanh đúng đặc điểm này. [2], [3]

3.4.7 Giới hạn của phương pháp quét cửa sổ

Mặc dù đảm bảo độ phủ, quét cửa sổ có các giới hạn:

- Chi phí tăng theo độ phân giải ảnh.
- Không khai thác cấu trúc ngữ cảnh của cảnh.
- Không tận dụng tính liên tục thời gian nếu xử lý từng khung hình độc lập.
- Không tối ưu cho khuôn mặt rất nhỏ khi cửa sổ tối thiểu còn lớn.

Trong phạm vi chương sách, đây là một giới hạn được xử lý bằng thiết kế cascade và tối ưu đặc trưng tính nhanh, hơn là thay khung phát hiện bằng kiến trúc mới.

3.4.8 Kết luận

Quét cửa sổ trượt là cơ chế sinh ứng viên cốt lõi trong pipeline Viola–Jones. Khi kết hợp với tháp hình ảnh, hệ thống có thể bao phủ nhiều vị trí và tỉ lệ khuôn mặt. Chi phí tiềm ẩn rất lớn, nhưng cascade classifier ở bước sau sẽ loại nhanh phần lớn cửa sổ âm để giữ tốc độ suy luận ở mức thực dụng. [1], [2], [3]

3.5 Cascade classifier

3.5.1 Động cơ thiết kế: xử lý mất cân bằng lớp cực đoan

Sau bước tháp hình ảnh và quét cửa sổ trượt, hệ thống sinh ra số lượng rất lớn cửa sổ ứng viên. Trong thực tế, phần lớn cửa sổ là nền và chỉ một tỉ lệ rất nhỏ thực sự chứa khuôn mặt. Đây là bài toán phân loại nhị phân với mất cân bằng lớp rất mạnh:

$$P(\text{non-face}) \gg P(\text{face})$$

Nếu dùng một bộ phân loại phức tạp duy nhất cho mọi cửa sổ, chi phí trung bình sẽ rất cao vì đa số cửa sổ đều là âm. Cascade classifier được đề xuất để xử lý trực tiếp đặc điểm này. [2], [3]

3.5.2 Cấu trúc phân tầng

Cascade classifier là một chuỗi các bộ phân loại mạnh được sắp nối tiếp:

$$\text{Stage}_1 \to \text{Stage}_2 \to \cdots \to \text{Stage}_N$$

Chương sách mô tả cơ chế này theo logic chuỗi dạng AND giữa các trạm mạnh, đồng thời thảo luận thêm biến thể soft-cascade theo hướng nhiều điểm thoát sớm để giảm thời gian kiểm tra. [1] Nguyên tắc vận hành:

- Nếu cửa sổ bị phân loại âm ở bất kỳ trạm nào thì dừng ngay.
- Chỉ cửa sổ vượt qua toàn bộ các trạm mới được xem là khuôn mặt.

Vì vậy cascade thực hiện dãy kiểm tra ngày càng khắt khe, với cơ chế loại sớm cho mẫu âm.

3.5.3 Phân tích hiệu năng theo từng stage

Gọi d_i là tỉ lệ phát hiện của stage i, và f_i là tỉ lệ báo động giả của stage i. Khi ghép nối tiếp N stage, hiệu năng tổng thể là:

$$D = \prod_{i=1}^{N} d_i, \qquad F = \prod_{i=1}^{N} f_i$$

trong đó D là tỉ lệ phát hiện tổng thể và F là tỉ lệ báo động giả tổng thể.

Ví dụ, nếu mỗi stage có $d_i = 0.99$ và $f_i = 0.5$, với 20 stage:

$$D \approx 0.99^{20} \approx 0.82, \qquad F \approx 0.5^{20} \approx 10^{-6}$$

Tỉ lệ báo động giả giảm theo cấp số nhân, trong khi tỉ lệ phát hiện giảm chậm hơn, tạo nên hiệu quả đặc trưng của cascade. [2]

3.5.4 Chi phí tính toán kỳ vọng

Gọi C_i là chi phí đánh giá stage i. Xác suất một cửa sổ đi tới stage i:

$$P(\text{survive to } i) = \prod_{j=1}^{i-1} f_j$$

Chi phí kỳ vọng trên một cửa sổ:

$$\mathbb{E}[C] = \sum_{i=1}^{N} \left(\prod_{j=1}^{i-1} f_j \right) C_i$$

Vì $f_j < 1$, số cửa sổ giảm nhanh theo từng stage. Do đó đa số cửa sổ bị loại ở trạm đầu và chi phí trung bình thấp hơn nhiều so với cách dùng một bộ phân loại đầy đủ cho mọi cửa sổ. Cascade vì vậy tối ưu chi phí kỳ vọng, không chỉ tối ưu độ chính xác. [1], [2]

3.5.5 Thiết kế từng stage

Mỗi stage thường tuân theo nguyên tắc:

- Stage đầu đơn giản, dùng ít đặc trưng, chi phí rất thấp.
- Stage sau phức tạp hơn, dùng nhiều đặc trưng để tăng độ phân biệt.

Trong thực hành, stage đầu có thể chỉ vài bộ phân loại yếu, còn stage sau có thể dùng nhiều hơn đáng kể. Cách phân bổ độ phức tạp theo tầng giúp tối ưu đánh đổi giữa tốc độ và độ chính xác.

3.5.6 Tối ưu từng stage trong huấn luyện

Huấn luyện cascade thường theo chuỗi:

- Huấn luyện stage i để đạt ngưỡng tỉ lệ phát hiện tối thiểu và tỉ lệ báo động giả mục tiêu.
- Dùng stage đã học để loại bỏ mẫu âm dễ.
- Huấn luyện stage $i + 1$ trên tập còn lại khó hơn.

Quá trình lặp lại đến khi tỉ lệ báo động giả toàn hệ thống đạt mục tiêu thiết kế. [2], [3]

3.5.7 Quan hệ giữa cascade và đặc trưng tính nhanh

Cascade chỉ thật sự hiệu quả khi chi phí đánh giá đặc trưng ở mỗi cửa sổ đủ thấp. Vì vậy ảnh tích phân và đặc trưng Haar là điều kiện thiết kế đi kèm: đặc trưng phải tính nhanh, bộ phân loại yếu phải đơn giản, rồi mới khai thác được lợi ích loại sớm của cascade. Nếu đặc trưng tính chậm, cascade sẽ mất lợi thế tốc độ.

3.5.8 Đánh giá tổng hợp: ưu điểm và hạn chế

Ưu điểm

- Tối ưu chi phí trung bình trên mỗi cửa sổ bằng cơ chế loại sớm.
- Phù hợp tự nhiên với mất cân bằng lớp rất lớn trong detection.
- Có thể đạt tốc độ gần thời gian thực trên phần cứng phổ thông.
- Dễ mở rộng theo mục tiêu giảm báo động giả bằng cách tăng số stage.

Hạn chế

- Phụ thuộc vào thứ tự và chất lượng stage đầu.
- Nếu stage đầu quá khắt khe, recall giảm đáng kể.
- Huấn luyện mang tính tuần tự nên khó tối ưu toàn cục.
- Khó khai thác ngữ cảnh không gian rộng như các mô hình CNN hiện đại.

3.5.9 Kết luận

Cascade classifier là lõi tối ưu tốc độ của phương pháp Viola–Jones. Bằng cách tổ chức nhiều bộ phân loại mạnh thành chuỗi và loại sớm các cửa sổ âm, cascade giảm mạnh chi phí tính toán trung bình trong khi vẫn duy trì tỉ lệ phát hiện cao. Thiết kế này giải quyết trực diện bài toán mất cân bằng lớp trong phát hiện khuôn mặt và là một đóng góp quan trọng bậc nhất của hướng cổ điển. [1], [2], [3]

3.6 Bộ phân loại mạnh trong từng trạm

Trong cấu trúc cascade, mỗi stage không phải là một phép kiểm tra đơn lẻ, mà là một bộ phân loại mạnh được xây dựng từ nhiều bộ phân loại yếu bằng AdaBoost. Mục này làm rõ ba thành phần nền tảng:

- Đặc trưng Haar-like.
- Integral image để tính đặc trưng nhanh.
- AdaBoost để chọn và kết hợp đặc trưng.

3.6.1 Không gian đặc trưng và động cơ chọn đặc trưng Haar

Trong cửa sổ 24 nhân 24 có 576 giá trị cường độ. Nếu dùng trực tiếp vector điểm ảnh thô, biểu diễn thường kém ổn định trước thay đổi chiếu sáng, khó nhấn mạnh cấu trúc khuôn mặt và tốn chi phí tính toán. Viola–Jones thay biểu diễn thô bằng đặc trưng Haar-like, là hiệu giữa tổng cường độ của các vùng chữ nhật. Các mẫu điển hình gồm hai vùng, ba vùng và bốn vùng, giúp phản ánh tương phản cục bộ như mắt, sống mũi và má. Các tương phản điển hình gồm vùng mắt tối hơn vùng má và sống mũi sáng hơn vùng hai bên. Không gian đặc trưng khả dĩ trong một cửa sổ chuẩn là rất lớn, nên bắt buộc phải có cơ chế chọn đặc trưng hiệu quả. [2], [3]

3.6.2 Integral Image: tính đặc trưng trong thời gian hằng

Cho ảnh $I(x, y)$, ảnh tích phân được định nghĩa:

$$II(x, y) = \sum_{x' \leq x,\ y' \leq y} I(x', y')$$

Có thể tính theo một lượt quét bằng hai công thức đệ quy:

$$S(x,y) = S(x,y-1) + I(x,y), \qquad II(x,y) = II(x-1,y) + S(x,y)$$

Tổng cường độ trên vùng chữ nhật có góc trên trái (x_1, y_1) và dưới phải (x_2, y_2):

$$\text{Sum} = II(x_2,y_2) - II(x_1-1,y_2) - II(x_2,y_1-1) + II(x_1-1,y_1-1)$$

Nhờ đó, mỗi tổng vùng chỉ cần bốn phép truy xuất mảng, đạt độ phức tạp hằng số $O(1)$. [2]

3.6.3 Bộ phân loại yếu

Mỗi đặc trưng $z_k(x)$ tạo một bộ phân loại yếu dạng decision stump:

$$h(x;k,\tau,p) = \begin{cases} +1, & p\,z_k(x) < p\,\tau \\ -1, & \text{ngược lại} \end{cases}$$

trong đó k là chỉ số đặc trưng, τ là ngưỡng và $p \in \{+1,-1\}$ là cực tính. Mỗi bộ phân loại yếu chỉ dựa vào một đặc trưng nên năng lực phân biệt còn hạn chế.

3.6.4 AdaBoost: Xây dựng bộ phân loại mạnh

Với tập huấn luyện $\{(x_i,y_i)\}_{i=1}^N$, $y_i \in \{-1,+1\}$, mục tiêu là học:

$$H(x) = \text{sign}\left(\sum_{m=1}^{M} \alpha_m h_m(x)\right)$$

Quy trình AdaBoost chuẩn

- Khởi tạo trọng số mẫu $w_i^{(1)} = \frac{1}{N}$.
- Với mỗi vòng $m = 1,\dots,M$:
  - Huấn luyện bộ phân loại yếu h_m để tối thiểu hóa sai số có trọng số:

$$\epsilon_m = \sum_{i=1}^{N} w_i^{(m)}\,\mathbf{1}[h_m(x_i) \neq y_i]$$

  - Tính hệ số tin cậy:

$$\alpha_m = \frac{1}{2}\ln\left(\frac{1-\epsilon_m}{\epsilon_m}\right)$$

  - Cập nhật trọng số:

$$w_i^{(m+1)} = w_i^{(m)} \exp\big(-\alpha_m y_i h_m(x_i)\big)$$

  - Chuẩn hóa lại tổng trọng số.

3.6.5 Diễn giải hình học của AdaBoost

AdaBoost có thể nhìn như tối ưu hóa hàm mất mát mũ, tăng biên phân loại và thực hiện chọn đặc trưng tự động. Mỗi vòng lặp chọn đặc trưng có sức phân biệt tốt nhất trong không gian đặc trưng lớn, tăng trọng số cho mẫu khó và giảm trọng số cho mẫu đã phân loại đúng. Vì vậy AdaBoost đồng thời giải quyết ba việc trong một khung chung: chọn đặc trưng, huấn luyện bộ phân loại và tối ưu trọng số kết hợp.

3.6.6 Quan hệ giữa AdaBoost và Cascade

Trong cascade, mỗi trạm là một bộ phân loại mạnh. Các trạm đầu thường dùng ít bộ phân loại yếu để xử lý nhanh, các trạm sau dùng nhiều hơn để tăng độ chính xác. Huấn luyện thường theo trình tự: huấn luyện trạm trước, loại bỏ mẫu âm dễ, rồi huấn luyện trạm sau trên tập còn lại. Thiết kế này tạo ra cơ chế tiết kiệm tính toán theo hướng loại sớm. [1], [2], [3]

3.6.7 Asymmetric Boosting (AsymBoost): Xử lý dữ liệu mất cân bằng

Trong phát hiện khuôn mặt, lượng cửa sổ nền (background) áp đảo hoàn toàn so với khuôn mặt, khiến mô hình dễ có xu hướng bỏ qua khuôn mặt. Để giải quyết, Viola & Jones phát triển **AsymBoost**. Bằng cách chấp nhận tăng tỷ lệ nhận diện nhầm nền thành mặt, AsymBoost giúp tỷ lệ bắt dính khuôn mặt đạt đến 99.9%, sự đánh đổi này sau đó sẽ được khắc phục triệt để nhờ kiến trúc Cascade nhiều tầng.
Quy trình AsymBoost chia sẻ hoàn toàn các bước tính sai số ϵ_m và hệ số α_m với AdaBoost chuẩn. Điểm khác biệt duy nhất nằm ở bước **cập nhật trọng số**, trong đó tích hợp thêm tham số phạt bất đối xứng $k > 1$:

$$w_i^{(m+1)} = w_i^{(m)} \exp\big(-\alpha_m y_i h_m(x_i)\big) \cdot \begin{cases} k & \text{nếu } y_i = +1 \text{ và } h_m(x_i) = -1 \\ 1 & \text{trong các trường hợp còn lại} \end{cases}$$

(Hệ số k khuếch đại trọng số của các mẫu khuôn mặt bị phân loại sai (False Negative), ép mô hình bắt buộc phải ưu tiên xử lý chúng ở vòng lặp tiếp theo). Sau đó, tiến hành chuẩn hóa lại tổng trọng số như bình thường.

3.6.8 Đánh giá ưu và nhược điểm

Ưu điểm

- Tự động chọn đặc trưng có ích từ không gian đặc trưng rất lớn.
- Tối ưu trực tiếp cho bài toán phân loại nhị phân.
- Phối hợp tốt với cascade trong bối cảnh mất cân bằng lớp mạnh.

Nhược điểm

- Có thể nhạy với nhiễu nếu khâu chuẩn hóa và lựa chọn dữ liệu huấn luyện chưa tốt.
- Các trạm sau phụ thuộc vào kết quả lọc của trạm trước.
- Khó biểu diễn quan hệ không gian phức tạp như các mô hình học sâu hiện đại.

3.6.9 Tổng kết

Trong pipeline Viola–Jones, AdaBoost giữ vai trò trung tâm: chọn đặc trưng Haar hữu ích nhất, kết hợp các bộ phân loại yếu thành bộ phân loại mạnh và tạo nên từng trạm của cascade. Khi kết hợp với integral image, hệ thống đạt tốc độ gần thời gian thực mà vẫn giữ độ chính xác tốt trong bối cảnh phát hiện khuôn mặt chính diện. [1], [2], [3]

3.7 Gom nhóm và hợp nhất các phát hiện

3.7.1 Hiện tượng nhiều phát hiện cho cùng một khuôn mặt

Do cơ chế tháp hình ảnh kết hợp quét cửa sổ trượt, một khuôn mặt thực thường được phát hiện ở nhiều vị trí gần nhau và ở nhiều mức tỉ lệ khác nhau. Stride nhỏ tạo ra nhiều vùng chồng lấp, còn các mức tháp lân cận tạo ra các hộp có kích thước hơi khác nhau quanh cùng đối tượng. Nếu giữ toàn bộ phát hiện dương tính sau cascade, một khuôn mặt có thể xuất hiện nhiều hộp bao, đầu ra thiếu ổn định và tăng nguy cơ báo động giả lẻ. Vì vậy bước hậu xử lý gom nhóm và hợp nhất là thành phần bắt buộc trong pipeline. [1], [4]

3.7.2 Nguyên lý gom nhóm dựa trên sự lân cận

Nguyên tắc trực quan của detector cổ điển là: nếu nhiều hộp dương tính gần nhau về vị trí và kích thước, chúng có khả năng cao cùng tương ứng một khuôn mặt. Ngược lại, phát hiện đơn lẻ không có lân cận xác nhận thường có xác suất là báo động giả cao hơn. Do đó, hậu xử lý được mô hình như một bài toán gom cụm hộp bao theo ba tiêu chí:

- Gần nhau về tọa độ tâm.
- Tương đương về kích thước.
- Có mức chồng lấp đáng kể.

3.7.3 Cơ chế xác nhận theo số lượng phát hiện

Chiến lược thường dùng trong triển khai cascade cổ điển:

- Gom các hộp lân cận thành cụm.
- Đếm số phát hiện trong từng cụm.
- Chỉ giữ cụm có số lượng đủ lớn.

Gọi n_j là số hộp thuộc cụm j. Một cụm được chấp nhận nếu:

$$n_j \geq T$$

trong đó T là ngưỡng xác nhận tối thiểu. Cơ chế này dựa trên quan sát rằng khuôn mặt thật thường sinh nhiều phát hiện chồng lấp, còn báo động giả ngẫu nhiên thường xuất hiện rời rạc.

3.7.4 Hợp nhất bounding box trong mỗi cụm

Sau khi cụm được chấp nhận, hệ thống tạo một hộp đại diện duy nhất. Hai cách phổ biến:

- Lấy trung bình tọa độ các hộp trong cụm.
- Chọn hộp có điểm tin cậy cao nhất.

Trong thực hành cascade cổ điển, cách lấy trung bình thường cho đầu ra ổn định hơn do làm mượt sai lệch nhỏ giữa các phát hiện lân cận.

3.7.5 Vai trò của hậu xử lý trong toàn hệ thống

Bước gom nhóm có ba vai trò trực tiếp:

- Giảm báo động giả bằng cách loại các phát hiện đơn lẻ.
- Ổn định đầu ra bằng cách hợp nhất nhiều hộp thành một hộp duy nhất cho mỗi khuôn mặt.
- Tăng độ tin cậy quyết định cuối theo cơ chế bỏ phiếu từ nhiều phát hiện lân cận.

3.7.6 Đánh giá tổng hợp: ưu điểm và hạn chế

Ưu điểm

- Đơn giản, dễ triển khai.
- Phù hợp đặc tính quét dày của sliding window.
- Cải thiện độ ổn định hiển thị trong ứng dụng thực tế.

Hạn chế

- Phụ thuộc vào ngưỡng xác nhận tối thiểu T.
- Có thể loại nhầm khuôn mặt nhỏ nếu số phát hiện sinh ra ít.
- Không trực tiếp tối ưu theo các tiêu chí đánh giá hiện đại.

3.7.7 Kết luận

Gom nhóm và hợp nhất phát hiện là bước hậu xử lý cuối trong pipeline detector cổ điển. Bằng cách khai thác hiện tượng một khuôn mặt sinh nhiều phát hiện lân cận, hệ thống loại bỏ phát hiện đơn lẻ và hợp nhất kết quả trùng lặp thành một hộp duy nhất. Bước này hoàn thiện chuỗi xử lý tháp hình ảnh, quét cửa sổ, cascade và học tăng cường, đồng thời bảo đảm đầu ra ổn định cho triển khai thực tế. [1], [4]

Cơ chế xác nhận dựa trên nhiều phát hiện lân cận phản ánh tư duy loại sớm và bỏ phiếu theo mật độ, trong đó các phát hiện đơn lẻ thường khó trở thành bằng chứng đủ mạnh cho quyết định cuối cùng. Những nguyên lý này tiếp tục được kế thừa dưới nhiều hình thức trong các hệ thống phát hiện đối tượng hiện đại, chẳng hạn ngưỡng hóa theo điểm tin cậy, khử trùng lặp bằng loại bỏ không cực đại và hợp nhất dự đoán ở giai đoạn hậu xử lý. [5], [6]

3.8 Áp dụng các cải tiến kỹ thuật vào bộ khung cơ sở

3.8.1 Định tuyến mô hình theo góc nhìn (Face-Pose Hierarchy)

Vấn đề thực tiễn

Bộ phân loại Cascade truyền thống thường chỉ được huấn luyện cho khuôn mặt nhìn thẳng (frontal face). Khi áp dụng vào môi trường thực tế với đa dạng góc xoay của đầu (in-plane và out-of-plane), hiệu năng của hệ thống suy giảm nghiêm trọng.

Cơ chế định tuyến (Routing)

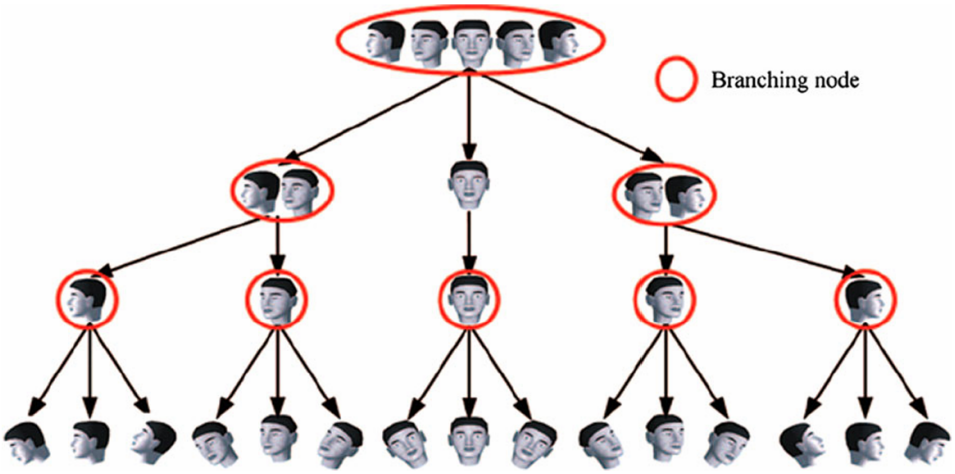

Hình I.2: Fig. 11.10 trong chương sách: minh họa của cấu trúc phát hiện khuôn mặt ở đa góc nhìn. Nguồn Huang et al. [7]

Hệ thống sử dụng cấu trúc cây quyết định phân cấp (Detector Pyramid) thay vì một luồng tuyến tính I.2:

- **Nút gốc (Root Node):** Hoạt động như một trạm phân loại góc nhìn sơ bộ. Nó quét cửa sổ ảnh và ước lượng nhanh hướng của khuôn mặt (ví dụ: thẳng, nghiêng trái, nghiêng phải).
- **Nút lá (Leaf Nodes):** Cửa sổ ảnh sau đó được luân chuyển vào các nhánh Cascade chuyên biệt đã được huấn luyện riêng cho góc độ đó.

Đánh giá

- *Ưu điểm:* Mở rộng khả năng nhận diện đa góc độ (multiview) mà không làm giảm tốc độ rà quét (do chỉ chạy 1 luồng nhánh thay vì chạy song song mọi mô hình).
- *Hạn chế:* Tốn chi phí huấn luyện nhiều bộ Cascade; rủi ro sai số tích lũy (nếu trạm gốc phân loại sai góc, khuôn mặt sẽ bị đưa vào sai nhánh và bị loại bỏ vĩnh viễn).

3.8.2 Nâng cấp bộ trích xuất với đặc trưng MB-LBP

Vấn đề thực tiễn

Đặc trưng Haar-like cơ sở chỉ phản ánh được sự chênh lệch cường độ sáng tối (gradient) cơ bản, dễ bị ảnh hưởng bởi nhiễu và điều kiện chiếu sáng phức tạp.

Cơ chế trích xuất

Thay thế Haar-like bằng Multi-Block Local Binary Pattern (MB-LBP):

- Không so sánh từng điểm ảnh, hệ thống so sánh cường độ sáng trung bình của 1 khối trung tâm với 8 khối lân cận bao quanh nó.
- Kết quả xuất ra một mã nhị phân 8-bit, biểu diễn dưới dạng biểu đồ tần suất (Histogram) để phản ánh cấu trúc vi mô (kết cấu bề mặt).
- Vẫn tận dụng triệt để mô hình Integral Image để tính tổng cường độ sáng của các khối, giữ nguyên độ phức tạp $O(1)$.

Đánh giá

- *Ưu điểm:* Cực kỳ mạnh mẽ trong việc nắm bắt kết cấu cục bộ (texture); tính kháng nhiễu với thay đổi ánh sáng tốt hơn Haar-like.
- *Hạn chế:* Không gian đặc trưng là rời rạc (categorical), buộc phải thay đổi kiến trúc của bộ phân loại yếu (dùng Bảng tra cứu - Look-up table thay vì so sánh ngưỡng số thực).

3.8.3 Huấn luyện bất đối xứng với AsymBoost

Vấn đề thực tiễn

Bài toán trượt cửa sổ sinh ra sự mất cân bằng dữ liệu cực độ (1 khuôn mặt / hàng triệu ảnh nền). AdaBoost truyền thống dễ bị chệch, thiên vị lớp đa số để giảm sai số tổng, dẫn đến bỏ sót khuôn mặt.

Cơ chế huấn luyện

Sử dụng thuật toán Asymmetric Boosting (AsymBoost) để can thiệp vào quá trình cập nhật trọng số:

- Đưa vào hệ số phạt bất đối xứng $k > 1$.
- Nếu mô hình bỏ sót khuôn mặt (False Negative), trọng số của mẫu đó bị khuếch đại lên k lần ở vòng lặp sau.
- Nếu mô hình nhận diện nhầm ảnh nền (False Positive), trọng số chỉ được cập nhật bình thường.

Đánh giá

- *Ưu điểm:* Ép mô hình dịch chuyển ngưỡng quyết định, đảm bảo tỷ lệ phát hiện (Detection Rate) luôn tiệm cận 100%; phù hợp tuyệt đối với triết lý "thà bắt nhầm còn hơn bỏ sót" của các trạm Cascade đầu tiên.
- *Hạn chế:* Việc thiên vị lớp thiểu số làm tăng đáng kể tỷ lệ báo động giả (False Alarm), đẩy gánh nặng tính toán sang các trạm Cascade ở phía sau; đòi hỏi tinh chỉnh thủ công hệ số k.

4 Phân tích kết quả trong chương sách

Trong chương sách, ví dụ định tính quan trọng cho phát hiện khuôn mặt chính diện là Fig. 11.14, trong đó hệ thống phát hiện được minh họa trên 9 ảnh cảnh khác nhau với điều kiện nền và chiếu sáng thay đổi. [1]

Hình I.3: Fig. 11.14 trong chương sách: kết quả phát hiện khuôn mặt chính diện bằng hộp trắng.

Hình I.4: Fig. 11.15 trong chương sách: kết quả phát hiện khuôn mặt đa góc nhìn trên bộ ảnh CMU.

Phân tích từ ví dụ này cho thấy ba điểm kỹ thuật chính:

- Bộ phát hiện xử lý tốt các khuôn mặt chính diện có kích thước vừa đến lớn trong bối cảnh đời thường.
- Kết quả giữa các ảnh cho thấy hành vi tương đối ổn định khi nền thay đổi, phản ánh vai trò của cascade trong việc loại nhanh phần lớn cửa sổ âm.
- Chương sách nhấn mạnh đánh đổi giữa tỉ lệ phát hiện và số báo động giả, đồng thời dùng đường ROC để đánh giá ở cấp hệ thống. [1]

Với Fig. 11.15, chương sách chuyển sang bối cảnh đa góc nhìn, trong đó số lượng khuôn mặt lệch góc tăng rõ. Điểm này phù hợp với mô tả trong chương về các bộ phát hiện đa hướng dạng view-based và multiview cascade, thay vì chỉ dùng một bộ phân loại chính diện duy nhất. [1]

Đọc kỹ từ mục 11.6 cho thấy chương sách đặt ra một quy trình đánh giá có cấu trúc rõ:

- Tách riêng hai thành phần của hệ thống là bộ phân loại mặt và khâu hậu xử lý gom nhóm để đánh giá.

- Dùng hai kiểu dữ liệu kiểm tra gồm ảnh con kích thước cố định để đo bộ phân loại và ảnh tự nhiên để đo toàn hệ thống.
- Dùng cặp chỉ số tỉ lệ phát hiện và báo động giả, đồng thời nhấn mạnh số báo động giả sau hậu xử lý là chỉ số gắn trực tiếp với đầu ra cuối.
- Dùng đường cong ROC với trục ngang là số báo động giả sau hậu xử lý trên bộ dữ liệu chuẩn MIT-CMU cho so sánh liên hệ thống.

Ở mục 11.6.2, sách còn tổng kết thêm các so sánh giữa các biến thể boosting, kiểu bộ học yếu và kích thước cửa sổ con, trong đó báo cáo rằng kích thước cửa sổ con 20 nhân 20 thường cho tỉ lệ phát hiện tốt ở miền báo động giả trung bình, còn 24 nhân 24 có thể phù hợp hơn ở miền báo động giả rất thấp. [1]

Giới hạn của ví dụ trong sách là tập trung chủ yếu vào nhóm ảnh khuôn mặt chính diện, chưa phản ánh đầy đủ tình huống khuôn mặt rất nhỏ, che khuất mạnh và thay đổi tư thế lớn như trong dữ liệu ngoài tự nhiên hiện đại. Vì vậy, ở mục sau nhóm thực hiện tái lập trực tiếp trên chính Fig. 11.14 rồi mở rộng sang ảnh khó để so sánh.

5 Minh họa cài đặt của nhóm

Phần này trình bày kết quả nhóm tự cài đặt để đối chiếu trực tiếp với ví dụ trong sách, sau đó mở rộng sang ảnh khó để phân tích hạn chế. Hệ thống dùng Viola–Jones qua OpenCV CascadeClassifier với bộ phân tầng Haar Cascade mặc định. [2], [3], [4], [8] Tập dữ liệu là WIDER FACE validation gồm 1 687 ảnh có nhãn hộp bao khuôn mặt. [9], [10]

Giao thức đo:

- Chạy detector trên toàn bộ ảnh validation với một cấu hình cố định.
- Ghép dự đoán và nhãn thật bằng ngưỡng IoU bằng 0.3 để xác định TP, FP, FN.
- Tổng hợp Precision, Recall và F1 trên toàn tập.

Ngưỡng IoU bằng 0.3 được chọn để phù hợp bộ phát hiện cổ điển, vì hộp dự đoán của cascade thường lệch tâm và độ khít so với nhãn thật không cao như detector học sâu hiện đại. Ghép một-một theo chiến lược tham lam được dùng để giữ quy trình đánh giá đơn giản và dễ tái lập; tuy nhiên cách ghép này có thể phụ thuộc thứ tự hộp dự đoán. Nếu cần ổn định hơn ở bước đối sánh, có thể thay bằng ghép tối ưu toàn cục theo Hungarian.

Kết quả tổng hợp toàn tập:

- Tổng số nhãn thật: 37 161 khuôn mặt.
- Tổng số dự đoán: 9 211 hộp.
- TP bằng 6 100, FP bằng 3 111, FN bằng 31 061.
- Precision bằng 66.23%, Recall bằng 16.42%, F1 bằng 26.31%.

Các chỉ số cho thấy detector vẫn hoạt động khá tốt trên một phần khuôn mặt chính diện rõ, nhưng độ phủ thấp ở bối cảnh không ràng buộc với khuôn mặt nhỏ, góc nghiêng và che khuất.

Tái lập trực tiếp trên ví dụ trong sách. Nhóm cắt đúng vùng Fig. 11.14 từ trang sách, tách thành 9 ảnh con theo đúng bố cục lưới của hình, chạy detector trên từng ảnh con rồi ghép kết quả lại để tránh nhiễu do quét xuyên biên giữa các ảnh:

- Nhóm quét lưới siêu tham số theo `scaleFactor`, `minNeighbors`, `minSize`, tổ hợp cascade và ngưỡng lọc kích thước hộp.

- Mỗi cấu hình được chấm theo ba tiêu chí hộp bao: tổng số phát hiện gần mật độ của hình sách, độ phủ đủ 9 ảnh con và không xuất hiện hộp bao quá lớn.
- Cấu hình A gần sách nhất dùng `frontal_default + frontal_alt2`, `scaleFactor=1.05`, `minNeighbors=3`, `minSize=18`, lọc `maxAreaRatio=0.20`.
- Cấu hình B tăng nhẹ độ phủ dùng `frontal_default + frontal_alt2`, `scaleFactor=1.07`, `minNeighbors=1`, `minSize=18`, lọc `maxAreaRatio=0.20`.

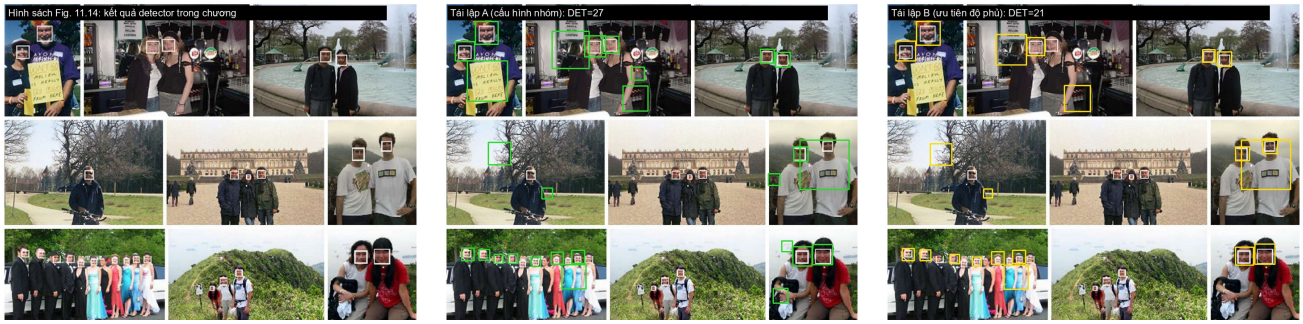

(a) Hình gốc trong sách (b) Tái lập cấu hình A (c) Tái lập cấu hình B

Hình I.5: So sánh ví dụ trong sách và kết quả tái lập của nhóm trên cùng ảnh Fig. 11.14.

So sánh trực tiếp từ Hình I.5:

- Ảnh sách thể hiện nhiều khuôn mặt chính diện đã được bắt ổn định bằng hộp trắng.
- Cấu hình A cho 27 hộp, phủ đủ cả 9 ảnh con và có mật độ hộp bao gần nhất với hình sách.
- Cấu hình B cho 21 hộp, giảm bớt các hộp chồng lặp và giữ xu hướng ổn định hơn ở các ảnh nhiễu nền.

Tái lập thêm cho Fig. 11.15 đa góc nhìn. Nhóm tiếp tục sweep siêu tham số trên chính Fig. 11.15 với nhiều tổ hợp cascade và chọn cấu hình có mật độ hộp bao gần sách nhất.

(a) Fig. 11.15 trong sách

(b) Tái lập gần đúng của nhóm

Hình I.6: Đối chiếu kết quả đa góc nhìn: sách và tái lập trên cùng ảnh Fig. 11.15.

Ở cấu hình được chọn, detector tạo 20 hộp phát hiện và bao phủ được phần lớn khuôn mặt chính. Tuy nhiên kích thước hộp và mức gom nhóm vẫn khác ảnh sách. Nguyên nhân chính là ảnh sách nhiều khả năng dùng bộ phát hiện multiview chuyên dụng được huấn luyện riêng trong hệ FloatBoost hoặc RealBoost với đặc trưng Haar mở rộng, không trùng với các cascade dựng sẵn của OpenCV. [1]

Cấu hình siêu tham số dùng cho demo.

- Thư viện: OpenCV 4.13.0 với lớp CascadeClassifier, dùng mô hình Haar Cascade frontalface mặc định của OpenCV. [4], [8]
- Tiền xử lý: chuyển ảnh màu sang ảnh xám trước khi chạy detector.
- Bước 1 mô phỏng sinh ứng viên dày: detectMultiScale với scaleFactor bằng 1.05, minNeighbors bằng 0, minSize bằng 20 nhân 20.
- Bước 2 cộng bước 3 cho đầu ra cuối: detectMultiScale với scaleFactor bằng 1.1, minNeighbors bằng 3, minSize bằng 20 nhân 20.
- Thiết lập khác giữ mặc định của OpenCV cho detectMultiScale.
- Đánh giá TP, FP, FN: ghép một-một theo chiến lược tham lam giữa hộp dự đoán và nhãn thật, với ngưỡng IoU bằng 0.3.

Thiết lập này ưu tiên bám sát hành vi detector cổ điển trong điều kiện ảnh thực tế. Ngưỡng IoU bằng 0.3 được giữ nhất quán để tránh phạt quá nặng các hộp dự đoán còn thô, và chiến lược ghép tham lam được chọn vì tính minh bạch khi tái lập.

Tái lập mở rộng theo mục 11.6. Để bám sát tinh thần ROC và so sánh cấu hình trong chương sách, nhóm chạy thêm hai sweep trên tập con 500 ảnh có nhãn của WIDER FACE validation. Mục tiêu của phần này là **tái lập xu hướng** thay vì tái tạo đúng từng con số gốc trong sách. Do khác mô hình huấn luyện, khác bộ dữ liệu và khác giao thức đánh giá, các so sánh định lượng trong mục này được dùng như minh họa có kiểm soát.

Ngoài sweep chuẩn, nhóm bổ sung một lượt tái lập có ràng buộc theo đúng ba nhánh thuật toán được chú thích trong Fig. 11.16 của sách, gồm nhánh từ [11], [12] và [13]. Do không có mô hình huấn luyện gốc trên MIT-CMU của từng bài, nhóm ánh xạ sang các siêu tham số suy luận tương đương trong OpenCV để giữ đúng tinh thần từng nhánh:

- Nhánh [11]: dùng cascade chính diện, giảm bước quét theo tỉ lệ xuống `scaleFactor=1.05`, `minNeighbors=2`, `minSize=20`.
- Nhánh [12]: dùng cấu hình đa góc nhìn với `frontal_default + frontal_alt2 + profile`, bật quét ảnh lật ngang, `scaleFactor=1.08`, `minNeighbors=3`, `minSize=20`.
- Nhánh [13]: ưu tiên điểm làm việc thiên về độ phủ. Dùng hai cascade `frontal_default` và `frontal_alt2` với `scaleFactor=1.05`, `minNeighbors=1`, `minSize=20`.

Bảng I.1: Kết quả tái lập cấu hình theo ba tài liệu [11], [12], [13] trên tập con 200 ảnh WIDER FACE validation.

Cấu hình neo theo tài liệu	Precision	Recall	F1
[11]	36.38%	13.07%	19.23%
[12]	51.09%	18.38%	27.03%
[13]	26.13%	18.70%	21.80%

Kết quả cho thấy cấu hình neo theo [12] cho F1 cao nhất trong ba cấu hình ánh xạ, còn cấu hình neo theo [13] cho recall nhỉnh hơn nhưng kéo theo số báo động giả cao hơn.

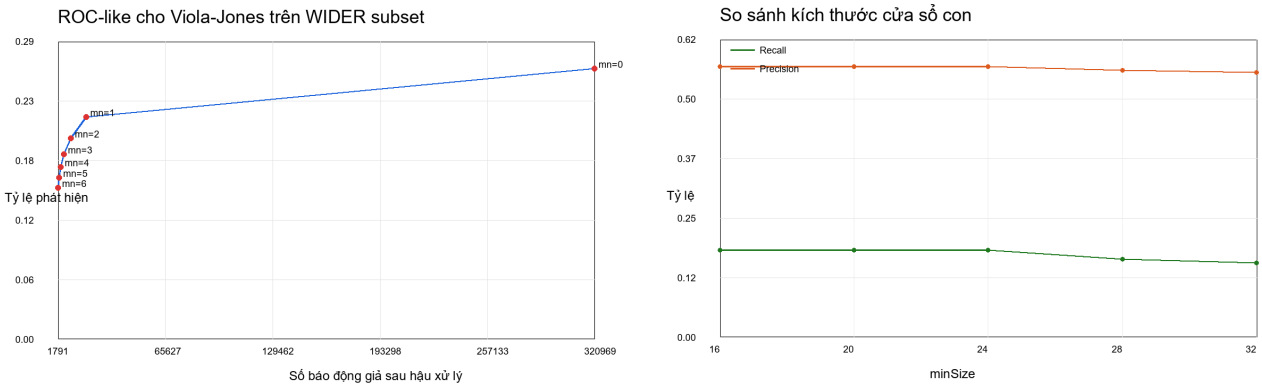

(a) ROC-like theo số báo động giả sau hậu xử lý

(b) Ảnh hưởng kích thước cửa sổ con

Hình I.7: Kết quả tái lập theo định hướng đánh giá của mục 11.6 trong chương sách.

Kết quả chính từ Hình I.7:

- Khi giảm `minNeighbors` từ 6 xuống 0, tỉ lệ phát hiện tăng từ 15.66% lên 29.00%, nhưng số báo động giả tăng mạnh từ 314 lên 65 877.
- Điểm cân bằng tốt nhất theo F1 trong sweep này nằm ở `minNeighbors=2`: precision 57.60%, recall 21.39%, F1 31.20%.
- Với `minNeighbors=3`, các mức `minSize` 16, 20, 24 cho kết quả gần như tương đương; khi tăng lên 28 và 32 thì recall giảm rõ từ 19.46% xuống 16.14% và 14.62%.

Những quan sát này nhất quán với kết luận của sách về đánh đổi giữa tỉ lệ phát hiện và báo động giả. Riêng phần so sánh sâu giữa DAB, RAB, GAB và kiểu cây yếu nhiều nút như trong 11.6.2 cần huấn luyện lại nhiều cascade trên bộ dữ liệu chuẩn cùng giao thức gốc và sẽ được nhóm triển khai ở báo cáo cuối kỳ.

Từ kết quả quét toàn tập, một ảnh đại diện thỏa đồng thời ba điều kiện đã được chọn để minh họa rõ hạn chế trong bối cảnh ngoài tự nhiên: có phát hiện đúng, có nhận nhầm và có bỏ sót. Ảnh thuộc WIDER FACE validation với định danh `2--Demonstration/2_Demonstration_Protesters_2_738.jpg`. [9], [10]

(a) Bước 1: sinh ứng viên dày đặc (b) Bước 2+3: chấm điểm và gom nhóm (c) Đối chiếu TP, FP, FN

Hình I.8: Phân tích hạn chế Viola–Jones trên một ảnh khó của WIDER FACE validation.

Quy ước ký hiệu trong Hình I.8:

- Ảnh trái: hộp màu xanh lam biểu diễn các cửa sổ ứng viên dày đặc của bước quét ban đầu.
- Ảnh giữa: hộp màu xanh lá biểu diễn các phát hiện còn lại sau cascade và gom nhóm.
- Ảnh phải: xanh lá là phát hiện đúng, đỏ là phát hiện sai, vàng là khuôn mặt thật bị bỏ sót.

Phân tích theo đúng luồng ba bước trên ảnh khó:

- Bước 1 tạo 425 ứng viên, phản ánh đặc tính bao phủ rộng nhưng chi phí lớn của cơ chế quét đa vị trí và đa tỉ lệ.
- Sau chấm điểm cascade và gom nhóm, đầu ra còn 11 hộp.
- Khi đối chiếu với nhãn thật: TP = 5, FP = 6, FN = 5 trên tổng 10 khuôn mặt.

Với ví dụ này, điểm mạnh của phương pháp là phát hiện tốt một số khuôn mặt chính diện có kích thước vừa. Hạn chế thể hiện rõ ở các vùng nền giàu kết cấu gây nhận nhầm và ở các khuôn mặt nhỏ hoặc tư thế khó gây bỏ sót. Quan sát này nhất quán với kết quả tổng hợp toàn tập ở phần phân tích thực nghiệm.

6 Thảo luận phản biện

Điểm mạnh. Chiến lược loại bỏ rất hiệu quả, quy trình dễ diễn giải, và có tác động thực tiễn mạnh trong lịch sử.

Hạn chế. Đặc trưng thủ công kém bền vững hơn trong điều kiện hiện đại không ràng buộc (che khuất, thay đổi góc nhìn, chiếu sáng phức tạp, khuôn mặt kích thước nhỏ).

Hàm ý cho báo cáo này. Chương sách cung cấp bộ khung ý tưởng của bộ phát hiện mà các phương pháp hiện đại vẫn theo, nhưng từng giai đoạn hiện được học và tối ưu theo hướng dữ liệu.

7 Kết luận

Chương sách đóng góp nền tảng về logic phát hiện và tư duy tối ưu. Mô hình cơ sở này là then chốt để lý giải vì sao các phương pháp hiện đại như SCRFD là một bước tiến trong cách hiện thực, chứ không thay thế mục tiêu theo giai đoạn của bộ phát hiện.

Chương II

PHÂN TÍCH BÀI BÁO: SCRFD (ICLR 2022)

1 Giới thiệu và động lực

Phát hiện khuôn mặt là một bài toán nền tảng trong thị giác máy tính, với nhiều ứng dụng quan trọng như căn chỉnh khuôn mặt, tái tạo khuôn mặt 3D, phân tích thuộc tính và nhận dạng khuôn mặt. Trong điều kiện tự nhiên, đây vẫn là bài toán khó, đặc biệt khi phần lớn khuôn mặt trong dữ liệu thực tế có kích thước rất nhỏ.

Thống kê phân bố kích thước trên WIDER FACE cho thấy phần lớn khuôn mặt trong tập khó nhỏ hơn 32×32 điểm ảnh; vì vậy, năng lực xử lý khuôn mặt rất nhỏ trở thành nhân tố quyết định hiệu năng tổng thể của bộ phát hiện. [9], [14]

Nhiều bộ phát hiện hiện đại kế thừa mạng trục chính từ bài toán phân loại ảnh, nơi tài nguyên tính toán thường tập trung vào các tầng sâu để học đặc trưng ngữ nghĩa mạnh. Tuy nhiên, với khuôn mặt nhỏ, thông tin quan trọng lại xuất hiện nhiều ở các tầng nông có độ phân giải cao hơn. Do đó, cách phân bổ tính toán vốn hiệu quả cho phân loại ảnh chưa chắc tối ưu khi chuyển sang phát hiện khuôn mặt. [14]

Thay vì gia tăng độ phức tạp kiến trúc bằng nhiều nhánh bổ sung, bài báo xuất phát từ giả thuyết nghiên cứu sau: *Nếu tổng số phép tính được giữ cố định, liệu việc tái cấu trúc phân bổ tính toán giữa các tầng có cải thiện đáng kể hiệu quả phát hiện hay không?*

Từ động lực đó, SCRFD đề xuất hai hướng tối ưu: (1) tái cân bằng tài nguyên tính toán trong bộ phát hiện để phù hợp hơn với phân bố kích thước khuôn mặt, và (2) điều chỉnh phân bố mẫu huấn luyện theo thang đo để tăng mật độ mẫu tại các miền kích thước quan trọng. Kết quả cho thấy có thể cải thiện hiệu quả rõ rệt mà không cần tăng tổng ngân sách tính toán. [14]

2 Các công trình liên quan và kiến thức nền

Về kiến thức nền, SCRFD kế thừa khung phát hiện ba giai đoạn đã được hình thành từ các hệ cổ điển và được tinh chỉnh dần trong các kiến trúc học sâu một giai đoạn lẫn hai giai đoạn. Về công trình liên quan, chuỗi phát triển từ Viola–Jones đến RetinaNet và các mô hình chuyên biệt khuôn mặt cho thấy xu hướng chuyển dịch rõ ràng từ thiết kế thủ công sang tối ưu hóa phân bố tài nguyên tính toán và phân bố mẫu dữ liệu theo đặc thù bài toán.

2.1 Luồng bộ phát hiện 3 bước

Diễn giải theo luồng phát hiện cơ sở. Ở cách tiếp cận ngây thơ nhất, giai đoạn sinh ứng viên được thực hiện bằng cách duyệt toàn bộ cửa sổ trên ảnh ở mọi vị trí và mọi kích thước. Trong thực tế, thao tác này thường được cài đặt bằng quét cửa sổ trượt trên tháp tỉ lệ, nên số lượng ứng viên tăng rất nhanh theo độ phân giải ảnh

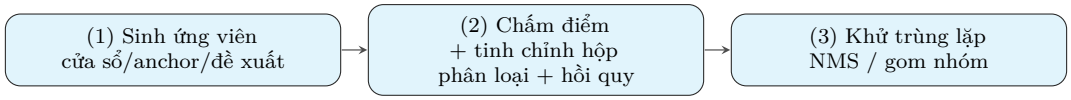

Hình II.1: Quy trình phát hiện chuẩn dùng chung cho bộ phát hiện cổ điển và hiện đại.

và số mức tỉ lệ. Ở giai đoạn chấm điểm, từng cửa sổ được đánh giá độc lập để quyết định có phải khuôn mặt hay không và có thể kèm hiệu chỉnh hộp bao. Ở giai đoạn hợp nhất, các dự đoán chồng lấp cao được gộp lại bằng cơ chế như NMS để tránh lặp phát hiện. Khung ngây thơ này giúp nhìn rõ bản chất bài toán, đồng thời chỉ ra nút thắt tính toán khiến các phương pháp hiện đại phải tối ưu mạnh ở cả ba giai đoạn.

2.2 Sơ đồ tiến hóa đến SCRFD

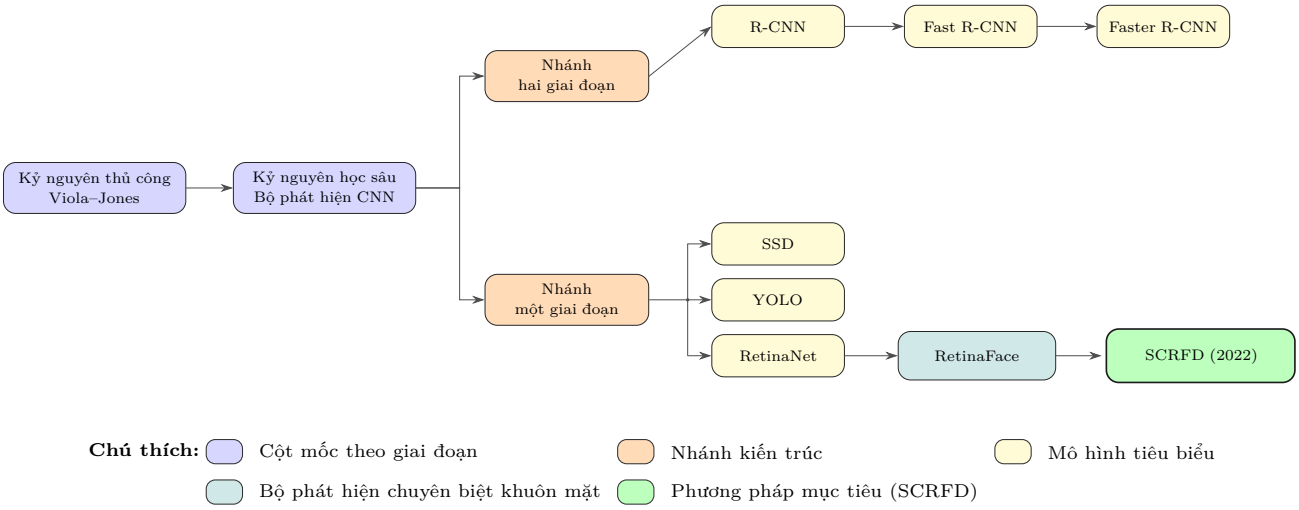

Hình II.2: Lộ trình tiến hóa từ phát hiện khuôn mặt thủ công đến SCRFD (nhánh một giai đoạn).

2.3 Phân tích chi tiết các cột mốc trên đường tiến hóa đến SCRFD

Nguyên tắc đọc chung. Mỗi cột mốc kiến trúc trong Hình II.2 đều có thể quy chiếu về cùng một khung phát hiện ba giai đoạn: sinh ứng viên, chấm điểm kèm định vị lại hộp, và hợp nhất dự đoán. Sự khác biệt giữa các thế hệ chủ yếu nằm ở cách hiện thực và trọng tâm tối ưu hóa tại từng giai đoạn. Trong phần này, tuyến phân tích chính được giữ theo chuỗi *Viola–Jones* → *CNN detectors* → *RetinaNet* → *SCRFD*; các nhánh còn lại chỉ tóm tắt để định vị bối cảnh.

Viola–Jones. Ở giai đoạn sinh ứng viên, hệ thống quét cửa sổ trượt trên nhiều tỉ lệ ảnh để bao phủ không gian vị trí và kích thước khuôn mặt. Giai đoạn chấm điểm sử dụng đặc trưng Haar-like tính nhanh bằng ảnh tích phân, kết hợp AdaBoost để chọn đặc trưng phân biệt và tổ chức thành cascade nhiều tầng nhằm loại sớm mẫu âm. Giai đoạn cuối hợp nhất các cửa sổ chồng lấp thành phát hiện duy nhất. Đóng góp bản chất của cột mốc này là đặt nền cho một quy trình phát hiện có tính hệ thống, trong đó tốc độ được tối ưu ngay từ cơ chế ra quyết định. [1], [2], [3]

Kỷ nguyên học sâu. Trong giai đoạn chuyển tiếp sang học sâu, cơ chế sinh ứng viên dần rời khỏi các quy tắc thủ công và gắn với bản đồ đặc trưng học được. Khâu chấm điểm và hồi quy hộp hưởng lợi trực tiếp từ biểu diễn sâu, nhờ đó độ tách biệt giữa mặt và nền trong bối cảnh che khuất, thay đổi tư thế và điều kiện chiếu sáng phức tạp được cải thiện đáng kể. NMS tiếp tục đảm nhiệm khâu hợp nhất dự đoán, nhưng chất lượng đầu vào đã cao hơn rõ rệt. Điểm thay đổi cốt lõi của giai đoạn này là chuyển trọng tâm từ thiết kế đặc trưng bằng tay sang học biểu diễn từ dữ liệu.

Nhánh hai giai đoạn. Nhánh này gồm R-CNN, Fast R-CNN và Faster R-CNN. Trong R-CNN, sinh ứng viên dựa trên selective search với số lượng vùng đề xuất lớn; các vùng này được đưa qua CNN theo từng vùng, sau đó

phân loại bằng SVM và hồi quy hộp, trước khi hợp nhất bằng NMS. [15] Fast R-CNN giữ cơ chế đề xuất vùng bên ngoài nhưng tái cấu trúc khâu chấm điểm bằng cách chia sẻ đặc trưng tích chập toàn ảnh, chỉ trích xuất ROI tại bước sau, đồng thời học chung phân loại và hồi quy để giảm mạnh tính toán lặp. [16] Faster R-CNN tiếp tục hợp nhất quy trình bằng cách thay selective search bằng RPN dựa trên anchor và chia sẻ đặc trưng với nhánh nhận dạng; NMS vẫn giữ vai trò then chốt ở cả mức đề xuất và mức dự đoán cuối. [5] Nhìn tổng thể, nhánh hai giai đoạn ưu tiên chất lượng ứng viên và độ chính xác, đánh đổi bằng độ trễ suy luận cao hơn.

Nhánh một giai đoạn sớm. Nhánh này tiêu biểu bởi SSD và YOLO. SSD sinh ứng viên bằng default boxes đa tỉ lệ trên nhiều mức đặc trưng và dự đoán trực tiếp nhãn cùng sai lệch hộp cho từng default box trong một lượt suy luận, trước khi áp dụng NMS. [17] YOLO mô hình hóa không gian ảnh theo lưới đều, dự đoán đồng thời hộp giới hạn, điểm tin cậy và xác suất lớp tại từng ô, rồi khử trùng lặp bằng ngưỡng và NMS. [18] Đóng góp quan trọng của nhánh này là hợp nhất khâu sinh ứng viên và khâu chấm điểm vào một quy trình tích hợp theo hướng thời gian thực.

RetinaNet. RetinaNet duy trì cơ chế phát hiện dày đặc bằng anchor trên tháp đặc trưng đa mức. Khâu chấm điểm và hồi quy được tách thành hai nhánh song song; cải tiến quan trọng là focal loss nhằm giảm ảnh hưởng của mẫu âm dễ và dồn trọng số học vào mẫu khó. Khâu hậu xử lý vẫn sử dụng NMS để hợp nhất kết quả. So với SSD và YOLO, RetinaNet xử lý hiệu quả hơn bài toán mất cân bằng lớp trong phát hiện dày đặc, nhờ đó chất lượng phân loại được cải thiện rõ rệt. [6]

SCRFD. SCRFD kế thừa nền tảng phát hiện dày đặc một giai đoạn với anchor đa mức, nhưng không chấp nhận nguyên trạng tỉ lệ thiết kế của mô hình gốc. Ở tầng phương pháp, bài báo đồng thời tối ưu kiến trúc và dữ liệu huấn luyện qua hai cơ chế: Computation Redistribution tái cân bằng tài nguyên tính toán giữa mạng trục chính, cổ đặc trưng, đầu dự đoán và từng tầng trong mạng trục chính; Sample Redistribution điều chỉnh phân bố mẫu theo thang đo để tăng cường tín hiệu học tại các miền kích thước quan trọng của khuôn mặt nhỏ. NMS vẫn được giữ ở khâu hợp nhất dự đoán; tuy nhiên, chất lượng hộp và điểm tin cậy được nâng lên nhờ hai tối ưu nói trên. So với RetinaFace và nhiều mốc trước đó, SCRFD cải thiện rõ hiệu năng trên tập khó trong khi vẫn duy trì hiệu quả tính toán trong cùng ngân sách. [14], [19]

3 Phương pháp bài báo đề xuất

3.1 Phương pháp chính của SCRFD

A. Các đóng góp cốt lõi. Dựa trên kiến trúc nền lấy cảm hứng từ RetinaNet, bài báo đề xuất SCRFD như một cách tái thiết kế ở mức hệ thống, tập trung vào phân bố tài nguyên và phân bố mẫu hơn là thêm mô-đun phức tạp. [6], [14] Ba đóng góp chính gồm:

- Xây dựng không gian tìm kiếm rút gọn và chiến lược tìm kiếm hai bước cho Computation Redistribution nhằm tối ưu đồng thời backbone, neck và head.
- Thiết kế không gian tăng cường thu phóng có thể tìm kiếm cho Sample Redistribution để đẩy thêm mẫu học vào các miền kích thước có ích cho khuôn mặt nhỏ.
- Báo cáo thực nghiệm diện rộng trên WIDER FACE, cho thấy đánh đổi độ chính xác và hiệu năng vượt trội trên nhiều mức ngân sách tính toán. [9], [14]

B. Giải phẫu kiến trúc nền. Để làm rõ điểm mới của SCRFD, cần nhìn trước vào detector nền một giai đoạn mà bài báo sử dụng:

- **Backbone:** trích xuất đặc trưng theo các tầng $C_2 \to C_5$.
- **Neck:** dùng PAFPN để tổng hợp đặc trưng đa mức theo cả hướng trên-xuống và dưới-lên.
- **Head:** dự đoán phân loại và hồi quy hộp trên các mức đặc trưng.

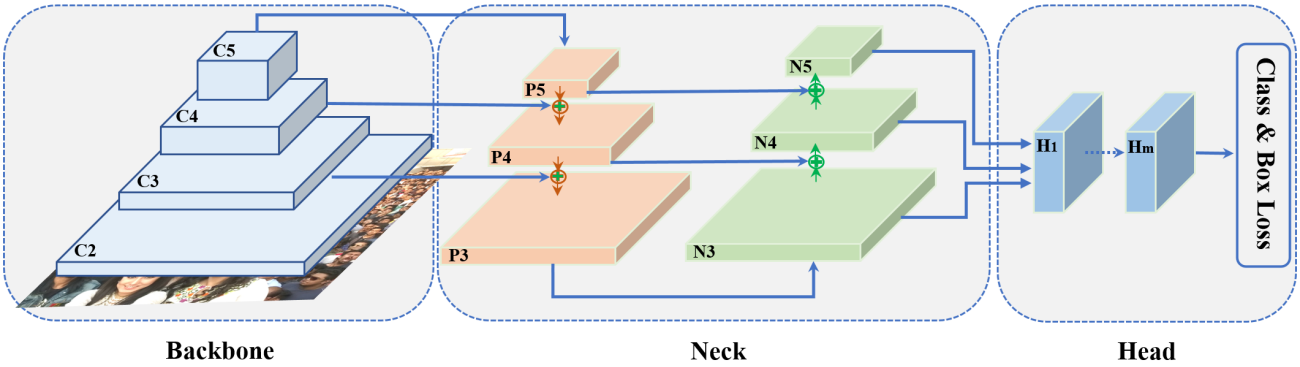

Hình II.3: Minh họa kiến trúc nền SCRFD theo ba khối: Backbone, Neck và Head.

C. Vấn đề kỹ thuật sinh ra nhu cầu tối ưu. Bài báo chỉ ra hai điểm nghẽn quan trọng khi áp dụng thiết kế kế thừa từ detector tổng quát vào phát hiện khuôn mặt nhỏ ở mức VGA 640 nhân 480. Thứ nhất, cách phân bổ tính toán mặc định từ mạng phân loại ảnh chưa phù hợp với tín hiệu khuôn mặt nhỏ vốn nằm nhiều ở các mức đặc trưng nông. Thứ hai, phân bố mẫu theo thang đo và phân bố anchor chưa khớp tốt với dữ liệu thực, dẫn đến thiếu mẫu dương ở các mức thật sự cần cho khuôn mặt rất nhỏ. [14]
D. Cơ chế giải quyết của SCRFD. SCRFD triển khai hai trụ cột phối hợp:

- **Computation Redistribution CR:** tái cấu trúc phân bổ tính toán giữa backbone, neck, head và giữa các tầng trong backbone để dồn tài nguyên vào phần có ích hơn cho khuôn mặt nhỏ.
- **Sample Redistribution SR:** điều chỉnh phân bố mẫu huấn luyện theo thang đo bằng chiến lược thu phóng có tìm kiếm, giúp tăng mật độ mẫu dương tại các mức anchor nhỏ.

3.2 Mục tiêu kỹ thuật, cách tiếp cận và nguyên nhân hiệu quả

A. Mục tiêu kỹ thuật. Mục tiêu cốt lõi của SCRFD là tối ưu đánh đổi độ chính xác và hiệu năng tính toán. Trong thiết lập khó, bài báo đặt trọng tâm vào miền khuôn mặt rất nhỏ dưới 32 nhân 32 điểm ảnh và yêu cầu mô hình giữ hiệu năng tốt dưới ngân sách suy luận chặt. [14]
B. Cách tiếp cận và hiệu quả của CR. CR dùng random search trên không gian đã rút gọn, kết hợp phân tích bootstrap thực nghiệm để xác định miền cấu hình hiệu quả. Pha tìm kiếm được chia làm hai bước để tránh bùng nổ tổ hợp:

- **Bước 1:** tìm độ sâu và độ rộng cho các tầng backbone, ưu tiên tăng năng lực tại các tầng nông như C2, C3.
- **Bước 2:** tối ưu neck và head để giữ ngân sách FLOPs khi backbone đã được tái phân bổ.

Thiết kế này giúp random search vẫn hiệu quả, đồng thời tạo được cấu hình có tính thực dụng cao trong triển khai. [14]

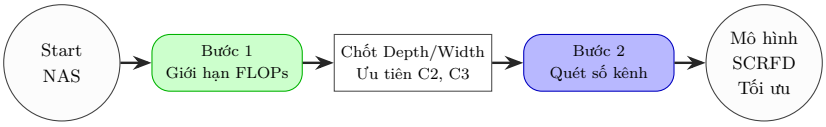

Hình II.4: Quy trình tìm kiếm hai bước trong SCRFD để tái phân bổ tính toán.

C. Cách tiếp cận và hiệu quả của SR. SR tìm chiến lược thu phóng dữ liệu để phân bố lại mẫu học theo thang đo, bảo đảm khuôn mặt nhỏ xuất hiện nhiều hơn tại các mức đặc trưng phù hợp. Trong cấu hình suy luận, SCRFD dùng anchor theo ba mức:

$$\{16, 32\} \text{ trên stride } 8, \quad \{64, 128\} \text{ trên stride } 16, \quad \{256, 512\} \text{ trên stride } 32$$

và ưu tiên tỉ lệ hình học gần vuông cho khuôn mặt. Nhờ đó số mẫu dương ở các mức nhỏ tăng lên, giúp cải thiện rõ độ phủ trên tập khó mà không cần tăng ngân sách tính toán tổng. [14]

3.3 Kết quả mô hình tối ưu và tinh chỉnh tham số anchor

Sau pha tìm kiếm NAS, cấu trúc SCRFD cho thấy một dịch chuyển rõ so với cấu hình mạng phân loại chuẩn. Thay vì tiếp tục dồn tài nguyên vào tầng sâu, mô hình tối ưu của SCRFD tăng năng lực tại tầng nông và trung gian để phù hợp hơn với tín hiệu khuôn mặt nhỏ.

1. Hình dáng kiến trúc nặng tầng nông, gọn tầng sâu. So với dạng ResNet-50 truyền thống, mô hình SCRFD giảm đáng kể số block ở C4, C5 và tăng tương đối ở C2, C3. Để không làm FLOPs bùng nổ, số kênh ở neck và head được giữ gọn ở dải nhỏ hơn so với thiết kế nền. Mẫu hình thiết kế này phản ánh đúng mục tiêu của CR: đưa tài nguyên về các mức đặc trưng có độ phân giải phù hợp phát hiện khuôn mặt nhỏ. [14]

2. Tinh chỉnh anchor theo cấu trúc khuôn mặt và theo stride. Bài báo đơn giản hóa thiết kế anchor theo hai hướng:

- **Giảm đa dạng tỉ lệ hình học:** ưu tiên tỉ lệ gần vuông cho khuôn mặt, thay vì giữ nhiều tỉ lệ dọc-ngang như detector tổng quát.
- **Quy hoạch kích thước theo mức đặc trưng:**

$$\{16, 32\} \text{ trên stride } 8, \quad \{64, 128\} \text{ trên stride } 16, \quad \{256, 512\} \text{ trên stride } 32$$

Trong đó, stride 8 tập trung cho khuôn mặt rất nhỏ, stride 16 cho miền trung bình, và stride 32 cho đối tượng lớn. Phân công này tương thích trực tiếp với SR, vì thu phóng dữ liệu sẽ đẩy thêm mẫu dương về các mức nhỏ nơi detector cần tăng độ nhạy. [14]

3.4 Đánh giá hiệu quả thực tiễn so với mô hình đối sánh

Khi kết hợp CR và SR, SCRFD cho mức đánh đổi độ chính xác và hiệu năng rất mạnh trong thiết lập VGA 640 nhân 480 của bài báo. [14]

- **So với TinaFace:** SCRFD-34GF đạt AP tập khó 86.21 trong khi TinaFace ở mức 81.43, chênh 4.78 điểm AP. Đồng thời SCRFD-34GF dùng 34.13 GFLOPs so với 172.95 GFLOPs của TinaFace, tức khoảng một phần năm chi phí tính toán.
- **So với BFBox:** trong cùng bối cảnh đánh giá ở tập khó, bài báo ghi nhận SCRFD-34GF vượt tới 15.81 điểm AP nhờ tối ưu đồng thời backbone, neck và head.
- **Ở miền thiết bị biên:** cấu hình SCRFD-0.5GF vượt các cấu hình MobileNet baseline trên tập khó, với mức cải thiện AP được báo cáo lên đến 21.19 điểm trong thiết lập so sánh tương ứng.

Các số liệu trên cho thấy giá trị thực dụng của chiến lược tái phân bổ: hiệu năng tăng nhờ tái cấu trúc phân bố tính toán và phân bố mẫu, không phải nhờ tăng thuần kích thước mô hình.

Phân tích điểm kế thừa của SCRFD từ Viola–Jones. Dù khác mạnh về công nghệ hiện thực, SCRFD vẫn kế thừa trực tiếp tư duy thiết kế của phương pháp Viola–Jones trong chương sách:

- **Kế thừa khung ba bước phát hiện.** Cả hai đều giữ cùng mục tiêu quy trình: sinh ứng viên, chấm điểm và định vị, rồi hợp nhất kết quả. SCRFD thay thế cách làm thủ công bằng mô hình học sâu, nhưng không thay mục tiêu theo giai đoạn.
- **Kế thừa tư duy đa tỉ lệ.** Viola–Jones dùng tháp tỉ lệ ảnh để quét cửa sổ ở nhiều kích thước. SCRFD kế thừa ý tưởng đó bằng đặc trưng đa mức và phân phối lại mẫu theo tỉ lệ để bám tốt khuôn mặt nhỏ.

- **Kế thừa định hướng tối ưu hiệu quả tính toán.** Viola–Jones tăng tốc bằng chuỗi phân tầng loại sớm. SCRFD theo cùng tinh thần tối ưu chi phí, nhưng thực hiện bằng phân phối lại phép tính giữa backbone, neck và head.
- **Kế thừa bước hợp nhất dự đoán cuối.** Từ gom cửa sổ chồng lấp trong Viola–Jones, SCRFD giữ cùng vai trò hậu xử lý bằng NMS hiện đại.

Như vậy, SCRFD có thể xem là sự kế thừa có hệ thống từ Viola–Jones: giữ nguyên logic phát hiện cốt lõi, đồng thời hiện đại hóa từng bước bằng học sâu và tối ưu theo dữ liệu.

4 Phân tích thực nghiệm

SCRFD được đánh giá trên WIDER FACE, nơi khuôn mặt nhỏ chiếm ưu thế và bộc lộ rõ điểm yếu xử lý tỉ lệ. Bài báo báo cáo AP trên các tập Easy/Medium/Hard và so sánh đồng thời độ chính xác lẫn hiệu năng trong điều kiện suy luận được kiểm soát. [9], [14]

Một số kết quả định lượng tiêu biểu trong bài báo cho thấy mức cải thiện rõ rệt về đánh đổi độ chính xác - chi phí tính toán:

- Ở chế độ VGA, **SCRFD-34GF** đạt AP tập khó 86.21, cao hơn TinaFace ở mức 81.43 trong khi chi phí thấp hơn mạnh.
- Cùng mốc này, SCRFD-34GF dùng khoảng 34.13 GFLOPs so với 172.95 GFLOPs của TinaFace, tức chỉ khoảng một phần năm chi phí tính toán.
- So với BFBox trong cùng bối cảnh đánh giá, bài báo báo cáo mức vượt đáng kể ở AP tập khó nhờ tối ưu đồng thời backbone, neck và head.
- Ở miền chi phí thấp, SCRFD-0.5GF vượt rõ các cấu hình nhẹ kiểu MobileNet baseline trên tập khó, cho thấy lợi ích của CR và SR vẫn giữ được khi ngân sách tính toán rất hạn chế.

Các số liệu trên được trích trực tiếp từ các bảng định lượng trong bài báo SCRFD, chủ yếu ở Table 2 và phần đối chiếu chi phí TinaFace tại Table 4. [14]

Trọng tâm phân tích của báo cáo gồm:

- Vì sao CR giúp chuyển tài nguyên tính toán sang các thành phần có đóng góp hiệu quả hơn cho phát hiện khuôn mặt nhỏ.
- Vì sao SR cải thiện hành vi của mô hình trên tập khó thông qua tái phân bố mẫu theo thang tỉ lệ.
- SCRFD định vị như thế nào so với các mô hình nền tiêu biểu ở cả nhánh một giai đoạn và hai giai đoạn.

5 Minh họa cài đặt (để ở báo cáo cuối kỳ)

Phần cài đặt và benchmark đầy đủ được dời lại. Báo cáo giữa kỳ này chốt trước kế hoạch minh họa:

- Chạy ít nhất hai mức kích thước mô hình SCRFD trên cùng một tập kiểm định.
- Báo cáo AP (hoặc chỉ báo thay thế theo tập), độ trễ, FPS, và độ phức tạp mô hình.
- Trình bày ví dụ định tính cả thành công/lỗi trên khuôn mặt nhỏ, đông đúc, và che khuất.
- Giữ cố định môi trường và tiền xử lý để đảm bảo so sánh công bằng.

6 Thảo luận phản biện

6.1 Điểm mạnh

- Đánh đổi độ chính xác - hiệu năng tốt trong các ngân sách tính toán thực tế.
- Tối ưu theo đặc thù bài toán một cách tường minh, thay vì kế thừa tỉ lệ kiến trúc chung.
- Cải thiện ổn định trên điều kiện khó với mật độ khuôn mặt nhỏ cao.

6.2 Hạn chế

- Quy trình tìm kiếm kiến trúc tốn kém chi phí huấn luyện.
- Hiệu năng có thể nhạy với dịch chuyển miền dữ liệu ngoài thống kê của WIDER FACE.
- Kiểm thử đa tỉ lệ vẫn có thể làm tăng độ trễ khi triển khai.

6.3 Giá trị ứng dụng công nghiệp

SCRFD đưa ra một thông điệp thực dụng cho triển khai công nghiệp: không thể lấy nguyên cấu hình mạng phân loại tổng quát rồi áp thẳng vào bài toán phát hiện khuôn mặt nhỏ mà không tái thiết kế theo đặc thù dữ liệu. Họ mô hình từ 0.5GF đến 34GF tạo ra một dải cấu hình phù hợp nhiều mức tài nguyên, từ thiết bị biên công suất thấp đến hệ thống máy chủ giám sát.

- Ở lớp thiết bị biên, các cấu hình nhẹ ưu tiên độ trễ thấp và chi phí tính toán nhỏ.
- Ở lớp máy chủ, các cấu hình cao hơn giữ độ chính xác mạnh trên cảnh đông và khuôn mặt nhỏ.
- Cùng một triết lý CR và SR giúp duy trì tính nhất quán khi mở rộng từ kịch bản camera đơn lẻ sang hệ thống phân tích đám đông.

6.4 Rào cản kỹ thuật và khả năng tái lập

Điểm khó lớn nhất của phương pháp nằm ở pha tìm kiếm kiến trúc. Theo mô tả trong bài báo, để thực hiện empirical bootstrap cho từng mức ngân sách FLOPs, nhóm tác giả sinh và huấn luyện từ đầu 320 mô hình trên cụm 8 GPU Tesla V100. [14]

- Với phòng thí nghiệm nhỏ hoặc dữ liệu tùy chỉnh, chi phí này rất khó đáp ứng.
- Vì vậy, trong thực hành triển khai, đa số nhóm sẽ dùng cấu hình và trọng số đã tối ưu sẵn trên WIDER FACE thay vì tự chạy lại toàn bộ pha tìm kiếm.
- Điều này tạo ra rào cản tái lập đầy đủ, dù vẫn cho phép tái lập mức suy luận và đánh giá ở lớp ứng dụng.

6.5 Hướng cải tiến tiềm năng

- Chưng cất tri thức sang các mô hình chi phí thấp hơn cho triển khai ở thiết bị biên.
- Thích nghi miền dữ liệu cho dữ liệu giám sát ban đêm/ánh sáng yếu.
- Bổ sung hậu xử lý theo chất lượng/độ bất định để giảm dương tính giả có độ tự tin cao.

Bảng II.1: So sánh phương pháp chương sách và SCRFD: cùng mục tiêu, khác cách hiện thực

Khía cạnh	**Chương sách (cổ điển)**	**Bài báo SCRFD (hiện đại)**
Thiết kế đặc trưng	Họ đặc trưng thủ công Haar/LBP	Hệ đặc trưng CNN học sâu đa tầng
Lõi học máy	Xây dựng bộ phân loại dựa trên boosting	Tìm kiếm CR + SR dưới ràng buộc ngân sách tính toán
Chiến lược tốc độ	Loại sớm bằng cascade	Tái cấu trúc phân bổ tính toán + họ mô hình gọn
Xử lý tỉ lệ	Quét theo tháp/quy tắc kinh nghiệm đa góc nhìn	Tái phân bổ tăng cường theo thang tỉ lệ được tìm kiếm
Hợp nhất kết quả cuối	Gom các cửa sổ chồng lấp	NMS chuẩn trên dự đoán dày đặc

6.6 Tóm tắt so sánh chương sách và SCRFD

7 Kết luận

SCRFD giữ nguyên mục tiêu theo giai đoạn của bộ phát hiện đã hình thành từ phát hiện cổ điển, nhưng thay thế từng giai đoạn bằng cơ chế học được, có nhận thức ngân sách tính toán và nhạy theo thang tỉ lệ. Cấu trúc hai chương này làm rõ cả nền tảng lịch sử (chương sách) lẫn hiện thực tiên tiến hiện đại (bài báo) trong một mạch báo cáo nghiên cứu thống nhất.

Tài liệu tham khảo

[1] S. Z. Li and J. Wu, "Face detection," in *Handbook of Face Recognition*, S. Z. Li and A. K. Jain, Eds., 2nd ed., Springer, 2011, pp. 277–301. DOI: 10.1007/978-0-85729-932-1_11

[2] P. Viola and M. Jones, "Rapid object detection using a boosted cascade of simple features," in *2001 IEEE Computer Society Conference on Computer Vision and Pattern Recognition*, 2001, pp. I-511–I-518. DOI: 10.1109/CVPR.2001.990517

[3] P. Viola and M. Jones, "Robust real-time face detection," *International Journal of Computer Vision*, vol. 57, no. 2, pp. 137–154, 2004. DOI: 10.1023/B:VISI.0000013087.49260.fb

[4] OpenCV Team. "Opencv cascade classifier documentation," Accessed: Feb. 27, 2026. [Online]. Available: https://docs.opencv.org/4.x/db/d28/tutorial_cascade_classifier.html

[5] S. Ren, K. He, R. Girshick, and J. Sun, "Faster r-cnn: Towards real-time object detection with region proposal networks," in *Advances in Neural Information Processing Systems*, vol. 28, 2015. Accessed: Feb. 26, 2026. [Online]. Available: https://arxiv.org/abs/1506.01497

[6] T.-Y. Lin, P. Goyal, R. Girshick, K. He, and P. Dollar, "Focal loss for dense object detection," in *2017 IEEE International Conference on Computer Vision*, 2017, pp. 2999–3007. DOI: 10.1109/ICCV.2017.324

[7] C. Huang, H. Ai, Y. Li, and S. Lao, "High-performance rotation invariant multiview face detection," *IEEE Transactions on Pattern Analysis and Machine Intelligence*, vol. 29, no. 4, pp. 671–686, 2007. DOI: 10.1109/TPAMI.2007.1011

[8] G. Bradski, "The opencv library," *Dr. Dobb's Journal of Software Tools*, 2000.

[9] S. Yang, P. Luo, C. C. Loy, and X. Tang, "Wider face: A face detection benchmark," in *2016 IEEE Conference on Computer Vision and Pattern Recognition (CVPR)*, 2016, pp. 5525–5533. DOI: 10.1109/CVPR.2016.596

[10] Hugging Face Datasets. "Cuhk-cse/wider_face dataset mirror," Accessed: Feb. 27, 2026. [Online]. Available: https://huggingface.co/datasets/CUHK-CSE/wider_face

[11] S. C. Brubaker, J. Wu, J. Sun, M. D. Mullin, and J. M. Rehg, "On the design of cascades of boosted ensembles for face detection," *International Journal of Computer Vision*, vol. 77, no. 1-3, pp. 65–86, 2008. DOI: 10.1007/s11263-007-0084-7

[12] S. Z. Li and Z.-Q. Zhang, "Floatboost learning and statistical face detection," *IEEE Transactions on Pattern Analysis and Machine Intelligence*, vol. 26, no. 9, pp. 1112–1123, 2004. DOI: 10.1109/TPAMI.2004.64

[13] J. Wu, S. C. Brubaker, M. D. Mullin, and J. M. Rehg, "Fast asymmetric learning for cascade face detection," *IEEE Transactions on Pattern Analysis and Machine Intelligence*, vol. 30, no. 3, pp. 369–382, 2008. DOI: 10.1109/TPAMI.2007.70766

[14] J. Guo, J. Deng, A. Lattas, and S. Zafeiriou, "Sample and computation redistribution for efficient face detection," in *International Conference on Learning Representations (ICLR)*, 2022. Accessed: Feb. 25, 2026. [Online]. Available: https://openreview.net/forum?id=RhB1AdoFfGE

[15] R. Girshick, J. Donahue, T. Darrell, and J. Malik, "Rich feature hierarchies for accurate object detection and semantic segmentation," *arXiv preprint arXiv:1311.2524*, 2014. Accessed: Feb. 26, 2026. [Online]. Available: https://arxiv.org/abs/1311.2524

[16] R. Girshick, "Fast r-cnn," in *2015 IEEE International Conference on Computer Vision*, 2015, pp. 1440–1448. DOI: 10.1109/ICCV.2015.169

[17] W. Liu et al., "Ssd: Single shot multibox detector," *arXiv preprint arXiv:1512.02325*, 2016. Accessed: Feb. 26, 2026. [Online]. Available: https://arxiv.org/abs/1512.02325

[18] J. Redmon, S. Divvala, R. Girshick, and A. Farhadi, "You only look once: Unified, real-time object detection," in *2016 IEEE Conference on Computer Vision and Pattern Recognition (CVPR)*, 2016, pp. 779–788. DOI: 10.1109/CVPR.2016.91

[19] J. Deng, J. Guo, Y. Zhou, J. Yu, I. Kotsia, and S. Zafeiriou, "Retinaface: Single-shot multi-level face localisation in the wild," *arXiv preprint arXiv:1905.00641*, 2020. Accessed: Feb. 26, 2026. [Online]. Available: https://arxiv.org/abs/1905.00641